

MASARYKOVA UNIVERZITA



Přírodovědecká fakulta



Markov Chain Monte Carlo metody a konvergenční diagnostiky s aplikací v ekonomii

Diplomová práce

Jméno a příjmení autora: Tomáš Kvaka

Vedoucí diplomové práce: Ing. Daniel Němec

Prohlašuji, že jsem diplomovou práci napsal samostatně, za použití uvedených pramenů a literatury.

V Brně dne

Tomáš Kvaka

Děkuji vedoucímu práce Ing. Danielovi Němcovi za trpělivé a ochotné korigování mého snažení i za cenné inspirativní podněty. Za důvěru a inspiraci děkuji Verunce.

Brno, 2008

.....
Tomáš Kvaka

Obsah

Úvod	3
1 MCMC algoritmy	5
1.1 Markovské řetězce v MCMC	5
1.2 Gibbsův vzorkovač	6
1.3 Metropolis-Hastings algoritmus	7
1.3.1 Independence Chain M-H algoritmus	9
1.3.2 Random Walk Chain M-H algoritmus	9
2 MCMC diagnostiky	11
2.1 Obecné konvergenční metody	13
2.1.1 Gelman a Rubin	13
2.1.2 Brooks a Gelman	14
2.1.3 Heidelberg a Welch	17
2.1.4 Yu a Mykland CUSUM metoda	19
2.1.5 Metoda Raftery a Lewis	20
2.1.6 Gewekova konvergenční diagnostika	22
2.2 Specifické metody	23
2.2.1 Robertsova L^2 konvergenční metoda	23
2.2.2 Johnsonova diagnostika	24
2.2.3 Metoda Rittera a Tannera	24
2.2.4 Meoda Zellnera a Mina	25
2.2.5 Liuova, Liuova a Rubinova L^2 konvergenční statistika .	26
2.2.6 Yuova L^1 diagnostika	27
3 Aplikace konvergenčních metod	29
3.1 Použití vybraných metod	32
3.1.1 Raftery a Lewis	32
3.1.2 CUSUM graf	33
3.1.3 Heidelberg a Welch	36
3.1.4 Gelman a Rubin	37

3.1.5	Brooks a Gelman	39
3.1.6	Gewekeova CD diagnostika	43
3.2	Zhodnocení	44
4	Aplikace konvergenčních diagnostik v kontextu DSGE mo-	
	delu	46
4.1	RBC a DSGE model	46
4.2	Bayesianský odhad modelu	49
4.3	Aplikace konvergenčních metod	50
	Závěr	57
A	Grafy pro ostatní parametry RBC modelu	61
B	Programové vybavení pro Matlab	68

Úvod

V ekonomii hrají významnou roli modely a jejich identifikace. V rámci identifikace modelu se obvykle zabýváme odhady parametrů těchto modelů. Jednou z možností odhadu je aplikace bayesiánského přístupu, který je založen na několika jednoduchých zákonech pravděpodobnosti, což přispívá k jeho univerzálnímu použití. Nechť y je vektor nebo matice dat a θ je vektor parametrů, pomocí něhož vysvětlujeme chování veličiny y . Pro řešení použijeme Bayesovo pravidlo a následně upravíme do tvaru:

$$p(\theta|y) \propto p(\theta)p(y|\theta)$$

Neboli posteriorní hustota $p(\theta|y)$ je proporcionální součin apriorní hustoty $p(\theta)$ a věrohodnostní funkce $p(y|\theta)$. V mnoha případech je analytická konstrukce posteriorního rozdělení nezvládnutelným úkolem. V těchto situacích aplikujeme výpočetní procedury, které využívají počítačové simulace a místo analytického odvození a analýzy skutečného posteriorního rozdělení parametrů generují náhodné výběry (vzorky), které by měly odpovídat výběrům z neznámé posteriorní hustoty. Tyto nástroje se staly velice populárními pro analýzu komplexních statistických modelů. Nazýváme je Markov Chain Monte Carlo, MCMC algoritmy, neboť generují náhodné výběry, které tvoří Markovské řetězce a jejich rozdělení těchto výběrů se blíží alespoň limitně k posteriornímu. Na základě těchto výběrů jsou pomocí tzv. Monte Carlo integrace odhadovány libovolné statistiky cílové posteriorní hustoty parametrů (jako jsou např. střední hodnota nebo rozptyl). Právě problém diagnostiky toho, zda-li náš výběr můžeme pokládat za výběr z posteriorního rozdělení se stane hlavní náplní naší práce. Budeme se zabývat tzv. konvergenčními diagnostikami. Těch existuje celá řada. Cílem naší práce bude jejich přehledný popis a podrobná analýza těch diagnostik, které jsou obecně uplatnitelné na jakýkoliv MCMC řetězec. Analýza bude probíhat na základě srovnání kvality diagnostiky konvergence, a to v kontextu umělého příkladu, kde jsme s jistotou schopni říci, jaké je skutečné (teoretické) posteriorní rozdělení. Výsledky tohoto experimentu budu využity v aplikaci diagnostik v rámci identifikace ekonomického modelu RBC. V první části práce uvedeme základy

Markovských řetězců a definujeme některé nezbytné předpoklady k jejich sestavení. Pak představíme nejznámější MCMC procedury a konkrétněji Gibbsův vzorkovač a Metropolis-Hastings algoritmus. Stěžejní částí naší práce bude prezentace konvergenčních diagnostik, a to jak teoreticky, tak s následnou implementací na námi vygenerovaný umělý model pomocí Gibbsova vzorkovače. Poslední částí bude aplikace metod na novokeynesiánský model reálných cyklu RBC, kde provedeme odhady parametrů modelu pomocí Dynare programu. Ten využívá právě Metropolis-Hastings algoritmus. Na vygenerované řetězce pak aplikujeme námi vybrané diagnostické prostředky k verifikaci úspěšnosti konvergence těchto odhadů.

Kapitola 1

MCMC algoritmy

V této kapitole uvedeme základy teorie Markovských řetězců a následně představíme MCMC algoritmy. Budeme zde vycházet z vynikající knihy bayesiánské ekonometrie od Garyho Koopa[1].

1.1 Markovské řetězce v MCMC

Markovský řetězec je stochastický proces s pravděpodobností v čase t tak, že pravděpodobnost přechodu do nového stavu závisí jenom na aktuálním členu, $\theta^{(t)}$, a proto nezávisí na předešlých hodnotách, $\theta^{(0)}, \theta^{(1)}, \dots, \theta^{(t-1)}$. Formálně to můžeme vyjádřit:

$$p(\theta^{(t)} \in A | \theta^{(0)}, \theta^{(1)}, \dots, \theta^{(t-2)}, \theta^{(t-1)}) = p(\theta^{(t)} \in A | \theta^{(t-1)}).$$

Uvažujeme Markovskou posloupnost se stavy nespočetné množině $E \subseteq \mathbb{R}^1$. Nechť $X_0, X_1, \dots, X_n$ je Markovský řetězec, $K(x, y)$, označme jeho jádro přechodu, popisující pravděpodobnost přechodu ze stavu x do stavu y . V případě MCMC je zpravidla substochastické, tj.

$$\int_E K(x, y) dy \leq 1, \quad R(x) = 1 - \int_E K(x, y) dy \geq 0,$$

kde $R(x)$ je pravděpodobnost, že řetězec zůstane ve stavu x . Dále označme

$$K^t(x, y) = \int_E K(x, z)^{t-1} K(z, y) dz + K(x, y)^{t-1} R(y) + [R(x)]^{t-1} K(x, y)$$

jádro popisující přechody za t -kroků. Označme ještě $p(x)$ jako hustotu invariantní distribuce řetězce a předpokládejme, že $p(x) > 0$ na E . Tato hustota pak splňuje

$$\int_A p(x) dx = \int_E P(X^{(1)} \in xA | X^{(0)} = z) p(z) dz,$$

pro všechny měřitelné množiny $A \subset E$. Přitom je

$$P(X^{(1)} \in A | X^{(0)} = z) = \int_a K(z, y) dy + R(z) \cdot 1[z \in A].$$

Jádro K je ireducibilní, jestliže pro všechna $x \in E$ a pro všechny měřitelné $A \subset E$ je $P(X^{(1)} \in A | X^{(0)} = x) > 0$ pro nějaké $t > 0$. Dále jádro je aperiodické, když pro žádné $n \geq 2$ neexistuje rozklad $\bigcup_{j=1}^n B_j = E$ takový, že řetězec pravidelně (periodicky) navštěvuje množiny B_j . Tyto definice jsou známy ze standardní teorie Markovských řetězců a také jsou základem konvergence řetězců k jeho invariantnímu rozdělení, viz [1]. Důležité je pak toto tvrzení: Nechť p je hustota jednorozměrného rozdělení řetězce $X_0, X_1, \dots, X_n$ a přechodové jádro K je ireducibilní a aperiodické, pak při $t \rightarrow \infty$, pro každé $x \in E$

1.

$$\int_E |K^t(x, y) - p(y)| dy \rightarrow 0.$$

2. A pro reálnou a p -integrovanou funkci g ,

$$\frac{1}{t} \sum_{s=1}^t g(X^{(s)}) \rightarrow \int_E g(x) p(x) dx.$$

Tvrzení 1. nám říká, že rozdělení $X^{(t)}$ konverguje k invariantnímu rozdělení a 2. tvrzení, také označováno jako ergodičnost, nám vypovídá, že průměr z členů řetězce je rozumným odhadem pro střední hodnotu invariantního rozdělení (a že to platí i pro různé transformace řetězce). Z těchto tvrzení vyplývá, že MCMC algoritmy musí poskytovat ireducibilní a aperiodické markovské řetězce, aby byly splněny podmínky konvergence. Nyní představíme metody, které jsou hojně využívány v bayesovské analýze a splňují námi uvedené předpoklady pro Markovské řetězce.

1.2 Gibbsův vzorkovač

Princip tohoto nástroje prezentujeme na p -rozměrném vektoru parametrů θ a posteriorní hustotě $p(\theta|y)$. Navíc si rozdělíme θ do více bloků, tedy $\theta = (\theta_{(1)}, \theta_{(2)}, \dots, \theta_{(B)})$, kde $\theta_{(i)}$ může být vektor či skalár pro $j = 1, 2, \dots, B$. Pak například v lineárně regresním modelu nastavujeme $B = 2$, tedy $\theta_{(1)} = \beta$ a $\theta_{(2)} = h$, kde β jsou regresní koeficienty a $h = \frac{1}{\sigma^2}$ je přesnost chyby. Monte carlo integrace poskytuje odhad $E[g(\theta)|u]$, na základě náhodných výběrů z $p(\theta|y)$, a to pro jakoukoliv funkci $g(\theta)$. Ne vždy však můžeme provést náhodné výběry z $p(\theta|y)$. Často je však možné provést náhodné výběry

z $p(\theta_{(1)}|y, \theta_{(2)}, \dots, \theta_{(B)}), p(\theta_{(2)}|y, \theta_{(1)}, \dots, \theta_{(B)}), \dots, p(\theta_{(1)}|y, \theta_{(1)}, \dots, \theta_{(B-1)})$. Tato množina rozdělení se pak nazývá množinou plně podmíněných posteriorní rozdělení, neboť definují posteriorní hustotu pro každý blok podmíněnou ostatními bloky. Náhodné výběry z těchto podmíněných rozdělení nám pak dávají sekvenci vzorků, $\theta^{(1)}, \theta^{(2)}, \dots, \theta^{(S)}$, které můžeme zprůměrovat k odhadu $E[g(\theta)|y]$ pomocí Monte Carlo integrace. Obecný algoritmus Gibbsova vzorkovače si můžeme definovat následovně:

Pro $s = 1, \dots, S$

- Krok 0: Zvolíme počáteční hodnotu, $\theta^{(0)}$
- Krok 1. Provedeme náhodný výběr, $\theta_{(1)}^{(s)}$ z $p(\theta_{(1)}|y, \theta_{(2)}^{(s-1)}, \theta_{(3)}^{(s-1)}, \dots, \theta_{(B)}^{(s-1)})$
- Krok 2. Provedeme náhodný výběr, $\theta_{(2)}^{(s)}$ z $p(\theta_{(2)}|y, \theta_{(1)}^{(s-1)}, \theta_{(3)}^{(s-1)}, \dots, \theta_{(B)}^{(s-1)})$
- Krok 3. Provedeme náhodný výběr, $\theta_{(B)}^{(s)}$ z $p(\theta_{(B)}|y, \theta_{(1)}^{(s-1)}, \theta_{(2)}^{(s-1)}, \dots, \theta_{(B-1)}^{(s-1)})$

Získáme tak S výběrů, $\theta^{(s)}$, pro $s = 1, \dots, S$. Problémem je nalezení počátečního výběru $\theta^{(0)}$. Pokud bychom uměli uskutečnit náhodný výběr z $p(\theta|y)$ nepotřebovali bychom pak použít Gibbsův vzorkovač, ale využili bychom samotnou Monte Carlo integraci. Můžeme však ukázat, že počáteční nastavení $\theta^{(0)}$ nebude hrát žádnou roli ve smyslu konvergence z Gibbsova vzorkovače k sekvencím výběrů z $p(\theta|y)$. Po zvolení počáteční hodnoty $\theta^{(0)}$, provedeme S -replikaci Gibbsova vzorkovače. Poté odstraníme prvních S_0 vzorků, abychom se snažili eliminovat efekt počáteční hodnoty. Ze zbývajících pozorování pak můžeme spočítat námi požadované charakteristiky. V rámci této metody vznikají dvě otázky. Jak velké zvolit S_0 , aby byl odstraněn vliv $\theta^{(0)}$ na výsledky? A kolik replikací S musíme zvolit, aby Gibbsův vzorkovač zkonvergoval k výběrům z $p(\theta|y)$? Na zodpovězení těchto otázek byly vytvořeny konvergenční diagnostiky, které jsou probírány níže.

1.3 Metropolis-Hastings algoritmus

V rámci Metropolis-Hastings algoritmu si je možno představit celou skupinu algoritmů, jež lze využít k vytvoření posteriorních simulátorů pro širokou škálu modelů. Opět využijeme označení θ , vektor parametrů, $p(y|\theta)$ bude věrohodnostní funkce, $p(\theta)$ apriorní a $p(\theta|y)$ posteriorní hustota. Definujeme zde tzv. kandidátskou hustotu, "candidate generating density". Nechť θ^* bude označovat výběr právě z této hustoty pravděpodobnosti, který označíme $q(\theta^{s-1}; \theta)$. Toto označení je interpretováno tak, že kandidátský výběr θ^* je realizací náhodné veličiny θ , jejíž hustota závisí na θ^{s-1} . Jinak řečeno,

současný výběr závisí na předchozím, což implikuje existenci Markovského řetězce pro sekvenci $s = 1, \dots, S$, a proto je tento algoritmus označován jako MCMC algoritmus. Potom Metropolis-Hastings algoritmus má následující podobu:

- Krok 0: Zvolíme počáteční hodnotu, $\theta^{(0)}$.
- Krok 1: Vygenerujeme kandidátský výběr θ^* s kandidátské hustoty $q(\theta^{(s-1)}; \theta)$.
- Krok 2: Spočítáme akceptační pravděpodobnost $\alpha(\theta^{(s-1)}, \theta^*)$.
- Krok 3: Přiřadíme $\theta^{(s)} = \theta^*$ s pravděpodobností $\alpha(\theta^{(s-1)}, \theta^*)$ a $\theta^{(s)} = \theta^{(s-1)}$ s pravděpodobností $1 - \alpha(\theta^{(s-1)}, \theta^*)$.
- Krok 4. Opakujeme Krok 1, 2 a 3 celkem S -krát.
- Krok 5. Spočítáme průměr S výběrů $g(\theta^{(0)}), \dots, g(\theta^{(S)})$.

Tímto způsobem získáme odhad $E[g(\theta)|y]$ pro jakoukoliv funkci, která nás zajímá. Intuitivně lze MCMC algoritmus chápat jako proces procházející celou oblast posteriorní hustoty, kdy vybírá nejčastěji vzorky z oblasti vysoké posteriorní hustoty pravděpodobnosti a proporcionálně méně vzorků z oblasti nízké posteriorní hustoty. Kandidátská hustota není identická s posteriorní hustotou a výběry z ní by nepokryly celý parametrický prostor. Metropolis-Hastings řeší tento nesoulad tím, že neakceptuje každý kandidátský výběr. Odvozuje se proto akceptační pravděpodobnost, která je nejvyšší v oblastech vysoké posteriorní hustoty a naopak nejnižší v oblastech nízké posteriorní hustoty. Z toho vyplývá, že způsob konstrukce akceptační pravděpodobnost, která závisí na θ^* a $\theta^{(s-1)}$, by měl rychle posouvat řetězec z oblasti nízké posteriorní pravděpodobnosti do oblasti vyšší posteriorní pravděpodobnosti. V tomto duchu definujeme akceptační pravděpodobnost jako:

$$\alpha(\theta^{(s-1)}, \theta^*) = \min \left[\frac{p(\theta = \theta^*|y)q(\theta^* = \theta^{(s-1)})}{p(\theta = \theta^{(s-1)}|y)q(\theta^{(s-1)} = \theta^*)}, 1 \right]$$

Poznamenejme, že operátor minima je tady uplatněn proto, aby akceptační pravděpodobnost nemohla být větší než jedna. Problémem této metody se stal správný výběr kandidátské hustoty. Při nevhodném výběru může dojít k tomu, že fakticky mohou být všichni kandidáti zamítnuty a tím pádem řetězec stagnuje na jednom místě. Samozřejmě i zde musí být aplikovány konvergenční diagnostiky k verifikaci konvergence řetězce. Existuje spousta postupů výběrů kandidátské hustoty. My uvedeme dva nejznámější.

1.3.1 Independence Chain M-H algoritmus

Již z názvu můžeme usuzovat, že tento představený algoritmus využívá kandidátských hustot, které nezávisí na předchozích výběrech. Neboli funkce $q(\theta^{(s-1)}; \theta) = q^*(\theta)$ a kandidátská hustota tak nezávisí na $\theta^{(s-1)}$. Tato metoda má úspěšné použití při existenci vhodné aproximace posteriorní hustoty, kterou pak použijeme jako kandidátskou hustotu. Tím pak akceptační pravděpodobnost zjednodušíme na:

$$\alpha(\theta^{(s-1)}, \theta^*) = \min \left[\frac{p(\theta = \theta^* | y) q^*(\theta = \theta^{(s-1)})}{p(\theta = \theta^{(s-1)} | y) q^*(\theta^{(s-1)} = \theta^*)}, 1 \right]$$

Jak už bylo zmíněno u této metody je nejpodstatnější výběr kandidátské hustoty. Neexistuje obecný návod na její sestavení. V nejen Koop[1] se uvádí, že pro dostatečně velké n , můžeme aproximativně určit posteriorní hustotu z (vícerozměrného) normálního rozdělení. V praxi však se častěji využívá Studentovo rozdělení, jelikož má širší konce a je zde větší pravděpodobnost pokrytí celého parametrického prostoru. To nastává hlavně při nízkém ν , neboli počtu volnosti studentova rozdělení t . Samozřejmě existují případy, kdy ani volba t rozdělení nám nezajistí adekvátní výběr. To může nastat například v multimodální nebo nějak omezené posteriorní hustotě, například u Gamma rozdělení (definované na kladných číslech). U této metody je přímo nezbytné diagnostikovat konvergenci, neboť vše je postavené na výběru aproximativní posteriorní hustoty - kandidátské hustoty.

1.3.2 Random Walk Chain M-H algoritmus

Když nejsme schopni nalézt vhodnou aproximaci posteriorní hustoty, využijeme Random Walk Chain M-H metodu. Ta využívá kandidátskou hustotu, která náhodně cestuje parametrickým prostorem. Provádíme náhodné výběry různých oblastech posteriorní hustoty. Formálně můžeme vyjádřit generování kandidátů jako:

$$\theta^* = \theta^{(s-1)} + z$$

kde z se nazývá "increment random variable", tedy přírůstková náhodná veličina. Také můžeme říci, že jednotliví kandidáti jsou generováni jako náhodná procházka. Posun žádoucím směrem nám pak zaručí akceptační pravděpodobnost, která je redukována na tvar:

$$\alpha(\theta^{(s-1)}, \theta^*) = \min \left[\frac{p(\theta = \theta^* | y)}{p(\theta = \theta^{(s-1)} | y)}, 1 \right]$$

K přesné formě kandidátské hustoty je nutné determinovat náhodnou veličinu z . Obvyklým způsobem je výběr uskutečněn z mnohorozměrného

normálního rozdělení. Střední hodnotu pak reprezentuje předchozí výraz a nezbývá nic jiného než určit kovarianční matici Σ :

$$q(\theta^{(s-1)}; \theta) = f_N(\theta | \theta^{(s-1)}, \Sigma).$$

Výběr této matice se stává důležitým aspektem tohoto M-H algoritmu, protože má velký vliv na hodnotu akceptační pravděpodobnosti. Nízké celkové akceptační pravděpodobnosti způsobí neúnosné požadavky na velikost generovaného vzorku, neboť jen zřídka kdy algoritmus projde celou posteriorní hustotou. Tato skutečnost implikuje situaci, kdy Σ je "velké" a většina vzorků pochází z konce posteriorního rozdělení. Problémem je rovněž situace, kdy akceptační poměr je vysoký, čímž také nedosáhneme generování vzorku z celé posteriorní oblasti, jelikož vzorky θ^* a $\theta^{(s-1)}$ budou blízko u sebe. Jako obecné a praxi prověřené lze brát pravidlo, že akceptační podíl by měl ležet v intervalu 0.2 až 0.5. Tato informace poskytuje uživateli velkou možnost odhadu matice Σ . Jedním ze způsobů je přiřazení odhadu kovarianční matice parametrů θ , na základě maximalizace funkce posteriorní hustoty.

Kapitola 2

MCMC diagnostiky

U MCMC algoritmů vzniká řada otázek. Jednou z nich je otázka, jakou velikost má mít výsledná simulace, aby byl zajištěn výběr z posteriorní hustoty a jestli už odezněl vliv počátečních hodnot θ_0 ? Pro zodpovězení těchto otázek byla vytvořena spousta procedur zjišťující konvergenci MCMC algoritmu do cílového rozdělení. Jako základní rozdělení metod použijeme těchto sedm bodů uvedených M.K. Cowless a B.P. Carlin[8].

1. *Teoretický základ.* Konvergenční diagnostiky mohou vycházet z matematické teorie, mohou vycházet z jednoduchých "CUSUM" grafů, jádrové hustoty, či pokročilé teorii pravděpodobnosti. Méně sofistikované metody jsou obvykle všeobecně aplikovatelné a jednoduše naprogramovatelné, ale na druhou stranu někdy dochází k jejich nevěrohodnosti, například v komplexnějších modelech.

2. *Diagnostickeý cíl.* Většina diagnostických procedur zkoumá odchylky nebo vzdálenosti odhadnuté hodnoty spočtené v každé iteraci od pravé hodnoty cílového rozdělení. Některé zas porovnávají rozptyly nebo preciznost těchto odhadů, které se pak stávají z praktického hlediska významnější.

3. *Výstupní formát.* Některé postupy jsou kvantifikovány a výstupem je jednoduché shrnující číslo. Ty jsou samozřejmě i jednoduše interpretovány. Ostatní mohou být grafické, či mít jiné kvalitativní zobrazení. U těchto výstupů dochází někdy k problémům s jejich vysvětlením a často se tak jedná o subjektivní záležitost.

4. *Replikace.* Zde se rozděluje na aplikace jednoho Markovova řetězce nebo užití více paralelních řetězců při různých počátečních hodnotách k získání diagnostického výstupu.

5. *Dimenze.* Některé postupy zkoumají marginální hustoty parametrů a jiné se pokouší o diagnostiku konvergence plné sdružené hustoty parametrů. Můžeme říci, že diagnostiky založené na sdružené posteriorní hustotě jsou v některých případech neproveditelnou záležitostí, hlavně ve vysoce di-

menzionálním prostoru. A dochází zde někdy nahrazení sdružené hustoty jednorozměrným reprezentantem.

6. Použitelnost. Některé diagnostiky můžeme aplikovat pouze na Gibbsův vzorkovač, jiné jsou použitelné na jakýkoliv MCMC algoritmus nebo na různé jejich varianty.

7. Obtížnost jejich použití. Nakonec je můžeme rozdělit pomocí obtížnosti jejich programování a následné náročnosti na výpočet. Není pak překvapením, že obecné metody na rozdíl od těch specifických, které jsou použitelné pro jakýkoliv MCMC algoritmus, budou populárními nástroji konvergenční analýzy.

Nyní uvedeme následující tabulku, kde jsou prezentovány konvergenční diagnostiky rozdělené podle těchto charakteristik, publikovanou v [8].

Tabulka 2.1: Publikované konvergenční metody

Konvergenční metoda	Teoretický základ	Diagnostický cíl	Výstupní formát	Replikace	Dimenze	Použitelnost
Gelman a Rubin (1992)	Rozsáhlé porovnávání	Odchylky	Kvantitativní	Více řetězců	Marginální hustota	Všechny MCMC
Brooks a Gelman	Rozsáhlé porovnávání	Odchylky	Kvantitativní I grafický	Více řetězců	Marginální hustota	Všechny MCMC
Heidelberg a Welch (1983)	Spektrální Analýza	Odchylky i Rozptyly	Kvantitativní	Jeden řetězec	Marginální hustota	Všechny MCMC
Yu a Mykland (1994)	CUSUM plot	Odchylky i Rozptyly	Grafický	Jeden řetězec	Marginální hustota	Všechny MCMC
Raftery a Lewis (1992)	Markovské řetězce	Odchylky i Rozptyly	Kvantitativní	Jeden řetězec	Marginální hustota	Všechny MCMC
Geweke (1992)	Spektrální analýza	Odchylky i Rozptyly	Kvantitativní	Jeden řetězec	Marginální hustota	Všechny MCMC
Roberts (1992)	Pravděpodobnost	Odchylky	Grafický	Jeden řetězec	Sdružená hustota	Některé MCMC
Johnson (1994)	„Fixní bod“ teorém	Odchylky	Kvantitativní	Více řetězců	Sdružená hustota	Některé MCMC
Ritter a Tanner	„Importance“ váhy	Odchylky	Grafický	Jeden řetězec	Sdružená hustota	Gibbsův Vzorkovač
Zellner a Min (1995)	Podmíněná pravděpod.	Odchylky	Kvantitativní	Jeden řetězec	Sdružená hustota	Některé MCMC
Liu, Liu a Rubin (1992)	Pravděpodobnost	Odchylky	Kvantitativní I grafický	Více řetězců	Sdružená hustota	Gibbsův Vzorkovač
Yu (1994)	Jádrová hustota	Odchylky	Grafický	Jeden řetězec	Marginální hustota	Některé MCMC

Teď představíme jednotlivé konvergenční metody rozdělené do dvou částí. V první budou uvedeny obecné metody použitelné pro jakýkoliv MCMC al-

goritmus. V té druhé představíme diagnostiky specificky diverzifikované, a to buď algoritmicky nebo modelově specifické. Toto rozdělení je učiněno záměrně, jelikož se chceme výhradně zabývat těmi obecnými a ty pak aplikovat ve 4. a 5. kapitole. U obecných metod vycházíme s původních článků od autorů těchto diagnostik, zatímco při modelově specifických využijeme článek Cowless a Carlin[8].

2.1 Obecné konvergenční metody

2.1.1 Gelman a Rubin

Tato metoda byla poprvé uvedena v Gelman[5]. Vyžaduje aplikaci m paralelních řetězců s různými výchozími hodnotami. Je založena na zkoumání a následném porovnávání rozptylu v rámci řetězce a v rozptylech mezi paralelními sekvencemi. Výsledkem je jejich porovnání a následné jednoduché kvantitativní vyjádření.

Nechť $\theta^{(0,i)}$ pro $i = 1, \dots, m$ označuje m počátečních hodnot z různých oblastí parametrického prostoru. Jedná se tzv. overdispersed starting values, tedy silně rozptýlené počáteční hodnoty. Návod na určení těchto hodnot je popsán v původní literatuře [5]. Jde o nalezení K modů cílového rozdělení, kde oblasti nejvyšších posteriorních hustot budou aproximovány mixem K vícerozměrných normálních rozdělení se střední hodnotou μ_K a kovarianční maticí Σ_k odpovídající druhé derivace v každém modu. Pak výběr z tohoto rozdělení dělený skalární náhodnou veličinou (obvykle z χ^2) bude tvořit počáteční rozptýlené hodnoty pro příslušný posteriorní simulátor.

Nechť $\theta^{(s,i)}$ pro $s = 1, \dots, S$ označuje S výběrů navzorkovaných Gibbsovým vzorkovačem z i -té počáteční hodnoty a $\hat{g}_{S_i}^{(i)}$ vyjadřuje odpovídající odhad $E[g(\theta)|y]$. Intuitivně, pokud by efekt počátečních hodnot odezněl, každá z těchto sekvencí by měla být stejná, resp. podobná. Tedy rozptyl spočtený mezi sekvencemi by neměl být velký vzhledem k rozptylu v rámci sekvence. Obvyklým odhadem rozptylu sekvence je:

$$s_i^2 = \frac{1}{S_1 - 1} \sum_{s=S_0+1}^S [g(\theta^{(s,i)}) - \hat{g}_{S_i}^{(i)}]^2$$

což označuje vnitřní rozptyl sekvence. Lze pak definovat průměrný rozptyl vnitřních rozptylů sekvencí jako

$$W = \frac{1}{m} \sum_{i=1}^m s_i^2$$

Obdobně lze ukázat, že mezisekvenční rozptyl je možno odhadnout jako:

$$B = \frac{S_1}{m-1} \sum_{i=1}^m (\hat{g}_{S_i}^{(i)} - \hat{g})^2,$$

kde

$$\hat{g} = \frac{1}{m} \sum_{i=1}^m \hat{g}_{S_i}^{(i)}.$$

Poznamenejme, že W je odhadem $\text{var}[g(\theta)|y]$. Lze ukázat, že odhadem $\text{var}[g(\theta)|y]$ je

$$\text{var}[\hat{g}(\theta)|y] = \frac{S_1 - 1}{S_1} W + \frac{1}{S_1} B$$

Pokud Gibbsův vzorkovač nezkonvergoval, potom W podhodnotí $\text{var}[g(\theta)|y]$. Intuitivně řečeno, pokud Gibbsův vzorkovač prošel jenom část posteriorní hustoty, měl by podhodnotit její varianci. Naopak B je založeno na sekvencích s rozptýlenými počátečními hodnotami. Tato rozptýlenost by měla implikovat, že pokud Gibbsův vzorkovač zkonvergoval, $\text{var}[\hat{g}(\theta)|y]$ nadhodnocuje $\text{var}[g(\theta)|y]$. Obvyklá konvergenční diagnostika má podobu:

$$\hat{R} = \frac{\text{var}[\hat{g}(\theta)|y]}{W}$$

Hodnoty by měly být větší než jedna, přičemž hodnoty blízké jedné indikují úspěšnou konvergenci. $\sqrt{\hat{R}}$ je označován jako odhadnutý "potential scale reduction factor" (PSRF). Lze jej interpretovat jako mez toho, jak vzdálené mohou být odhady směrodatné odchylky $g(\theta)$ díky nedostatečné konvergenci.

2.1.2 Brooks a Gelman

Brooks A Gelman provedli v roce (1996) v [9] korekce metody Gelman a Rubin 2.1.1. Taky přistupují k detekci konvergence přes několik paralelních řetězců. Navrhli různé varianty výpočtu PSRF, a to intervalový, momentový a vícerozměrný. Také přispěli k lepší interpretovatelnosti této metody jejím grafickým výstupem.

Doladili PSRF pro výběrový rozptyl s odhady stupňů volnosti s pro Studentovu t -aproximaci cílového rozdělení. Tento odhad je pořízen pomocí zobecněné metody momentů, kdy

$$d \approx \frac{2\hat{V}}{\widehat{\text{var}}(\hat{V})}$$

V původní metodě je použit faktor $d/d-2$, u kterého mohou nastat problémy s nekonečností či zápornými hodnoty pro pomalou konvergenci, kdy $d < 2$. Korektním faktorem, který vychází z vyhodnocení Fisherovy informace o t_d rozdělení a koriguje stupně volnosti pro $\hat{V}$ je pak

$$R_C = \frac{d+3}{d+1} R = \frac{d+3}{d+1} \frac{\hat{V}}{W}$$

Tyto korekce jsou však zanedbatelné, jelikož při konvergenci je d obrovské. Navrhují také iterující konvergenční přístup. Jde o grafický výstup, kdy jsou PSRF vypočítány na druhé polovině pozorování řad délky $2kb$ pro $k = 1, \dots, n/b$. Na volbě b závisí výpočetní náročnost, obecně se doporučuje přibližně použít $b \approx n/20$, jedná se o tvrzení z roku 1996. Dalším zlepšení verifikační vlastnosti této konvergenční diagnostiky je použití vykreslení $W^{\frac{1}{2}}$ a $\hat{V}^{\frac{1}{2}}$ do jednoho grafu. V konvergenci se tyto veličiny stabilizují a také ustálí na přibližně stejné hodnotě.

Jednoduchou metodou se stal intervalový PSRF, neboli $\hat{R}_{interval}$, který je založený na délce empirických intervalů. Postup pro jeho sestavení je následující:

- 1. z každého řetězce vezmeme empirický $100(1 - \alpha)\%$ interval (tzn. $100\frac{\alpha}{2}\%$ a $100(1 - \alpha)\%$ bod n nasimulovaných výběrů) $\Rightarrow$ vytvoříme m intervalových odhadů v rámci jednotlivých řetězců - IL_i (délka jednotlivých parametrů)
- 2. z celé množiny mn pozorování (ze všech řetězců) spočítáme empirický $100(1 - \alpha)\%$ interval $\Rightarrow$ odhad délky intervalu úplné řady TIL
- 3. spočítáme $\hat{R}$ definované jako

$$\hat{R}_{interval} = \frac{TIL}{\frac{1}{m} \sum_{i=1}^m IL_i}.$$

Pak stejně jako v předchozím případě hodnoty blízké jedné symbolizují úspěšnou konvergenci.

Momentový PSRF je založený na předpokladu existence vyšších momentů, ne jenom druhého řádu v původní verzi. Provedeme nahrazení čitatele a jmenovatele ve vztahu pro původní PSRF empirickými odhady centrovaných momentů s -tého řádu ze všech řetězců dohromady respektive průměrný s -tý moment počítaný pro každou sekvenci. Dostaneme pro $\hat{R}_s$ tvar:

$$\hat{R}_s = \frac{\frac{1}{mn-1} \sum_{j=1}^m \sum_{t=1}^n |\psi_{jt} - \bar{\psi}_{..}|^s}{\frac{1}{m(n-1)} \sum_{j=1}^m \sum_{t=1}^n |\psi_{jt} - \bar{\psi}_{j.}|^s}$$

Provedli také vícerozměrné rozšíření této metody. Jde o přímou analogii jednorozměrného přístupu, kdy ψ je vektor parametrů a $\psi_{jt}^{(i)}$ značí i -tý prvek vektoru parametrů v řetězci j v čase t , potom analogicky použijeme odhad posteriorní variančně-kovarianční matice.

$$W = \frac{1}{m(n-1)} \sum_{j=1}^m \sum_{t=1}^n (\psi_{jt} - \bar{\psi}_{j\cdot})(\psi_{jt} - \bar{\psi}_{j\cdot})'$$

$$B/n = \frac{1}{m-1} \sum_{j=1}^m (\bar{\psi}_{j\cdot} - \bar{\psi}_{\cdot\cdot})(\bar{\psi}_{j\cdot} - \bar{\psi}_{\cdot\cdot})',$$

kde B je p -rozměrný odhad mezisekvenční kovarianční matice, W je p -rozměrný odhad kovarianční matice v rámci sekvence. Pak můžeme monitorovat konvergenci pomocí vhodně zvoleného měřítka vzdálenosti mezi $\hat{V}$ a W , například použijeme příslušné determinanty matic. Existuje i celková skalární sumarizace jejich vzdálenosti a to pomocí

$$\hat{R}^p = \max_{\alpha} \frac{\alpha' \hat{V} \alpha}{\alpha' W \alpha},$$

které nazveme multivariate PSRF (MPSRF). Spočítat ho můžeme pomocí následujícího postupu:

Pro dvě nesingulární, pozitivně definitní a symetrické matice M a N platí

$$\max_{\alpha} \frac{\alpha' M \alpha}{\alpha' N \alpha} = \lambda,$$

kde λ je největší vlastní číslo pozitivně definitní matice $N^{-1}M$. Pak

$$\begin{aligned} \hat{R}^p &= \max_{\alpha} \frac{\alpha' \hat{V} \alpha}{\alpha' W \alpha} = \max_{\alpha} \frac{\alpha' \left[\frac{n-1}{n} W + B \frac{m+1}{mn} \right] \alpha}{\alpha' W \alpha} = \\ &= \frac{n-1}{n} + \left(\frac{m+1}{m} \right) \max_{\alpha} \frac{\alpha' B \alpha / n}{\alpha' W \alpha} = \frac{n-1}{n} + \left(\frac{m+1}{m} \right) \lambda_1, \end{aligned}$$

λ_1 je největší vlastní číslo symetrické, pozitivně definitní matice $W^{-1}B/n$. Při konvergenci se bude $\hat{R}^p$ přibližovat k hodnotě 1, jelikož $\lambda_1 \rightarrow 0$. Zde může nastat problém se singularitou matic W a B , v tom případě nám postačí informace na základě jejich determinantů. Jako souvislost mezi $\hat{R}^p$ a $\hat{R}$ lze využít aproximativně horní mez maximální jednorozměrné $\hat{R}$ statistiky přes všech p proměnných. Definujeme pro $k = 1, \dots, p$ je $\hat{R}(k)$ jednorozměrná PSRF aplikovaná na k -tý prvek vektoru θ a $\hat{R}^{max}$ označuje maximální hodnotu z $\hat{R}(k)$ pro $k = 1, \dots, p$, potom

$$\hat{R}^p = \max_{\alpha} \frac{\alpha' \hat{V} \alpha}{\alpha' W \alpha} \geq \max_k \frac{I_k' \hat{V} I_k}{I_k' W I_k} = \max_k \hat{R}(k) = \hat{R}_{max}.$$

2.1.3 Heidelberg a Welch

Tato konvergenční metoda byla jako první uvedena v [3]. Jde o kombinaci metody k detekci nestacionarity v nasimulovaném výstupu a odhadu variance výběrové střední hodnoty s použitím spektrální hustoty. Probíhá ve spuštění testů stacionarity a testu relativní poloviční šíře intervalu "half width interval" na různých částech řetězce.

Požaduje specifikovat čtyři základní parametry:

1. Maximum vygenerovaných vzorků $j_{\max}$
2. Počáteční bod j_1
3. Multiplikativní bod I
4. Pořadavek ϵ na relativní poloviční šířku intervalu

Test začne s j_1 vzorky. Pak se provede tzv. test stacionarity, popsáný níže, aplikovaný na $[X(n), n = 1, \dots, j_1]$ nebo jestliže existuje i n_0 , tak pak $[X(n), n = n_0 + 1, \dots, j_1]$. Z jeho výsledků se rozhodne, jestli tento vzorek má vlastnost kovariančně stacionárního procesu. Jestli se toto nepotvrdí, přecházíme do nového bodu $j_2 = \min\{I * j_1, j_{\max}\}$. Jestli však projde testovací procedurou, pak konfidenční interval bude generovaný z $[X(n), n = n_0 + 1, \dots, j_1]$. Tato procedura pak porovnává odhad relativní poloviční šíře intervalu s konfidenčním intervalem,

$$\text{ERHW} = (\text{šíře konfidenčního intervalu}) / 2\bar{X},$$

kde

$$\bar{X} = \frac{1}{j_1 - n_0} \sum_{n=n_0+1}^{j_1} X(n)$$

. Relativní poloviční šíře intervalu bude spojována s konfidenčním intervalem pro střední hodnotu, neboli $1.96 \times$ asymptotická standardní chyba NSE. Jestliže $\text{ERHW} \leq \epsilon$, pak končíme se simulací. Naopak jestli $\text{ERHW} > \epsilon$, následuje přechod do bodu $j_2 = \min\{I * j_1, j_{\max}\}$. Tento proces se opakuje ve stejném duchu s body $j_{k+1} = \min\{I * j_k, j_{\max}\}$ dokud konfidenční interval ERWH splní naše kritérium nebo j_{k+1} dosáhne $j_{\max}$. Tímto je procedura u konce. Mohou nastat dva případy. Za prvé, že náš výstup neprošel testem stacionarity, pak nemohou být vytvořené žádné konfidenční intervaly. Za druhé, při splnění kovariančně stacionárního procesu nebude generovaný interval spolehlivosti splňovat námi kladené požadavky ϵ . V praktických situacích Heidelberg a Welch navrhuji v proceduře ovlivňovat jenom dva parametry ze

čtyř, a to $j_{\max}$ a ϵ . Doporučují nastavit j_1 relativně veliké, kdy $j_1 = 0.1j_{\max}$ a $I = 1.5$. Těmito podmínkami proběhne simulací maximálně 6 testů.

Test stacionarity

Předpokládáme, že máme sekvenci $\{Y(j), : j = 1, \dots, n\}$ z kovariančně stacionárního procesu, který je ϕ -mixing a má spektrální hustotu $p(f)$. Nechť

$$S_0 = 0 \quad S_n = \sum_{j=1}^n Y_j \quad n \geq 1,$$

$$\bar{Y} = (1/n) \sum_{j=1}^n Y_j,$$

a

$$B_n(t) = \frac{S_{[nt]} - [nt]\bar{Y}}{(np(0))^{\frac{1}{2}}} \quad \text{pro } 0 \leq t \leq 1,$$

kde $[a]$ značí největší celé číslo menší nebo rovné a . Pak $B_n = \{B_n(t), 0 \leq t \leq 1\}$ konverguje distribučně k "Brownian bridge" $B = \{B(t), 0 \leq t \leq 1\}$ pro $n \rightarrow \infty$. Neboli pro velké n , má B_n přibližně "Brownian bridge" rozdělení B (Brownovský most).

V aplikaci této metody můžeme použít tyto čtyři statistiky založené na B_n :

1. Cramer von Misses statistika

$$\int_0^1 B_n(t)^2 dt = CVM(B_n).$$

2. Anderson-Darling statistika

$$\int_1^0 B_n(t)^2 / t(1-t) dt.$$

3. The Kolmogorov-Smirnov statistika

$$\sup\{|B_n(t)| : 0 \leq t \leq 1\} = KS(B_n(t)).$$

4. Schruben statistika

$$|B_n(t_n^*)| / (t_n^*(1-t_n^*)) = S(|B_n|),$$

kde t^* je hodnota, která nastane v supremu $|B_n(t_n)|$.

V praktických situacích nemůžeme použít vzorek funkcí z B_n , protože $p(0)$ je neznámé. Proto zde budeme pracovat s aproximativním odhadem

$$\hat{B}_n(t) = \frac{S_{[nt]} - [nt]\bar{Y}}{(n\hat{p}(0))^{\frac{1}{2}}} \quad \text{pro } 0 \leq t \leq 1,$$

kde $\hat{p}(0)$ je spektrální hustota odhadnutá ve frekvenci $\omega = 0$ a $[a]$ značí největší celé číslo menší nebo rovné a . Následně použijeme již představené statistiky $CVM(\hat{B}_n)$, $AD(\hat{B}_n)$, $KS(\hat{B}_n)$ a $S(|\hat{B}_n|)$ (případně některé z nich).

2.1.4 Yu a Mykland CUSUM metoda

CUSUM diagnostika je grafická metoda, která monitoruje konvergenci přes "CUSUM plot" s použitím hodnot z výstupu. Byla navržena Yu[6] v roce 1995 a dále diskutována v Brooks[7]. Může být aplikována na jakýkoliv posteriorní simulátor resp. MCMC algoritmus. Při výstupu $X_1, \dots, X_n$ a při odstranění počátečních n_0 iterací, které vyjadřují "burn-in" periody. Pak zkonstruujeme CUSUM graf pro souhrnné statistické parametry θ , podle těchto podmínek:

1. Spočteme

$$\hat{\mu} = (n - n_0)^{-1} \sum_{i=n_0+1}^n \theta(X_i).$$

2. Vytvoříme CUSUM jako

$$\hat{S}_T = \sum_{t=n_0+1}^T [\theta(x^t) - \hat{\mu}] \quad \text{pro } T = n_0 + 1, \dots, n.$$

3. Vykreslíme $\{\hat{S}_T\}$ na T pro $T = n_0 + 1, \dots, n$.

Yu a Mykland[17] uvádějí, že rychlost, kterou se řetězec "smíchá" (mixing), indikuje tzv. "hladkost" (smoothness) výsledků CUSUM grafu. Neboli vyhlazený graf vyjadřuje pomalé " ϕ -mixing", zatímco "ježatý" (hairy) rychlé smíšení pro θ . Z praktického hlediska je použití této konvergenční metody velice subjektivní záležitostí, a proto byly vytvořeny její nástavby k významnější verifikační interpretovatelnosti. Použitým postupem se pak stal tzv.

”hair” test navržený Brooksem[7]. Definujeme

$$d_t = \begin{cases} 1 & \text{jestliže } \hat{S}_T > \hat{S}_{T-1} \text{ a } \hat{S}_T < \hat{S}_{T+1} \\ & \text{nebo } \hat{S}_T < \hat{S}_{T-1} \text{ a } \hat{S}_T > \hat{S}_{T+1}, \\ 0 & \text{jinak.} \end{cases}$$

Pro všechna $T = n_0 + 1, \dots, n - 1$. Pak

$$D_{n,n_0} = \frac{1}{n - n_0} \sum_{T=n_0+1}^{n-1} d_T.$$

To znamená, že když v každém bodě CUSUM grafu bude lokální minimum či maximum, pak bude CUSUM graf tzv. ”hairy”. Neboli D_{n,n_0} bude nabývat hodnot mezi 0 a 1, kde hodnoty blízké 0 budou indikovat ”vyhlazený” graf, zatímco blízké 1 maximální ”hairiness”. Pak v konvergenci bude toto číslo centrováno někde kolem hodnoty $\frac{1}{2}$. Také můžeme vykreslit hranice, kde by mělo D_{n,n_0} ležet, přesněji pro velké n bude podle zákona velkých čísel bude mít přibližně normální rozdělení. Pak $100(1 - \alpha/2)\%$ konfidenční interval pro D_{n,n_0} je vyjádřen jako:

$$\frac{1}{2} \pm z_{\frac{\alpha}{2}} \sqrt{\frac{1}{4(n - n_0 - 1)}}$$

Tento výraz snadno vypočteme. Z hlediska interpretace se může jednat o objektivnější kritérium než předchozí subjektivně posuzovaný CUSUM graf.

2.1.5 Metoda Raftery a Lewis

Metoda Rafteryho a Lewise [2] je speciální metodou, která narozdíl od ostatních, nejenom diagnostikuje nedostatečnou konvergenci, ale také nám dává informaci o optimálním počtu simulací a počtu ”burn in” vzorků, neboli počtu vyhozených počátečních iterací.

Zabývá se specifickým problémem, výpočtem partikulárních kvantilů posteriorní distribuční funkce U parametrů θ . Formulovali následující postup. Předpokládáme, že chceme odhadnout $P[U \leq u|y]$ v mezích $\pm r$ s pravděpodobností s , kde U je funkce parametrů θ . Vstupními parametry tedy jsou:

- požadovaný odhadovaný kvantil q (např. .024)
- požadovaná přesnost τ (např. $\pm .005$)
- žádoucí pravděpodobnost s získání specifické přesnosti

- tolerance konvergence δ (obvykle .001)

Najdeme pak aproximativní počet potřebných iterací odpovídající zadaným podmínkám, jestliže správná hodnota bude q . Například, jestliže $q = 0.025$, $r = 0.005$ a $s = 0.95$, pak to koresponduje s 0.025 kvantilem celkové distribuční funkce v mezích ± 0.005 s pravděpodobností 0.95. Z MCMC výstupu vyhodíme počátečních M iterací a z ostatních N iterací uložíme každou k -tou. Z toho vyplývá, že úkolem je determinace M , N a k .

Nejdříve spočítáme U_t v každé t -iteraci a zavedeme proměnnou

$$Z_t = \begin{cases} 1, & \text{pro } U \leq u, \\ 0, & \text{jinak.} \end{cases}$$

$\{Z_t\}$ je binární proces 0 – 1 odvozený z Markovského řetězce, ale sám jím není. Definujeme zde proto nový proces $\{Z_l^{(k)}\}$, kde $Z_l^{(k)} = Z_{(l+(l-1)k)}$ skládající se z každé k -té iterace, bude přibližně Markovský řetězec pro dostatečně velké k . Pro každé k pak porovnáme první část s druhou částí řetězce a vybereme nejmenší k , které bude preferováno tou první. Spočteme tzv. "likelihood ratio test" statistiku G^2 s následným použitím Bayesova informačního kritéria.

K odvození M "burn-in" iterací, které budou zahozeny, použijeme dvoustavový Markovský řetězec. Nechť

$$P = \begin{pmatrix} 1 - \alpha & \alpha \\ \beta & 1 - \beta \end{pmatrix}$$

je matice přechodu pro $\{Z_l^{(k)}\}$, kde α je pravděpodobnost přechodu z prvního stavu do druhého a β pravděpodobnost opačného přechodu. Rovnovážné rozložení je potom $\pi = (\pi^0, \pi^1) = (\alpha + \beta)^{-1}(\beta, \alpha)$, kde $p_0 = P[U \leq u | \text{data}]$ a $\pi_1 = 1 - \pi_0$, pak l -tý krok matice přechodu je

$$P^l = \begin{pmatrix} \pi_0 & \pi_1 \\ \pi_0 & \pi_1 \end{pmatrix} + \frac{\lambda^l}{\alpha + \beta} \begin{pmatrix} \alpha & -\alpha \\ -\beta & \beta \end{pmatrix}$$

kde $\lambda = (1 - \alpha - \beta)$. Předpokládáme, že $P[Z_m^{(k)} = i | Z_0^{(k)} = j]$ na ε je π_i pro $i, j = 0, 1$. Jestliže $e_0 = (0, 1)$ a $e_1 = (1, 0)$, pak $P[Z_m^{(k)} = i | Z_0^{(k)} = j] = e_0 P^m e_1$ a podmínkou se stane

$$\lambda^m \leq \frac{(\alpha, \beta)\varepsilon}{\max(\alpha, \beta)},$$

která bude platit, když

$$m = m^* = \frac{\log \left\{ \frac{(\alpha, \beta)\varepsilon}{\max(\alpha, \beta)} \right\}}{\log \lambda}.$$

S předpokladem, že $\lambda > 0$, nakonec obdržíme

$$M = m^* k.$$

Pro vyjádření N , poznamenejme, že odhad $P[U \leq u | \text{data}]$ je $\bar{Z}_n^{(k)} = \frac{1}{n} \sum_{t=1}^n Z_t^{(k)}$. Pro velké n , má $\bar{Z}_n^{(k)}$ přibližně normální rozložení se střední hodnotou q a rozptylem

$$\frac{1}{n} \frac{(1 - \alpha - \beta)\alpha\beta}{(\alpha + \beta)^3}.$$

Proto požadavek, že $P[q - r \leq \bar{Z}_n^{(k)} \leq q + r] = s$, bude splněn pro

$$n = n^* = \frac{(1 - \alpha - \beta)\alpha\beta}{(\alpha + \beta)^3} \left\{ \frac{\Phi^{-1}\left(\frac{1}{2}(s + 1)\right)}{r} \right\}^2,$$

kde $\Phi^{-1}(\cdot)$ je distribuční funkce standardizovaného normálního rozdělení. Tímto získáme

$$N = n^* k.$$

Tato metoda si vyžaduje počáteční simulaci MCMC algoritmu k odhadnutí pilotního vzorku hodnot parametrů. Jako návod doporučují použít tzv. minimální $N_{\min}$ s nezávislými $\{Z^t\}$ a $\alpha = 1 - \beta = \pi^1 = 1 - q$, pro případ $M = 0$, $k = 0$ a

$$N = N_{\min} = \Phi^{-1}\left(\frac{1}{2}(s + 1)\right)^2 q(1 - q)/r^2.$$

Uživatel musí na začátku specifikovat čtyři proměnné, jmenovitě q , r , s a ε . Přibližně minimální počet iterací koresponduje $N \propto r^{-2}$. Pro volbu $q = 0.025$, $r = 0.005$ a $s = 0.95$ obdržíme $N_{\min} = 600$.

2.1.6 Gewekova konvergenční diagnostika

Geweke v roce 1991 [4] navrhl, jak postupovat k analýze konvergence Gibbsova vzorkovače. Přistupuje ke konvergenci přes spektrální hustotu. Prvně byl vyvinut pro zjištění konvergence pro Gibbsův vzorkovač a následně rozšířen pro všechny MCMC algoritmy. Jeho záměrem je odhadnout střední hodnotu funkce g parametrů θ , které byly simulovány.

Jestliže $g(\theta^j)$ je spočteno po každé iteraci Gibbsova vzorkovače, může být výsledná sekvence těchto funkcí považována za časovou řadu. Gewekova metoda je založena na předpokladu, že povaha MCMC procesu a g funkce implikuje existenci spektrální hustoty $S_g(\omega)$ pro tuto časovou řadu. Při splnění předpokladů, odhad střední hodnoty $E[g(\theta)]$ vyjádřen jako

$$\bar{g}_n = \frac{\sum_{i=1}^n g(\theta^i)}{n},$$

a asymptotický rozptyl je roven $S_g(0)/n$. $S(0)$ je spektrální hustota časové řady $g(\theta)$ vyhodnocená ve frekvenci 0. Právě druhá odmocnina tohoto rozptylu může být použita k odhadu numerické standardní chyby. Gewekův přístup je založen na rozdělení vzorků na dvě sady n_a a n_b , kdy $n_a + n_b < n$ a následném odhadu středních hodnot $\bar{g}(\theta)_n^a$ a $\bar{g}(\theta)_n^b$. Pak definujeme střední kvadratickou chybu neboli NSE jako $\frac{\bar{\sigma}_a}{\sqrt{n_a}}$ a $\frac{\bar{\sigma}_b}{\sqrt{n_b}}$. Následně za použití centrální limitní věty vyjádříme tuto konvergenční diagnostiku jako

$$CD \longrightarrow N(0, 1).$$

Konvergenční diagnostika je dána výrazem

$$CD = \frac{\bar{g}(\theta)_n^a - \bar{g}(\theta)_n^b}{\frac{\bar{\sigma}_a}{\sqrt{n_a}} - \frac{\bar{\sigma}_b}{\sqrt{n_b}}},$$

V praktických situacích se doporučuje rozdělit vzorek na $n_a = 0.1n$ a $n_b = 0.5n$. CD diagnostiku porovnáváme s kritickými hodnotami standardizovaného normálního rozdělení. Vysoké hodnoty CD ukazují na to, že $\bar{g}(\theta)_n^a$ a $\bar{g}(\theta)_n^b$ jsou od sebe vzdálené a je potřeba více replikací. Pokud naopak tato diagnostika nasvědčuje tomu, že jsme převedli dostatečný počet replikací, lze konečnou střední hodnotu funkce vypočítat na základě celého vzorku výběrů.

2.2 Specifické metody

2.2.1 Robertsova L^2 konvergenční metoda

Tato diagnostika používá statistiku poměrů hustot k nalezení L^2 konvergence rozdělení Markovova řetězce jako celku. Využívá několik nezávislých Markovských řetězců s konečnou Hilbert-Schmidt normou. Tato metoda je však omezena na speciální estimátor, a to reversibilní Gibbsův vzorovač viz Roberts(1994)¹. Provedeme m replikací řetězce s počátečním nastavením $x_i^0, i = 1, \dots, m$ a následným vygenerováním $\{x_i^t : t = 0, 1, 2, \dots\}$, následně definujeme naši skalární kontrolní proměnnou jako

$$x_{ij}^t = \frac{K(x_i^0, x_j^{2t-1})}{\pi(x_j^{2t-1})},$$

¹Roberts, G. O. (1994), Methods for Estimating L 2 Convergence of Markov Chain Monte Carlo.

kde K je tranzitivní hustota pro řetězec s rovnovážnou distribucí π . Roberts pak doporučuje následující postup:

Definujeme

$$D_t = \frac{1}{m} \sum_{i=1}^m x_{ij}^t \quad \text{a} \quad I_t = \frac{1}{m(m-1)} \sum_{i \neq j} x_{ij}^t,$$

kde D_t značí závislý člen měřící závislost aktuální hodnoty řetězce na počátečním nastavení. I_t je označován jako interakční člen. Roberts navrhol sledovat řetězec do vyrovnaní hodnot D_t a I_t . U této konvergenční statistiky nastává stejný problém jako u metody Liu, uváděnou v dalším textu v 2.2.5. Variance x_{ij}^t může dosahovat neúnosných hodnot. Návrhem řešení této komplikace je také logaritmická transformace veličiny x_{ij}^t .

2.2.2 Johnsonova diagnostika

Původně byla navržena pro Gibbsův vzorkovač, ale následně byla propracována na obecnější metodu Metropolis-Hastings generátor. Necht $U = \{u_{(j)}^t : j = 1, \dots, k, t = 1, 2, \dots\}$ je vektor nezávislých standardizovaných normálně rozdělených náhodných veličin a $x^t = \{x_{(j)}^t : j = 1, \dots, k\}$ vyjadřuje t -tou sekvenci výběrů z Gibbsova vzorkovače. Nakonec definujeme $F(\cdot|\cdot)$ jako podmíněnou distribuční funkci spojenou s π . Pak Gibbsův vzorkovač může být vytvořen pomocí následujícího postupu.

Krok 1. Vybereme m počátečních vektorů x_i^0 , $i = 1, \dots, m$ ze silně rozptýlených oblastí výběrů a nastavíme $t = 1$.

Krok 2. Pro $j = 1, \dots, k, i = 1, \dots, m$ a spojenou proměnnou $x_{(j)}^t$, nastavíme

$$x_{i(j)}^t = F^{-1}(u_{(j)}^t | x_{i(1)}^t, \dots, x_{i(j-1)}^t, x_{i(j+1)}^{t-1}, \dots, x_{i(k)}^{t-1}),$$

kde $x_{i(j)}^t$ je j -tá složka vektoru x_i^t , stav řetězce i v t -iteraci.

Krok 3. Jestliže $|x_i^t - x_i^t| \leq \epsilon \forall i \neq l, i, l \subseteq \{1, \dots, m\}$ a pro $\epsilon > 0$ pak řetězec zkonvergoval po t -iteraci. V opačném případě se vracíme ke kroku 2. a přiřadíme $t = t + 1$.

2.2.3 Metoda Rittera a Tannera

Jako mezi prvními se pokusili zjistit konvergenci ke sdruženému rozdělení, a to pomocí tzv. "importace vah", které počítali z Gibbsova vzorkovače. Tato

metoda je založená na "importance sampling" (viz. Koop[1]). Jestliže $K(\cdot, \cdot)$ značí Gibbsovu přechodovou hustotu, můžeme hustotu x^t definovat pomocí $p^t(x)$, kde

$$p^t(x) = \int_E K(y, x) p^{t-1}(dy), \quad p^1(x) = \int_E K(y, x) \pi_0(dy),$$

a π_0 označuje počáteční rozdělení řetězce. Vyjádříme-li $\tilde{\pi}$ jako ne-normalizované stacionární rozdělení, pak v konvergenci by měli být "importance váhy"

$$w^t(x) = \frac{\tilde{\pi}^t}{p}(x)$$

zhruba konstantou. Samozřejmě, že $p^t(x)$ je těžké explicitně dosáhnout, ale můžeme zde použít nestrannou Monte Carlo aproximaci z Rao-Blackwellised estimátoru a to

$$\hat{p}^t(x) = \frac{1}{m} \sum_{j=1}^m K(x_j^{t-1}, x),$$

kde $\{X_j^{t-1} : j = 1, \dots, m\}$ je výběr s p^{t-1} . Ritter a Tanner(1992)² doporučují vybírat přímo z p^{t-1} , neboli vzít m pozorování v $(t-1)$ -iteraci z m paralelních řetězců. Tento postup je výpočetně náročný, a proto byla vytvořena alternativa, kdy se redukuje náročnost jenom na m posledních replikací, kdy v konvergenci budou výběry z π . Následně navrhuje porovnání vah v každé iteraci a vykreslení do histogramu z různých replikací. Konvergenci pak bude symbolizovat tzv. "hrotové rozdělení" (spike distribution).

2.2.4 Meoda Zellnera a Mina

Zellner a Min³ se snažili zjistit, zda Gibbsův vzorkovač nekonverguje jenom k "nějakému" rozdělení, ale jestli konverguje k tomu tzv. "správnému". Zellner a Min navrhli dvě konvergenční kritéria Gibbsova vzorkovače založená na podmíněné pravděpodobnosti. Obě jsou použitelná, jestliže model může být rozdělen na dvě části (buď vektor nebo skalár) α a β a s použitím jejich marginálních pravděpodobností $\hat{p}(\alpha)$ a $\hat{p}(\beta)$ odhadnutých pomocí tzv. "Rao-Blackwellization" na Gibbsově vzorkovači viz. Gelfand and Smith⁴. Podmín-

²Ritter, C. and Tanner, M.A. (1992) "Facilitating the Gibbs Sampler: The Gibbs Stopper and the Griddy Gibbs sampler." Journal of the American Statistical Association, 87, 861-868.

³Zellner, A. and Min, C-k. (1995) "Gibbs Sampler Convergence Criteria (GSC^2).". To appear in Journal of the American Statistical Association.

⁴A.E. and Smith, A.F.M. (1990), "Sampling Based Approaches to Calculating Marginal Densities." Journal of the American Statistical Association, 85, 398-409.

kami se staly analytická vyjádření posteriorní hustoty pravděpodobnosti a možnost jejího odvození. Pro partikulární hodnoty parametrů α_1 a β_1 , může být konvergenční kritérium spočteno pomocí

$$\hat{p}(\alpha_1)p(\beta_1|\alpha_1) - \hat{p}(\beta_1)p(\alpha_1|\beta_1) = \hat{\eta}.$$

Konvergenční kritérium pro gibbsův vzorkovač” je vyjádřeno pomocí následujících výrazů, kde používá vždy dvě hodnoty parametrů, (α_1, β_1) a (α_2, β_2) :

$$\begin{aligned}\hat{\theta}_A &= \frac{\hat{p}(\alpha_1)p(\beta_1|\alpha_1)}{\hat{p}(\alpha_2)p(\beta_2|\alpha_2)} \\ \hat{\theta}_B &= \frac{\hat{p}(\beta_1)p(\alpha_1|\beta_1)}{\hat{p}(\beta_2)p(\alpha_2|\beta_2)} \\ \theta &= \frac{\pi(\alpha_1, \beta_1|I_0)f(\alpha_1, \beta_1|\mathbf{y})}{\pi(\alpha_2, \beta_2|I_0)f(\alpha_2, \beta_2|\mathbf{y})}\end{aligned}$$

Kde π je apriorní hustota a f je její věrohodnostní funkce. Jestliže Gibbsův vzorkovač zkonvergoval, pak $\hat{\eta} = 0$ a $\hat{\theta}_A \approx \hat{\theta}_B \approx \theta$.

Tyto konvergenční diagnostiky jsou založeny na analýze odchylek (nikoliv rozptylů). Mohou být dobře kvantitativně vyjádřeny a požadují jenom jediný řetězec.

2.2.5 Liuova, Liuova a Rubinova L^2 konvergenční statistika

Definovali tzv. ”skalární globální proměnnou” založenou na iteracích z vícenásobné replikace Markovského řetězce. Tato procedura pak redukuje konvergenci Gibbsova vzorkovače na jednodimenzionální náhodnou veličinu, která dává informaci o celkové konvergenci Markovského řetězce k cílovému rozdělení. Je také komplexnější než metody používající subkomponenty vygenerovaného řetězce. Liu navrhl výpočet ”kontrolní proměnné” podle následujícího postupu. V t -té iteraci vytvoříme množinu $m(m-1)$ hodnot U použitím dvou nezávislých paralelních Markovských řetězců, i a j , pomocí

$$U_{ij}^t = \frac{\pi(x_j^t)K(x_j^{t-1}, x_i^t)}{\pi(x_i^t)K(x_j^{t-1}, x_j^t)} \quad i \neq j, \quad i, j = 1, \dots, m.$$

Potom,

$$U^t = \frac{1}{m(m-1)} \sum_{i \neq j} U_{ij}^t$$

je nestranný odhad L^2 vzdálenosti mezi $p^t(\cdot)$ a $\pi(\cdot)$.

Autoři navrhuji dva způsoby k užití "globálních kontrolních proměnných". Jedním je rozdělit paralelní řetězce na $m/2$ nezávislých dvojic (dvojice nesdílejí společný řetězec) a sestrojit $\{U^t\}$ s následnou aplikací metody Gelmana and Rubina sekce 2.1.1 v každé iteraci pro každý pár. Tím dalším je vykreslení kumulativního rozdělení funkce U -hodnot až do $t = n+1, \dots, 2n$ a použít Smirnovova-statistiku popsanou v sekci Heidelberg a Welch 2.1.3.

Podstatným problémem této metody je rozptyl "kontrolní proměnné", který může být neúnosně vysoký, ne-li nekonečný. Jedním řešením je logaritmická transformace "globální kontrolní proměnné" a následná aplikace Gelmanovy a Rubinovy metody. Tento způsob je však méně věrohodný než původní postup.

2.2.6 Yuova L^1 diagnostika

Yu⁵ v roce 1995 navrhl metodu založenou na monitorování plné hustoty jedné replikace řetězce. Jestliže $\{x^t : t = 0, 1, 2, \dots\}$ je výstup p -dimensionálního Markovského řetězce se stacionární hustotou $\pi(x) = c\tilde{\pi}(x)$, kde $\tilde{\pi}$ je známo a c je neznámá normalizační konstanta pro π , pak Yu navrhl následující proceduru. Nejdříve je důležité si definovat jádrový odhad i širí pásma (b_n) tak, že

$$\tilde{\pi}_n(x) = \frac{1}{n} \sum_{t=1}^n h_{b_n}(x - x^t) \quad , \quad \text{kde} \quad h_{\sigma} = \frac{1}{\sigma^p} K\left(\frac{|x|}{\sigma}\right)$$

$K(\cdot)$ je jednorozměrné ohraničené symetrické jádro, určené jako $\int_{\mathbb{R}^p} K(|x|)dx = 1$, a $|\cdot|$ značí euklidovskou normu v $\mathbb{R}^p$. Pak můžeme stanovit odhad normalizační konstanty

$$\hat{c}_{\sigma} = \frac{1}{n(n-1)} \sum_{t=1}^n \sum_{\tau \neq t} \frac{h_{\sigma}(x^t - x^{\tau})}{\tilde{\pi}(x^{\tau})},$$

nakonec vybereme nějakou podmnožinu A na π a přírůstek hodnoty t_0 . Začneme v čase $t = t_0$, odhadneme optimální širí pásma b_t pro jádrovou hustotu, způsobem popsáným Silvermanem⁶ založené na datech, $x^0, \dots, x^t$.

⁵Yu, B. (1995), Estimating L 1 Error of Kernel Estimator: Monitoring Convergence of Markov Samplers. Technical report, Dept. of Statistics, University of California, Berkeley

⁶W.B. Silverman, Density estimation for statistic and data analysis, London, 1986

Po obdržení hodnoty b_t , odhadneme L^1 vzdálenost přes množinu A mezi odhadem jádrové hustoty $\tilde{\pi}$ a π pomocí

$$\hat{D}_t(A) = \int_A |\tilde{\pi}_t(x) - \hat{c}_{b_t} \tilde{\pi}_t(x)| dx.$$

Tento proces pak opakujeme pro $t = t_0, 2t_0, 3t_0, \dots$, dokud se graf $\hat{D}_t(A)$ neusadí v kritické hodnotě, za kterou YU doporučuje použít hodnotu 0.3. Jako ostatní metody založené na jádrové hustotě i tato metoda je výpočetně náročná. Výstup je těžce vysvětlitelný a doporučuje se vykreslovat několik sekvencí $\hat{D}_t(A)$ nezávislých řetězců dohromady. Také je velice zásadní výběr množiny A , jelikož může falešně diagnostikovat konvergenci. To nastane jestliže se množina A nebude nalézat v π .

Kapitola 3

Aplikace konvergenčních metod

V této části bychom rádi otestovali konvergenční diagnostiky aplikací na umělý model. K testování jsme využili diagnostiky prezentované v2.1. Tento výběr byl učiněn záměrně s důrazem na jejich všeobecnou použitelnost pro jakýkoliv posteriorní simulátor. Programovým prostředím byl Matlab. Ne všechny diagnostiky však jsou pro Matlab dostupné a rovněž ne u všech dostupných diagnostik jsme si byli jisti jejich korektním naprogramováním. Z toho důvodu jsme plně převzali jen diagnostiku Rafteryho a Lewise 2.1.5, která byla k dispozici v rámci volně dostupného ekonometrického toolboxu[18]. Ostatní diagnostiky jsme si naprogramovali sami. Případné další podrobnosti k jejich zpracování uvádíme v následujícím textu.

Pro testování použijeme uměle vytvořený model, kdy výběry pro neznámé parametry budou pocházet z posteriorní hustoty odpovídající vícerozměrnému normálnímu rozdělení, přesněji pocházejí z trojrozměrného normálního rozdělení s vysokou korelační závislostí mezi jednotlivými náhodnými veličinami. Konkrétněji

$$\begin{bmatrix} Y1 \\ Y2 \\ Y3 \end{bmatrix} \sim N \left(\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1.0 & 4.5 & 9.0 \\ 4.5 & 25.0 & 49.0 \\ 9.0 & 49.0 & 100.0 \end{bmatrix} \right)$$

Vzájemná korelace mezi veličinami je pak určena jako

$$\text{cor}(Y1, Y2) = 0.9 \quad \text{cor}(Y1, Y3) = 0.9 \quad \text{cor}(Y2, Y3) = 0.98$$

Volba silné autokorelace by měla znamenat vyšší nároky na velikost simulace, jinými slovy se dala očekávat potřeba více vygenerovaných vzorků pro úspěšnou konvergence. U vysoké korelační závislosti mezi parametry dochází

k určitým problémům u posteriorního simulátoru, kdy při nízkém počtu simulací neprojde celým parametrickým prostorem, a pak výsledná sekvence výběrů je nedostatečná vzhledem ke konvergenci ke stacionárnímu rozdělení. Jako posteriorní simulátor jsme si zvolili Gibbsův vzorkovač, kdy je potřeba odvodit si podmíněné hustoty pravděpodobnosti. Ty snadno získáme z definice a vlastností vícerozměrného rozdělení (viz. například Koop[1]).

Předpokládejme k -vektor $Y \sim N(\mu, \Sigma)$ je rozdělen jako

$$Y = \begin{pmatrix} Y_{(1)} \\ Y_{(2)} \end{pmatrix},$$

kde $Y_{(i)}$ je k_i -vektor pro $i = 1, 2$ a $k_1 + k_2 = k$, ve stejném duchu rozdělíme μ a Σ jako

$$\mu = \begin{pmatrix} \mu_{(1)} \\ \mu_{(2)} \end{pmatrix}$$

a

$$\Sigma = \begin{pmatrix} \Sigma_{(11)} & \Sigma_{(12)} \\ \Sigma'_{(12)} & \Sigma_{(22)} \end{pmatrix}$$

Pak platí následující podmínky:

- Marginální rozdělení $Y_{(i)}$ je $N(\mu_{(i)}, \Sigma_{(ii)})$ pro $i = 1, 2$.
- Podmíněné rozdělení $Y_{(1)}|Y_{(2)} = y_2$ je $N(\mu_{(1|2)}, \Sigma_{(1|2)})$, kde

$$\mu_{(1|2)} = \mu_{(1)} + \Sigma_{(12)}\Sigma_{(22)}^{-1}(y_2 - \mu_{(2)})$$

a

$$\Sigma_{(1|2)} = \Sigma_{(11)} - \Sigma_{(12)}\Sigma_{(22)}^{-1}\Sigma'_{(12)}$$

Podmíněné rozdělení $Y_{(2)}|Y_{(1)} = y_1$ bude formulováno jako předchozí vyjádření v opačném značení. Pomocí těchto podmíněných hustot dokáže Gibbsův vzorkovač vygenerovat vzorky ze sdružené hustoty pravděpodobnosti z vícerozměrného normálního rozdělení. Budeme testovat konvergenční diagnostiky ve třech případech.

1. Nízký počet simulací, 1000 vzorků, kdy tento výběr bude pravděpodobně nedostatečný
2. 100,000 simulací, kdy první polovinu vyhodíme jako "burn-in" periody a zbylé vzorky použijeme jako vygenerovaný řetězec pro aplikaci konvergenčních metod
3. Pro srovnání vygenerujeme vzorky bez vzájemné autokorelace, neboli kovarianční matice bude jednotková. Počet iterací bude stejný jako v prvním případě, tedy 1000 iterací.

V následujících tabulkách jsou uvedeny základní charakteristiky získané pomocí Monte Carlo integrace v podobě středních hodnot a rozptylů jednotlivých parametrů pro tyto tři případy. U našeho umělého modelu máme tu výhodu, že víme, z jaké sdružené posteriorní hustoty mají výběry pocházet, a proto můžeme ze základních charakteristik získaných z vygenerovaných vzorků usuzovat, jestli jsou tyto výběry z Gibbsova vzorkovače adekvátní vůči tomuto trojrozměrnému normálnímu rozdělení a do jaké míry analyzované diagnostiky správně indikovaly konvergenci

Tabulka 3.0.1: Vybrané charakteristiky pro 1.případ

1. Případ - 1000 iterací				
Skutečná	Střední hodnota	Kovarianční matice		
Y1	0.0000	1.0000	4.5000	9.0000
Y2	0.0000	4.5000	25.0000	49.0000
Y3	0.0000	9.0000	49.0000	100.0000
Vygenerovaná	Střední hodnota	Kovarianční matice		
Y1	-0.1657	0.8859	3.8518	7.5981
Y2	-0.7987	3.8518	21.2677	41.1813
Y3	-1.5851	7.5981	41.1813	83.7567

Z výsledků u 1000 iterací můžeme říci, že výběr, který má pocházet z nulových středních hodnot, je výrazně vzdálen od očekávaných výsledků, například u Y3 je -1.5851. Proto i bez použití diagnostik usuzujeme, že počet simulací je nedostatečný, a že výběr nám nekonvergoval do cílového rozdělení.

Tabulka 3.0.2: Vybrané charakteristiky pro 2.případ

2. Případ - 100,000 iterací - 50,000 „burn in“				
Skutečná	Střední hodnota	Kovarianční matice		
Y1	0.0000	1.0000	4.5000	9.0000
Y2	0.0000	4.5000	25.0000	49.0000
Y3	0.0000	9.0000	49.0000	100.0000
Vygenerovaná	Střední hodnota	Kovarianční matice		
Y1	0.0436	0.9941	4.5555	9.1125
Y2	0.2381	4.5555	25.3063	49.6123
Y3	0.4714	9.1125	49.6123	101.2109

U 100,000 iterací, kdy první polovinu vyhodíme, vidíme že uváděné charakteristiky z generovaných řetězců Gibbsova vzorkovače se výrazně přiblížili k posteriornímu rozdělení než v předešlém případě.

Tabulka 3.0.3: Vybrané charakteristiky pro 3.případ

3. případ - 1000 iterací bez autokorelace				
Skutečná	Střední hodnota	Kovarianční matice		
Y1	0.0000	1.0000	0.0000	0.0000
Y2	0.0000	0.0000	1.0000	0.0000
Y3	0.0000	0.0000	0.0000	1.0000
Vygenerovaná	Střední hodnota	Kovarianční matice		
Y1	0.0430	0.9879	-0.0228	0.0107
Y2	0.0087	0.0030	0.9900	-0.0524
Y3	0.0190	0.0107	-0.0524	0.9311

Porovnání s prvním případem vidíme, že bez autokorelace mezi parametry našeho umělého modelu, lze považovat výběr za dostatečný i při nízkém počtu replikací řetězce a očekáváme, že tato hypotéza bude potvrzena našimi diagnostikami.

3.1 Použití vybraných metod

Nyní můžeme přistoupit k použití analyzovaných diagnostických prostředků. Otestujeme je pro tři případy vzorků vygenerovaných z Gibbsova vzorkovače. Na tomto základě se pokusíme vyvodit závěry o kvalitě diagnostiky konvergence.

3.1.1 Raftery a Lewis

Jako první jsme použili Raftery a Lewis metodu. Jak autoři uvádí v [2], i my jsme použili základní nastavení parametrů $q = 0.025$, $r = 0.005$ a $s = 0.95$. Tento výběr pak vyjadřuje 0.025 kvantil celkové distribuční funkce v mezích ± 0.005 s pravděpodobností 0.95. Výstupy z této metody jsou v podobě M , N , k a $N_{\min}$ ve stejném smyslu, jak se uvedlo v teoretickém odvození.

Tabulka 3.1.1: Výstup Raftery a Lewis 1. případ

1. 1000 iterací se silnou autokorelací				
	M – burn in	N	k	Nmin
Y1	6	6405	1	3764
Y2	29	31694	2	3764
Y3	21	22360	1	3764

Tabulka 3.1.2: Výstup Raftery a Lewis 2. případ

2. 100,000 iterací- 50,000 vyhodíme				
	M – burn in	N	k	Nmin
Y1	59	59772	12	3764
Y2	68	73980	12	3764
Y3	76	78960	12	3764

Tabulka 3.1.3: Výstup Raftery a Lewis 3. případ

3. 1000 iterací bez vzájemné autokorelace				
	M – burn in	N	k	Nmin
Y1	2	3867	1	3764
Y2	2	3562	1	3764
Y3	2	3867	1	3764

V prvním případě je zřejmé (viz. tabulka 3.4), že počet iterací je nedostačující. Při specifikaci hodnot $q = 0.025$, $r = 0.005$ a $s = 0.95$ obdržíme doporučený počet iterací pro třetí parametr ve velikosti 22360. U druhého i třetího případu je jasné, že zvolený počet je postačující. U 50,000 iterací doporučuje ukládat každý k -tý vzorek, v tomto případě každý 12 pro všechny parametry. Tato velikost je asi důsledkem velkého rozsahu počtu iterací. U této metody je asi největší slabinou stanovení počátečních parametrů q , r a s , jelikož při různém nastavení můžeme dostat velmi rozdílné výsledky. Také opakování metody na stejném řetězci nevede ke shodnému řešení.


3.1.2 CUSUM graf

Nenáročnou metodou na zpracování a použití se stala Yuův a Myklandův CUSUM graf. Jejím výstupem je grafické zobrazení. Pro každý parametr n je v grafu vykreslená veličina $\hat{S}_T$ na T pro $T = n_o + 1, \dots, n$ spočtená ze vzorků s Gibbsova generátoru a také "benchmark". CUSUM trajektorie pro tento "benchmark" odpovídá nezávislé a stejnoměrně rozdělené náhodné proměnné z normálního rozdělení se střední hodnotou a rozptylem odpovídajícím výběrové střední hodnotě a rozptylu z vygenerovaného MCMC vzorku. Neboli


$$\mathbf{id} \sim N(E(g(\theta)), \text{var}(g(\theta))),$$


kde $E(g(\theta))$ a $\text{var}(g(\theta))$ značí střední hodnotu a rozptyl výstupu(řetězce) z Gibbsova vzorkovače pro jednotlivé parametry. V následujících grafech uvádíme CUSUM plot jenom pro veličinu Y2. Pro ostatní veličiny jsou grafy podobné.

Graf 3.1.4: 1. CUSUM graf



Graf 3.1.5: 2. CUSUM graf



Graf 3.1.6: 3. CUSUM graf

Jak jsme již uvedli interpretovatelnost těchto grafů je subjektivní záležitost, i přesto však lze u těchto výsledků diagnostikovat nedostatečnou konvergenci v prvním případě při 1000 iterací. Tento graf je výrazně vyhlazený a také velmi vzdálen od "benchmarku", než je tomu ve třetím případě. V tomto ohledu je poslední graf velmi "ježatý", co nám indikuje již proběhnuté smíchání řetězců i úspěšnou konvergenci. Aplikovali jsme také nastavení této metody v podobě "hair" testu, která by nám tyto výsledky měla potvrdit číselně. Tabulka 3.1.7 ukazuje získané výsledky, kdy v konvergenci by měly být hodnoty D_n centrovány okolo čísla $1/2$.

Tabulka 3.1.7: Výstup "Hair" testu—

Hair test D_n	1. 1000 iterací	2. 50,000 iterací	3. 1000 iterací bez korelace
Y1	0.2125	0.5092	0.1965
Y2	0.1036	0.4936	0.0905
Y3	0.0958	0.510	0.0907

Z těchto výsledků můžeme vyvodit, že splnění konvergence použitím "Hair" testu splnil jenom případ 2., neboli bez přítomnosti autokorelace s nízkým počtem simulací. U případu 2. kdy ostatní diagnostiky ukazují proběhlou konvergenci, se musíme spokojit asi jenom s grafickou podobou CUSUM viz obrázek 3.2, na které je patrná výraznější ježatost, ale zase ve velkém měřítku 50,000 iterací, což zkresluje jeho interpretovatelnost. Proto usuzujeme, že věrohodnost CUSUM grafu bude snížena u velkého počtu simulací.

3.1.3 Heidelberg a Welch

Po naprogramování Heidelberg a Welch procedury, jsme ji aplikovali na každý řetězec. Neprováděli jsme metodu popsanou v teoretické části 2.3, ale provedli jsme oba dva testy na celém vygenerovaném řetězci. Pro odhad spektrální hustoty ve frekvenci 0 jsme použili funkci `psd.m` ze signal processing tool-boxu jako u Gewekeho diagnostiky. Pro test stacionarity jsme vybrali Cramer von Mises statistiku. Pak s porovnáním s 0.95 kvantilem této statistiky, neboli jeli hodnota menší než 0.4651, považujeme tento test za úspěšný. Po splnění testu stationarity, nastupuje test "poloviční šířky intervalu" ("half width interval"). Zde musíme vypočítat asymptotickou standardní chybu, vyjádřenou jako podíl spektrální hustoty ve frekvenci 0 s počtem iterací. Jinými slovy řečeno "half width" (poloviční šíře) intervalu bude spojována s 95% procentním intervalem pro střední hodnotu ($1.96 \times$ asymptotická standardní chyba). Požadavek na relativní šíři intervalu, ϵ je zvolen přiměřeně v hodnotě 0.1. Tato velikost je použita z odkazem na[3]. Výsledky Heidelberg a Welch metody vidíme v následujících tabulkách pro všechny tři proměnné (řetězce).

Tabulka 3.1.8: Výstup Heidelbergova a Welchova testu pro 1. případ

1. Heidelberg- Welch metoda – 1000 iterací			
	Test stacionarity	Cramer von Mises statistika	Kritická hodnota
Y1	passed	0.0853	0.4610
Y2	passed	0.0932	0.4610
Y3	passed	0.0936	0.4610
	Half width test	Mean	Halfwidth
Y1	failed	-0.1657	0.1156
Y2	failed	-0.7987	0.6127
Y3	failed	-1.5851	1.2102

Tabulka 3.1.9: Výstup Heidelbergova a Welchova testu pro 2. případ

2. Heidelberg- Welch metoda – 1000 iterací			
	Test stacionarity	Cramer von Mises statistika	Kritická hodnota
Y1	passed	0.0033	0.4610
Y2	passed	0.0044	0.4610
Y3	passed	0.0046	0.4610
	Half width test	Mean	Halfwidth
Y1	failed	0.0436	0.0180
Y2	failed	0.2381	0.0970
Y3	failed	0.4714	0.1941


Tabulka 3.1.10: Výstup Heidelbergova a Welchova testu pro 3. případ

3. Heidelberg- Welch metoda – 1000 iterací bez autokorelace			
	Test stacionarity	Cramer von Misses statistika	Kritická hodnota
Y1	passed	0.0110	0.4610
Y2	passed	0.1875	0.4610
Y3	passed	0.1058	0.4610
	Half width test	Mean	Halfwidth
Y1	failed	0.0430	0.0279
Y2	failed	0.0087	0.0242
Y3	failed	0.0190	0.0183


Z výsledků je patrné, že každý řetězec prošel testem stacionarity. Z toho můžeme usuzovat, že i v prvním případě se řetězec ustálí na určitém stacionárním procesu, ale asi nám nezkonvergoval do cílového rozdělení, přesněji nejistota spojená se střední hodnotou tohoto rozdělení je stále vysoká. Překvapením je zamítnutí testu half width interval ve třetím případě pro všechny tři parametry, kdy ostatní diagnostiky považují tento výběr za dostatečný, to naznačuje jednak velkou přesnost testu, na druhé straně vzhledem k odhadům spektrální hustoty není vzorek 1000 iterací reprezentativním.

3.1.4 Gelman a Rubin


Tato metoda je založena na aplikaci více řetězců s různými počátečními hodnotami, neboli tzv. "overdispersed starting values". Vygenerovali jsme si deset takových paralelních řetězců. U našeho umělého modelu jsme měli tu výhodu, že jsme nemuseli hledat módy a aproximovat vícerozměrným normálním rozdělením. Víme, že vzorky z něho pocházejí. Generováním náhodných čísel z vícerozměrného normálního rozdělení se známou střední hodnotou a kovarianční maticí podělené náhodným výběrem rozdělení χ^2 s počtem stupňů volnosti $\eta = 2$, jsme obdrželi rozptýlené počáteční hodnoty. Po obdržení těchto hodnot nám nezbývá nic jiného, než pro každý parametr našeho modelu spočítat "potential reduction factor". Uvedeme grafický výstup pro veličinu Y_2 této metody v následujících grafech. Pro ostatní veličiny jsou uvedeny přílohách. V levých grafech je vykreslen jeho průběh pro každou iteraci a vidíme jeho přibližování se k hodnotě 1, která značí úspěšnou konvergenci, s růstem počtu simulací. Vpravo zobrazujeme průběh ustálení a následné sblížování veličin W a V (čitatel a jmenovatel ve výrazu pro R).

Graf 3.1.11: Gelman a Rubin PSRF 1.případ

U grafu 3.1.11 je zřejmé, že R se přibližuje k hodnotě jedna velmi ztěžka a sblížování matic W a V vůbec nenastane ani v 1000 iterací u prvního případu.

Graf 3.1.12: Gelman a Rubin PSRF 2.případ

Z grafu 3.1.12 je patrné, že R dosáhne hodnoty 1.001 přibližně v 40,000 vzorcích, kdy toto číslo považujeme za velice blízké jedné a tím pádem značí úspěšnou proběhlou konvergenci. Velice těžké je něco usuzovat o sblížování matic W a V , jelikož na ose x máme jednotky po desetitisících vzorků a pravý graf v obrázku 3.5 je pak nepoužitelný.

Graf 3.1.13: Gelman a Rubin PSRF 3.případ

Samozřejmě úplně jiná situace je u třetího případu graf 3.1.13, kdy oba dva zobrazené grafy jsou čitelné a mohou být interpretovány jako úspěšná konvergence. Jelikož přibližně od 500 iterací dosahují R hodnot téměř rovné jedné a matice W a V vykazují stejné hodnoty od tohoto počtu iterací. Konečné hodnoty PSRF uvedeme v následující podkapitole v tabulkách obsahující i hodnoty z jiných variant výpočtu PSRF.


3.1.5 Brooks a Gelman

Korekcí předchozí diagnostiky je metoda Brooks a Gelman viz 2.2. Potential scale reduction factor PSRF je zde nahrazen následovně:


- Intervalový PSRF - $\hat{R}_{intreval}$
- PSRF pro vyšší moment, v našem případě pro 3. moment - $\hat{R}_3$
- Vícerozměrné PSRF - MPSRF

Pro všechny tři případy platí, že úspěšnou konvergenci představuje PSRF blízke jedné. Na grafech uvedeme grafické výstupy této metody.


Graf 3.1.14: Brooks a Gelman Intervalový PSRF 1.případ









Graf 3.1.15: Brooks a Gelman Intervalový PSRF 2.případ



Graf 3.1.16: Brooks a Gelman Intervalový PSRF 3.případ



Graf 3.1.17: Brooks a Gelman momentový PSRF 1.případ**Graf 3.1.18:** Brooks a Gelman momentový PSRF 2.případ**Graf 3.1.19:** Brooks a Gelman momentový PSRF 3.případ

Graf 3.1.20: Brooks a Gelman vícerozměrný PSRF 1.případ**Graf 3.1.21:** Brooks a Gelman vícerozměrný PSRF 2.případ**Graf 3.1.22:** Brooks a Gelman vícerozměrný PSRF 3.případ

Všechny grafy uvedené v obrázcích 3.1.14-3.1.22 se moc neliší od grafického výstupu předešlé metody Gelman a Rubin, ze které všechny vycházejí a nějakým způsobem ji modifikují. Grafy jsou téměř totožné, a proto není až tak podstatné, kterou metodu pro výpočet PSRF použijeme. Záleží tedy na uživateli, kterou metodu výpočtu PSRF si zvolí a použije ji jako diagnostický

prostředek. Vzhledem k výše zmíněné podobnosti grafů 3.1.14-3.1.22, jsme se rozhodli tentokrát vynechat jejich popis. Proto tento účel stejně dobře poslouží komentář v podkapitole Gelman a Rubin 3.1.4.

Tabulka 3.1.23: Kvantitativní vyjádření PSRF

PSRF pro 1. případ				
	PSRF	Interval PSRF	Moment. PSRF	Víceroz. PSRF
Y1	1.0128	1.0257	1.0229	1.0320
Y2	1.0159	1.0320	1.0291	1.0320
Y3	1.0153	1.0309	1.0278	1.0320

PSRF pro 2. případ				
	PSRF	Interval PSRF	Moment. PSRF	Víceroz. PSRF
Y1	1.0001	1.0003	1.0004	1.0003
Y2	1.0002	1.0003	1.0005	1.0003
Y3	1.0002	1.0003	1.0005	1.0003

PSRF pro 3. případ				
	PSRF	Interval PSRF	Moment. PSRF	Víceroz. PSRF
Y1	0.9999	0.9999	1.0010	1.0002
Y2	0.9999	0.9998	0.9997	1.0002
Y3	0.9998	0.9996	0.9999	1.0002

V tabulkách 3.1.23 uvádíme kvantitativní vyjádření PSRF pro naše tři případy. V literatuře je doporučená kritická hodnota ve výši 1.1, neboli hodnoty PSRF mešší než toto číslo je ukazatel proběhlé konvergence. Všechny hodnoty v našem vygenerovaném modelu PSRF jsou menší 1.1 (dokonce menší než 1.05), a proto by se dalo usuzovat, že všechny vzorky zkonvergovaly do cílového rozdělení. Ale toto tvrzení je nesprávné, jelikož jak víme, v prvním případě jsou hodnoty výrazně vzdáleny od očekávaných. A proto usuzujeme že PSRF může předčasně diagnostikovat proběhlou konvergenci, při silné autokorelaci ovlivňující Gibbsův zorkovač. Disfunkce této diagnostiky je způsobena záměnou konvergence do cílového rozdělení se vzniklým stacionárním procesem, který se díky silné autokorelaci ustaluje velmi pozvolna do cílového rozdělení.

3.1.6 Gewekeova CD diagnostika

U Gewekeho procedury je jednoduchý kvantitativní výstup v podobě CD diagnostiky, kdy za potvrzení konvergence považujeme hodnoty $|CD| < 2$, neboli spadající do 95% intervalu spolehlivosti pro standardní normální rozdělení $N(0, 1)$. Uvádíme zde dva způsoby výpočtu NSE. První je podle spektrální

hustoty odhadnuté ve frekvenci 0 - NSE(psd) funkcí signal processing toolboxu a druhou variantou je použití funkce `momentg` z LeSage Toolboxu(Econometrics)[20]

Tabulka 3.1.24: Gewekovo CD pro 1. případ

GEWEKE metoda pro 1000 iterací				
	NSE	NSE(psd)	Geweke CD	Geweke CD (psd)
Y1	0.0313	0.0775	2.0384	2.1349
Y2	0.1570	0.4196	2.2751	2.1603
Y3	0.3162	0.8452	2.3191	2.1993

Tabulka 3.1.25: Gewekovo CD pro 2. případ

GEWEKE metoda pro 100,000 iterací – 50,000 „burn in“				
	NSE	NSE(psd)	Geweke CD	Geweke CD (psd)
Y1	0.0045	0.0089	-0.4014	-1.2790
Y2	0.0223	0.0480	-0.3436	-1.0946
Y3	0.0446	0.0959	-0.3659	-1.1689

Tabulka 3.1.26: Gewekovo CD pro 3. případ

GEWEKE metoda pro 1000 iterací bez autokorelace				
	NSE	NSE(psd)	Geweke CD	Geweke CD (psd)
Y1	0.0323	0.0109	-0.3410	-0.9598
Y2	0.0315	0.0119	-0.4211	-1.1762
Y3	0.0309	0.0136	0.0799	0.2558

Vidíme, že odhady NSE, pořízené dvěma způsoby, se od sebe hodnotově liší, ale signalizují alespoň stejný výsledek zamítnutí konvergence v jednotlivých případech. V prvním případě je zřejmé zamítnutí hypotézy o úspěšné konvergenci a ve druhém a třetím jde o její potvrzení oběma způsoby výpočtu NSE, protože CD v absolutní hodnotě je menší než 2. Jedinou nevýhodou této metody je odhad spektrální hustoty ve frekvenci 0, jelikož neexistuje jediná varianta odhadu a tím se snižuje její kvalitativní vyhodnocení, protože obdržíme různé výsledky při použití jiných postupů výpočtu.

3.2 Zhodnocení

Nyní můžeme zhodnotit námi vybrané a aplikované konvergenční metody. Obecně můžeme říci, že větší počet simulací má za následek lepší konvergenční vlastnosti vygenerovaného řetězce. U vybraných metod v některých případech docházelo k ne zrovna úspěšné diagnostice proběhlé konvergence.

Tento fakt byl způsobem výběrem našeho umělého modelu se silnou autokorelací, kdy některé diagnostiky tuto vlastnost nedokázali zachytit. Například kvantitativní vyjádření všech možných druhů výpočtu PSRF uváděli hodnoty výrazně menší než 1.1 pro všechny tři případy. Kdy velikost menší než 1.1 je považována za proběhlou konvergenci. Jak už jsme uvedli, tento důvod může být v záměně k diagnostice stacionárního procesu s konvergencí výběru do cílového rozdělení. Můžeme tedy usuzovat, že se tato vlastnost týká právě metody Gelmana a Rubina a její modifikace v podobě dalších způsobů výpočtu PSRF. Opravdu subjektivně posuzovanou metodou je CUSUM graf. Kdy při nízkém počtu iterací dokážeme rozhodnout o výpovědní hodnotě CUSUM grafu viz. první a druhý případ, zatímco při velkém počtu simulací v řádu desítitisících, je tento graf zkreslený, a proto také méně věrohodný. Toto tvrzení nám také potvrdil "Hair test". U Gewekovy a Heidelbergovy a Welchovy metody je jediným negativem výpočet spektrální hustoty. Protože při aproximativním odhadu spektrální hustoty na našem vzorku pomocí dvou funkcí v Matlabu dostáváme odlišné výsledky a nedokážeme rozhodnout o větší kvalitě jednoho či druhého odhadu. U výstupu z Rafteryho a Lewise zase záleží na nastavení předem definovaných parametrů, které nám pak produkují odlišné výsledky.

Na závěr můžeme říci, že ani jedna z metod se nedá považovat za dostačující verifikaci konvergence MCMC řetězce, a proto pro uživatele těchto prostředků doporučujeme vždy aplikovat určitou kombinaci představených diagnostik.

Kapitola 4

Aplikace konvergenčních diagnostik v kontextu DSGE modelu

V této části budeme aplikovat konvergenční diagnostiky na výstupy identifikace reálného ekonomického modelu. Níže analyzovaný model byl odhadován bayesovskými postupy pomocí programového nástroje Dynare[19]. Tento nástroj obsahuje jen diagnostiky Brookse a Gelmana. Je tak účelné implementovat naše v Matlabu zpracované diagnostiky na výstupy získané v Dynaru[19]. Modelovým konceptem je v našem případě model reálného hospodářského cyklu (RBC). Budeme vyházet hlavně z Karagedikli [11].

4.1 RBC a DSGE model

Od 70. let dochází ke změnám makroekonomického modelování. Jednou z příčin je bezesporu rozvoj informačních technologií, který umožnil odhady a simulace komplikovaných lineárních i nelineárních modelů. V dnešní době k nejvíce využívaným nástrojům makroekonomické analýzy patří DSGE modely, neboli strukturální dynamické stochastické modely všeobecné rovnováhy. RBC je možné zakomponovat do DSGE konceptu a můžeme charakterizovat jako Ramseyho neoklasický růstový model se stochastickými technologickými šoky viz. [10]. Tento model zavádí šoky jako příčiny hospodářských cyklů v interakci s produkční funkcí a preferencemi jednotlivých agentů.

Dokonale konkurenční ekonomika obsahuje tyto agenty:

- Domácnosti, které maximalizují svou užitkovou funkci při dané počáteční zásobě kapitálu. Domácnost participuje na trhu zboží, kapitálu a práce.

- Reprezentativní firmu, která prodává výstup, prezentuje produkční funkce obsahující kapitál, práci a technologický pokrok.

Produkční funkce je Cobb Douglasova produkční funkce s konstantními výnosy z rozsahu.

$$Y_t = (A_t N_t)^\alpha K_t^{1-\alpha}, \quad (4.1)$$

Y_t je výstup v čase t , A_t je technologický pokrok, N_t je počet odpracovaných hodin, K_t je zásoba kapitálu a $0 < \alpha < 1$. Akumulace kapitálu probíhá na základě vztahu:

$$K_{t+1} = (1 - \delta)K_t + Y_t - C_t, \quad (4.2)$$

kde δ je míra znehodnocení kapitálu a C_t je spotřeba v čase t .

Užitková funkce domácností je mocninná ve volném čase a logaritmická ve spotřebě:

$$\sum_{i=0}^{\infty} \beta^i [\log(C_{t+i}) + \theta \frac{(1 - N_{t+i})^{1-\gamma}}{1 - \gamma}], \quad (4.3)$$

kde $\sigma = 1/\gamma$ je elasticita mezičasové substituce volného času a β je diskontní faktor.

Definujeme úrokovou míru návratnosti (výnosu) investovaného kapitálu, R_{t+1} , která se rovná součtu mezního produktu kapitálu a nedepreciovaného kapitálu, tedy

$$R_{t+1} = (1 - \alpha) \left(\frac{A_{t+1} N_{t+1}}{K_{t+1}} \right)^\alpha + (1 - \delta). \quad (4.4)$$

Cílem je maximalizovat očekávaný užitek reprezentativní domácnosti s omezením 4.1 a 4.2.

Podmínkami prvního řádu maximalizačního problému jsou:

$$C_t^{-1} = \beta E_t[C_{t+1}^{-1} R_{t+1}] \quad (4.5)$$

a

$$\theta(1 - N_t)^{-\gamma} = \frac{W_t}{C_t} = \alpha \frac{A_t^\alpha}{C_t} \left(\frac{K_t}{N_t} \right)^{1-\alpha}, \quad (4.6)$$

kde mezní užitek z volného času je roven mzdě násobené mezním užitem ve spotřebě. Na dokonale konkurenčním trhu práce je mzda rovna meznímu produktu práce. Poznamenejme, že rovnice 4.5 symbolizuje mezičasový aspekt našeho problému (Eulerova rovnice) a také nabídka práce se řídí mezičasovou substitucí.

Předpokládáme, že ve steady statu, technologický pokrok, kapitál, výstup a spotřeba, rostou konstantní mírou, $G \equiv A_{t+1}A_t^{-1}$. Hrubá míra návratnosti kapitálu je také konstantní ve steady statu a značíme ji R .

Pak první podmínka 4.5 přechází na:

$$G = \beta R \quad (4.7)$$

Logaritmus pak značíme malými písmeny:

$$g = \log(\beta) + r \quad (4.8)$$

Definice návratnosti kapitálu 4.4 a podmínka prvního řádu 4.7 implikuje steady stateový poměr technologického pokroku ku kapitálu jako konstantu

$$\frac{A}{K} = \left(\frac{\frac{G}{\beta} - (1 - \delta)}{1 - \alpha} \right)^{1/\alpha} \frac{1}{N} \approx \left(\frac{r + \delta}{1 - \alpha} \right)^{1/\alpha} \frac{1}{N}, \quad (4.9)$$

s $R \approx 1 + r$. Produkční funkce a poměr technologického pokroku ke kapitálu rovněž implikuje konstantu jako poměr výstupu a kapitálu:

$$\frac{Y}{K} = \left(\frac{AN}{K} \right)^\alpha \approx \left(\frac{r + \delta}{1 - \alpha} \right) \quad (4.10)$$

Steady stateový poměr spotřeby a výstupu je:

$$\frac{C}{Y} = \frac{C/K}{Y/K} \approx 1 - \frac{(1 - \alpha)(g + \delta)}{r + \delta}. \quad (4.11)$$

Odchylka ze steady statu může být modelována jako systém nelineárních rovnic s logaritmem technologického pokroku, kapitálu, výstupu, práce a spotřeby. V naší práci použijeme standardní lineární aproximaci uváděnou v Romerovi [10]. Využijeme ji spolu s Taylorovým rozvojem prvního řádu okolo steady statu na naše rovnice 4.1, 4.2, 4.4, 4.5, 4.6. Odvození pak nalezneme v [11]. Nyní uvedeme log-linearizované rovnice, jejichž parametry budeme odhadovat na reálných datech:

$$y_t = \alpha(a_t + n_t) + (1 - \alpha)k_t, \quad (4.12)$$

$$K_{t+1} = \lambda_1 k_t + \lambda_2(a_t + n_t) + (1 - \lambda_1 - \lambda_2)c_t, \quad (4.13)$$

$$r_t + 1 = \lambda_3(a_{t+1} + n_{t+1} - k_{t+1}), \quad (4.14)$$

$$E_t \Delta c_{t+1} = \sigma \lambda_3 E_t [a_{t+1} + n_{t+1} - k_{t+1}], \quad (4.15)$$

$$n_t = \nu[(1 - \alpha)(k_t - n_t) + \alpha a_t - c_t], \quad (4.16)$$

kde

$$\lambda_1 = \frac{1+r}{1+g}, \quad \frac{\alpha(r+\delta)}{(1-\alpha)(1+g)}, \quad \lambda_3 = \frac{\alpha(r+\delta)}{r+1} \text{ a } \nu = \frac{1-N}{N}\sigma.$$

Logaritmus technologického procesu je vyjádřen jako autoregresivní proces prvního řádu:

$$a_t = \phi a_{t-1} + \epsilon_t, \quad (4.17)$$

kde ϕ je míra trvání technologického šoku, $-1 < \phi < 1$ a ϵ_t je bílý šum (s nulovou střední hodnotou a vzájemnou nekorelovaností šoků).

4.2 Bayesiánský odhad modelu

Máme definovaný jednoduchý RBC model s neznámými parametry v rovnicích 4.12-4.16, jmenovitě $(\alpha, \delta, \sigma, r, N, g)$ a parametr AR(1) procesu technologického pokroku, ϕ a rozptyl ϵ , značíme $\text{var}(\epsilon) = \sigma_\epsilon^2$. Provedeme bayesiánský odhad parametrů našeho modelu na českých datech s použitím čtvrtletních dat od roku 1996 do 2007. K tomu nám poslouží DYNARE toolbox[19]. Jedná se o nástroj pro řešení, simulaci a identifikaci DSGE modelů. Pro potřeby odhadu máme jediný vektor pozorování odchylky důchodů od své rovnovážné (potencionální) úrovně. K jejímu získání jsme využili Hodrick-Prescottův filtr na čtvrtletní data o reálném HDP, který tyto odhady provádí. Jde o soubor programů pracujících pod Matlabem. Na začátku je nezbytné specifikovat apriorní hustoty pravděpodobnosti našich parametrů. Použili jsme stejné hodnoty, které byly aplikovány v Karagedikli [11].


Tabulka 4.2.1: Bayesiánský odhad RBC modelu

	Apriorní Střední hod.	Posteriorní střední hod.	Konfidenční interval		Prior rozdělení	Posteriorní deviace
α	0.666	0.6537	0.5728	0.7361	beta	0.0500
σ	1.000	0.9737	0.5875	1.3786	gamma	0.2500
ϕ	0.900	0.9208	0.8705	0.9743	beta	0.0500
r	0.015	0.0154	0.0069	0.0231	gamma	0.0500
g	0.005	0.0050	0.0033	0.0065	gamma	0.0100
δ	0.025	0.0269	0.0095	0.0430	beta	0.0100
N	0.333	0.3377	0.2595	0.4203	beta	0.0500
ϵ	0.010	0.0038	0.0029	0.0047	invgamma	4.0000

Výsledky našich odhadů jsou zobrazeny v tabulce 4.2.1. Generovali jsme 10 paralelních bloků řetězců parametrů o velikosti 50,000 vzorků (pro výpočet posteriorních charakteristik) pomocí Metropolis-Hastings algoritmu viz 1.3, z toho 25,000 jsme odstranili z důvodu omezení vlivu počátečních podmínek. Apriorní a posteriorní hustoty jsou zobrazeny v grafu 4.2.2.

Z výsledků je patrné viz. tabulka 4.2.1, že naše posteriorní hodnoty jsou velmi podobné těm apriorním, v některých případech dokonce totožné (g). Tento fakt je dobře pozorován také na grafickém výstupu 4.2.2 apriorních a posteriorních hustot. Můžeme se proto domnívat, že data neobsahují mnoho informací o vývoji systému a posteriorní hodnoty značně reflektují naše apriorní nastavení. To je dáno i jediným pozorováním (důchod y). Přínosné na tomto odhadu se stala identifikace parametru ϕ , míry odeznění šoku v AR(1) procesu.

Graf 4.2.2: Apriorní a posteriorní hustoty (šedá=apriorní hustota, černá=posteriorní hustota, zelená=posteriorní střední hodnota)



4.3 Aplikace konvergenčních metod

Dynare[19] v sobě obsahuje pouze konvergenční diagnostiky Brookse a Gelmana[2.1.2], přičemž diagnostika pro sdruženou hustotu je prováděna určitou transformací na jednorozměrný případ a následnou aplikací jednorozměrné metody. Je tedy přínosné aplikovat námi analyzované diagnostiky. Použití

obecných diagnostických prostředků viz 2.1 provádíme na výstupy z Dynare programu. Bylo nutné tento výstup z Dynare[19] převést do žádoucí podoby, neboť řetězce jsou roztrženy v několika maticových blocích. Po přiřazení řetězců k jednotlivým parametrům, jsme obdrželi maticové bloky MCMC řetězců nezbytné k aplikaci námi zpracovaných konvergenčních metod. U diagnostik s grafickým zobrazením uvedeme jenom obrázky pro α , ϕ a g proměnné. Pro ostatní veličiny jsou uvedeny v příloze A.

U rafteryho a Lewis metody jsme použili stejné nastavení výchozích parametrů jako v předchozí kapitole. Tedy $q = 0.025$, $r = 0.005$ a $s = 0.95$. V tabulce 4.3 jsou uvedené výsledky z této metody a můžeme říci, že počet 50,000 iterací plně dostačující. Jen s výjimkou parametru ϕ .

Tabulka 4.3.1: Raftery a Lewis diagnostika

	M-burn in	N	k	Nmin
α	42	43330	7	3746
σ	28	30118	1	3746
ϕ	79	85770	9	3746
R	30	31392	4	3746
g	26	27414	1	3746
δ	24	25447	1	3746
N	27	29503	1	3746
ϵ	27	29032	1	3746

U gewekeho diagnostiky byly pro všechny parametry hodnoty diagnostiky CD výrazně menší než 2 (v absolutní hodnotě), jak vidíme v tabulce 4.3.2. Potvrdila se tedy konvergence našeho řetězce.

Tabulka 4.3.2: Geweke CD

	NSE	NSE (psd)	Geweke CD	Geweke CD (psd)
α	0.0003	0.0112	-0.2737	-0.0394
σ	0.0015	0.0169	-1.0211	-0.4168
ϕ	0.0002	0.0158	-1.6255	-1.0613
r	0.0000	0.0003	-1.6255	-1.0613
g	0.0000	0.0001	-0.4439	-0.1421
δ	0.0001	0.0005	0.4835	0.4768
N	0.0003	0.0058	0.0659	0.0153
ϵ	0.0000	0.0001	-0.0896	-0.0243

U Metody Heidelbergu a Welche jsme aplikovali postup opět na celý vygenerovaný řetězec. Výsledky zobrazené v následující tabulce 4.3.3 jsou

naprosto uspokojivé, jelikož řetězce jednotlivých parametrů splnili oba dva testy, test stacionarity a "half width test".


Tabulka 4.3.3: Heidelberg a Welch metoda

	Test Stacionarity	Testovací statistika
α	passed	0.0759
σ	passed	0.0657
ϕ	passed	0.0798
r	passed	0.0446
g	passed	0.0581
δ	passed	0.0524
N	passed	0.0662
ε	passed	0.0722
Kritická hodnota: 0.4610		Alpha = 0.05


	Halfwidth test	Střední hodnota	„Halfwidth interval“
α	passed	0.6534	0.0156
σ	passed	0.9790	0.0237
ϕ	passed	0.9204	0.0219
r	passed	0.0154	0.0004
g	passed	0.0050	0.0001
δ	passed	0.0271	0.0007
N	passed	0.3383	0.0081
ε	passed	0.0038	0.0001
Epsilon = 0.1			

U CUSUM grafů 4.3.4-4.3.6 je zřejmá "ježatost", ale jak už jsme zmínili v hodnocení této metody v předchozí kapitole, tak při interpretaci těchto grafů musíme být obezřetní, jelikož jsou vykreslovány vůči 50,000 iterací. Ale i přesto je hodnotíme za konvergenčně zdařilé.


Graf 4.3.4: CUSUM graf pro α



Graf 4.3.5: CUSUM graf pro ϕ




Graf 4.3.6: CUSUM graf pro g




Všechny metody způsobu výpočtu "potential scale reduction factor" PSRF zobrazují úspěšnou konvergenci. Ta je tady vyjádřena jako přiblížení PSRF k hodnotě 1. To si můžeme povšimnout na grafech 4.3.7-4.3.10.


Graf 4.3.7: Gelman a Rubin PSRF pro α, ϕ, g




Graf 4.3.8: Intervalový PSRF pro α, ϕ, g



Graf 4.3.9: Momentový PSRF pro α, ϕ, g



Graf 4.3.10: Vícerozměrný PSRF pro α, ϕ, g



Na závěr této kapitoly můžeme říci, že řetězce pro všechny odhadnuté parametry o velikosti 50,000 vzorků nám zkonvergovaly do cílového rozdělení. Tuto velikost replikací tedy považujeme za dostatečnou. Ani jedna z aplikovaných diagnostik nám toto tvrzení nevyvrátila, neboli všechny diagnostikovaly úspěšnou konvergenci do cílového rozdělení.

Samotný proces generování vzorků zabral na počítači s procesorem Celeron M, taktovaný frekvencí 2.0GHz, asi 4hodiny času. Vyšší počet replikací by znamenal adekvátní nárůst času, a to se jedná o relativně jednoduchý DSGE model. Z tohoto hlediska je tedy užitečné se ujistit při dané velikosti replikací o jejich konvergenci. Je samozřejmě možné vygenerovat 5,000,000 vzorků, a být si tak docela jistí, že vzorky odpovídají cílovému rozdělení, ale výpočetní čas by byl však enormní. Pomocí Dynare[19] je dle manuálu možné pokračovat v dosavadním generování, tudíž při zjištění nekonvergence není problém vygenerovat další vzorky a znovu testovat konvergenci. Z hlediska výpočetního času se jedná o efektivní přístup

Závěr

V naší práci jsme se pokusili představit veškeré důležité aspekty diagnostiky konvergence MCMC algoritmů, tohoto moderního statistického proudu k analýze komplexnějších modelů.

Při prezentaci jednotlivých diagnostik jsme se snažili o co největší srozumitelnost a samozřejmě o jejich originalitu, a proto jsme také vycházeli z původních publikovaných článků jednotlivých autorů. Záměrně jsme si vybrali obecnější metody (viz 2.1), jelikož můžou sloužit k vyšetřování řetězců pocházejících z různých MCMC algoritmů bez jakýchkoliv omezení. Samozřejmě by byla škoda neseznámit potenciální čtenáře s modelově či algoritmicky specifickými diagnostikami (viz 2.2).

Na umělém modelu jsme si odzkoušeli jejich kvalitu verifikace konvergence. Snažili jsem se vygenerovat vzorky z takového vícerozměrného rozdělení, které by implikovalo náročnější požadavky na velikost těchto simulací. Ve třech modelově různých případech jsme zhodnotili a analyzovali výsledky z diagnostických prostředků. Pak už jsme je mohli s jistou aplikační znalostí použít na reálný ekonomický model. Provedli jsme zde odhad parametrů jednoduchého RBC modelu pomocí Dynare toolboxu. Následně jsem potvrdili kvalitu tohoto odhadů pomocí námi naprogramovaných konvergenčních nástrojů.

Jako velký přínos naší práce považujeme aplikační zvládnutí těchto metod. Důležitým prvkem se stala jejich implementace do programového prostředí Matlab, který je hojně využíván v praxi ekonomicko-matematického modelování. Žádný dodnes dostupný toolbox pro Matlab ještě neobsahoval komplexní soubor řešení diagnostických nástrojů pro jakékoliv MCMC algoritmy. Proto také uvádíme v příloze jejich algoritmické postupy v již zmíněném Matlabu. To poslouží případným uživatelům těchto prostředků. Všechny námi zpracované metody jsme implementovali na výstup nástroje ekonomického modelování Dynare, který v sobě zahrnuje pouze jednu diagnostiku. Pak pro jakékoliv odhady pořízené tímto programem se s mírnou modifikací dostává do rukou řešitele bohatý komplexní diagnostický balíček.

Přestože v České republice je naše práce ojedinělá, v zahraničí se naopak

posuzovaným metodám věnuje spousta teoretiků. Věříme, že tato diplomová práce podnítlí zájem o MCMC algoritmy a obecněji i bayesiánskou ekonometrii i v českém ekonomickém diskursu, protože považujeme dané téma za nesmírně přínosné. Doufáme, že se v brzké době stane bayesiánský přístup epicentrem zájmu většiny ekonometrů.

Literatura


- [1] Gary K., Bayesian Econometric, University of Glasgow, 2003.
- [2] Raftery A.E., Lewis S., How many iterations in the Gibbs sampler, University of Washington, 1991.
- [3] Heidelberger P., Welch D., Simulation Run Length Control in the Presence of an Initial, Vol. 31, No. 6, Simulation. (Nov. - Dec., 1983), pp. 1109-1144.
- [4] Geweke John, Evaluating the Accuracy of Sampling-Based Approaches to the Calculation of Posterior Moments, University of Minnesota Research Department, 1991.
- [5] Andrew Gelman; Rubin Donald B. Inference from Iterative Simulation Using Multiple Sequences, Statistical Science, Vol. 7, No. 4. (Nov., 1992), pp. 457-472.
- [6] Yu B., Discussion to Besag, Statistical Science 10, 1995
- [7] Brooks S.P., Quantitative Convergence Assessment for MCMC via CUSUMS
- [8] Cowles M.K., Carlin, B.P. Markov Chain Monte Carlo Convergence Diagnostics: A Comparative Review
- [9] Brooks S.P., Gelman Andrew, General Methods for Monitoring Convergence of Iterative Simulations, Journal of Computational and Graphical Statistics, Vol. 7, No. 4. (Dec., 1998), pp. 434-455.
- [10] Romer D., Advanced Macroeconomics, Third Edition, 2006.
- [11] O. Karagedikli, T. Matheson, C. Smith, S.P. Vahey, RBC's and DSGE's, The computational Approach to Business Cycle Theoriz and Evidence, November 2007, Reserve Bank of New Zealand.

-
- [12] Johnson V., Studying Convergence of Markov Chain Monte Carlo Algorithms Using Coupled Sample Paths, Duke University.
 - [13] Wolf P., Linka A., O podstatě a aplikacích MCMC metod, ÚTIA ČAV a TU Liberec, Robust 1998.
 - [14] Gelman A., Carlin J.B., Stern H.S., Rubin B., Bayesian Data Analysis, university Columbia, Chapman and Hall 2004.
 - [15] Carlin, Bradley P., Bayes and empirical bayes methods for data analysis, New York: Chapman and Hall 2000.
 - [16] Koralov L.B., Sinai Y. G., Theory of Probability and Random Processes, second edition, Springer 2007.
 - [17] Yu B., Mykland P., Looking at markov sampler trough CUSUM plots, Statistic and Computing, 1997.
 - [18] MCMC Diagnostics Toolbox for Matlab 6.x, Version 1.1 2004-01, Aki Vehtari
 - [19] Juillard, M (1996), DYNARE: A program for the resolution and simulation of dynamic models with forward variables through the use of a relaxation algorithm. CEPREMAP. Couverture Orange, 9602. www.cepremap.cnrs.fr/dynare/
 - [20] LeSage James P. , Econometrics Toolbox, www.spatial-econometrics.com.

Příloha A


Grafy pro ostatní parametry RBC modelu

Graf A.0.11: CUSUM graf pro σ




Graf A.0.12: CUSUM graf pro


δ




Graf A.0.13: CUSUM graf pro r




Graf A.0.14: CUSUM graf pro N




Graf A.0.15: CUSUM graf pro ϵ




Graf A.0.16: Gelman a Rubin PSRF δ , σ , r , N , ϵ




Graf A.0.17: Intervalový PSRF pro δ , σ , r , N , ϵ



Graf A.0.18: Momentový PSRF pro δ , σ , r , N , ϵ



Graf A.0.19: Vícerozměrný PSRF pro δ , σ , r , N , ϵ



Příloha B

Programové vybavení pro Matlab

K diplomové práci přikládáme programové vybavení pro Matlab. Zde uvedeme strukturu a krátký popis jednotlivých souborů, které byly použity v naší analýze.

Tabulka B.0.20: Popis přiložených souborů

\\Diagnostiky\\raftery.m	Metoda Rafteryho a Lewise převzatá z LeSage ekonometrického toolboxu
\\Diagnostiky\\heid.m	Diagnostika Heidelbergera a Welche
\\Diagnostiky\\brooks.m	Různé druhy výpočtu PSRF +grafický výstup – Brooks a Gelman
\\Diagnostiky\\cusum.m	Yu a Mykland CUSUM graf
\\Diagnostiky\\psrf.m	„Potential scale reduction factor“ Gelman a Rubin metoda
\\Diagnostiky\\Karagedikli_converg.m	Aplikace obecných konvergenčních metod 2.1 na řetězce vygenerované v Dynare
\\Diagnostiky\\Gibbs_converg.m	Aplikování obecných konvergenčních metod 2.1 na řetězce z Gibbsova vzorkovače (Gibbs_norm.m)
\\Diagnostiky\\Gibbs_norm.m	Generování řetězců z podmíněných hustot vícerozměrného normálního rozdělení pomocí Gibbsova vzorkovače
\\Spatial-econometrics\\	LeSage P. J., Econometrics Toolbox, www.spatialeconometrics.com
\\Dynare_toolbox_v3\\	Program využitý pro řešení a simulaci dynamických modelů, v našem případě RBC modelu. www.cepremap.cnrs.fr/dynare/
\\model\\Karagedikli_Matheson_Smith_Vahey(2007)_Czech_RBC&\\	Výstup z Dynare toolboxu – odhad modelu RBC na českých datech
\\Diagnostiky\\MH\\	Řetězce jednotlivých parametrů generované Metropolis-Hastings algoritmem v Dynare, které jsou uloženy v blokových maticích

Všechny využití soubory přikládáme na CD. V případě jakýchkoliv dotazů a nejasností ohledně použití naprogramovaných součástí se můžete obrátit na tkvaka@gmail.com.