

MASARYKOVA UNIVERZITA

EKONOMICKO-SPRÁVNÍ FAKULTA

Diplomová práce

Brno 2025

Petr Chaloupek

**M A S A R Y K O V A
U N I V E R Z I T A**

EKONOMICKO-SPRÁVNÍ FAKULTA

Determinanty a elasticita českého exportu

Diplomová práce

PETR CHALOUPEK

Vedoucí práce: doc. Ing. Libor Žídek, Ph.D.

Katedra ekonomie

Studijní program: Hospodářská politika a mezinárodní vztahy

Brno, podzim 2025

MUNI
EKONOMICKO -
- SPRÁVNÍ
FAKULTA

Bibliografický záznam

Autor: Petr Chaloupek
Ekonomicko-správní fakulta
Masarykova univerzita
Katedra ekonomie
Název práce: Determinanty a elasticita českého exportu
Studijní program: Hospodářská politika a mezinárodní vztahy
Vedoucí práce: doc. Ing. Libor Žídek, Ph.D.
Akademický rok: 2025/2026
Počet stran: 59
Klíčová slova: keyword1, keyword2, ...

Anotace

This is the abstract of my thesis, which can span multiple paragraphs.

Bibliographic record

Author:	Petr Chaloupek Faculty of Economics and Administration Masaryk University Department of Economics
Title of Thesis:	Determinants and Elasticities of Czech Exports
Degree Programme:	Economic Policy and International Relations
Supervisor:	doc. Ing. Libor Žídek, Ph.D.
Academic Year:	2025/2026
Number of Pages:	59
Keywords:	keyword1, keyword2, ...

Annotation

This is the English abstract of my thesis, which can span multiple paragraphs.

Prohlášení

Prohlašuji, že jsem diplomovou práci Determinanty a elasticita českého exportu zpracoval samostatně pod vedením Libora Žídka a uvedl v ní všechny odborné zdroje v souladu s právními předpisy, vnitřními předpisy Masarykovy univerzity a vnitřními akty řízení Masarykovy univerzity a Ekonomicko-správní fakulty MU.

Brno, 17. listopadu 2025

Podpis autora

ZADÁNÍ
DIPLOMOVÉ PRÁCE

Akademický rok: 2025/2026

Student:	Bc. Petr Chaloupek
Program:	Hospodářská politika a mezinárodní vztahy
Název práce:	Determinanty a elasticita českého exportu
Název práce anglicky:	Determinants and Elasticities of Czech Exports
Cíl práce, postup a použité metody:	Cílem diplomové práce je identifikovat a kvantifikovat hlavní makroekonomické determinanty českého exportu v období 2000–2023 a odhadnout jejich elasticitu. Práce usiluje o zachycení krátkodobých a dlouhodobých vazeb. Obsah: - Úvod - 1. Literární rešerše - 2. Použitá data a metody - 3. Empirická analýza - Závěr
Rozsah grafických prací:	Podle pokynů vedoucího práce
Rozsah práce bez příloh:	60 – 80 stran
Literatura:	ALTAYLIGIL, Yalcin a Ahmet CETREZ. Macroeconomic, institutional and financial determinants of current account balances: a panel data assessment. <i>Empirica: Journal of European Economics</i>, 2020, 47(4), 801–845. ISSN 0340-8744. GHIRONI, Fabio, Seung Ki KIM, Marc J. MELITZ a Hyunseung MOON. International Trade and Macroeconomic Dynamics with Sanctions. NBER Working Paper Series, č. 30296, 2022. BOUBACAR, Inoussy. Spatial determinants of U.S. FDI and exports in OECD countries. <i>Economic Systems</i>, 2016, 40(1), 133–144. ISSN 0939-3625. SADIKU, Luljeta, Merale SADIQUE a Sanel IBRAIMI. The Persistence and Determinants of Current Account Deficit of FYROM: An Empirical Analysis. <i>Procedia Economics and Finance</i>, 2015, 33, 93–103. ISSN 2212-5671.
Vedoucí práce:	doc. Ing. Libor Žídek, Ph.D.
Pracoviště vedoucího práce:	Katedra ekonomie

Datum zadání práce: 7. 7. 2025

Termín odevzdání diplomové práce a vložení do IS je uveden v platném harmonogramu akademického roku.

V Brně dne: 7. 7. 2025

Poděkování

Na tomto místě bych rád poděkoval svému vedoucímu Liboru Žídkovi za vedení této práce a jeho rady. Dále bych také rád poděkoval své rodině a přátelům, kteří mi byli oporou nejen při tvorbě této práce, ale i po čas celého studia. V neposlední řadě bych rád poděkoval Jakubovi Chalmovianskému za jeho cenné rady ohledně ekonometrické stránky této práce.

Obsah

Seznam tabulek	15
Seznam obrázků	17
Úvod	19
1 Literární řešerše	21
1.1 Determinanty zahraničního obchodu	21
1.2 Modelování zahraničního obchodu	23
1.3 Zahraniční obchod a Česká republika	25
2 Použitá data a metody	27
2.1 Představení modelu	27
2.2 Teoretická východiska volby modelu	32
2.3 Proměnné v modelu	33
2.4 Odhad cyklických složek proměnných	37
2.5 Bayesiánská analýza	39
3 Empirická analýza	45
Závěr	47
Bibliografie	49
A R skript a dataset	57
B Test stacionarity	59

Seznam tabulek

1	Váhy reálného HDP 6 největších exportních partnerů	35
2	Proměnné použité v modelu	37
3	Popisné statistiky cyklických složek proměnných	39
4	ADF test cyklických složek proměnných	59

Seznam obrázků

1	Originální časové řady proměnných	34
2	Odchyly proměnných od ustáleného stavu	40

Úvod

Text

Literární rešerše

V první kapitole se zaměřuji na literární rešerši v oblasti determinantů vývozu. Export je velmi významnou složkou HDP v malých otevřených ekonomikách, kdy často hodnota exportu převyšuje hodnotu celého HDP. Malé otevřené ekonomiky mají často „aktivní“ platební bilanci (tím rozumíme, že běžný účet platební bilance je v přebytku), tedy exporty jsou větší, než importy. V této kapitole si tak nejprve pokusíme identifikovat tyto determinanty (1.1), poté se zaměříme na modelování zahraničního obchodu (1.2) a v neposlední řadě se zaměříme na specifika České republiky (1.3).

1.1 Determinanty zahraničního obchodu

V této podkapitole představím základní literární rešerši stran výzkumů determinantů zahraničního obchodu, resp. vývozu. Determinanty exportu jsou hojně diskutovány jak v empirické, tak teoretické rovině. Můžeme říci, že se jedná o jednu ze zásadních problematik v oblasti zkoumání malých otevřených ekonomik. Přístup literatury je dlouhodobě konzistentní v tom, že bilaterální obchodní toky silně souvisejí s ekonomickou velikostí partnerů a charakteru obchodu (vzdálenost, hranice apod.) byť konkrétní kanály se v čase a napříč studii liší v síle a robustnosti (srov. Anderson et al., 2003; Bergstrand, 1985; Eaton et al., 2002 či Head et al., 2014).

Nejrobustnějším determinantem exportu je **zahraniční poptávka** – tedy poptávka¹ partnerů, kam daná ekonomika vyváží. Řada studií ukazuje, že nárůst příjmů či HDP v zahraničí vede k růstu exportu domácí země (Redding et al., 2002). Z metodologického hlediska je tak export často funkcí nejen domácí nabídky, ale i struktury zahraniční poptávky (např. importní kvóty partnera, preference pro daný produkt). Logika tohoto determinantu je jasná, pokud rostou příjmy v destinacích exportu, otevírají se exportní příležitosti pro dodavatele. Tento efekt bývá obzvláště silný v případech, kdy domácí země má komparativní výhodu v doplňování rostoucí poptávky. Prati (2014) dokumentuje elasticitu exportu vůči zahraničním příjmům. Bottega (2021) udává, že ve studiích zabývajících se dlouhodobými efekty jsou technologický pokrok a zahraniční poptávka hlavními determinanty exportní výkonnosti země.

1. Rozumějme agregátní poptávka.

Dalším, v literatuře hojně zastoupeným determinantem je **směnný kurz**, efekt této proměnné je však nejednoznačný (viz Taglioni, 2012). Z literatury o *pass-through* směnného kurzu na ceny importu/exportu vyplývá, že změny nominálního kurzu se přenášejí do cen (a tím i do konkurenceschopnosti) méně, než jedna ku jedné (Choudhri, 2015).²

Směnný kurz můžeme rozlišit na nominální a reálný, kdy reálný kurz chápeme jako nominální směnný kurz a poměr cenových hladin, tedy

$$R = \frac{E * P^*}{P},$$

kde reálný směnný kurz (R) je roven nominálnímu směnnému kurzu (E) a poměru zahraniční cenové hladiny (P^*) a domácí cenové hladiny (P). Reálný směnný kurz tak v sobě nese dvě informace, odráží nominální směnný kurz a rozdíl cenových hladin doma a v zahraničí. Obecně je reálný směnný kurz považován za lepší měřítko konkurenceschopnosti. De Broeck (2012) uvádí, že reálný kurz odráží krátkodobé odchylky od dlouhodobého růstu produktivity. Nominální směnný kurz ovlivňuje export následovně: pokud domácí měna depreciuje domácí produkty se stávají v zahraničí relativněji levnější a proto by poptávka po exportech měla růst. Depreciace měny se však může negativně propasat na importní ceny, což může celý efekt snižovat či dokonce negovat (Fromlet, 2013). Efekt kurzu je tak značně heterogenní, závisí na struktuře výroby, nákupech vstupů i tržních strategií firem.

Dále můžeme zmínit jednotkové **náklady práce**, ty jsou často používány jako měřítko cenové konkurenceschopnosti a měřítko produktivity práce, resp. reálné ceny práce. Literatura ukazuje, že rozdíly v nákladech práce mohou být příčinou poklesu exportních podílů v dané zemi (Fagerberg, 1988). De Broeck (2012) ukazuje, že relativní náklady práce mají statistickou vazbu s růstem exportu, ale výklad je opatrný. V konvergujících ekonomikách je tento vztah velice komplikovaný. Decramer et al. (2014) ukazují, že vyšší jednotkové náklady práce znamenají pokles exportní výkonnosti, avšak efekt není, tak velký jak bychom čekali. Novější práce (Herrero, 2022) analyzuje nominální náklady práce a importní ceny u exportních sektorů ve středozemních ekonomikách a dochází k závěru, že efekt nominálních nákladů práce je nízký, ale efekt importních cen hraje vyšší roli.

Importní ceny vstupů se v literatuře objevují jako klíčová složka v cenové konkurenceschopnosti exportů. Herrero (2022) uvádí, že importní ceny mají větší vliv na exportní ceny, než samotné jednotkové náklady práce. Mimo to literatura o efektech směnného kurzu (např. Campa et al., 2002) ukazuje, že změnu kurzu se přenášejí částečně skrze importní ceny vstupů – vyšší dovozní ceny vstupů relativně znevýhodňují exportéra. V realitě však záleží na povaze exportu a na tom, kolik z exportovaného zboží tvoří reexporty, které mohou být výrazně ovlivněny importními cenami a kolik zboží a služby, které originálně pochází z exportující země. Na importní ceny lze také nahlížet jako na reálnou veličinu (reálné importní ceny), kdy odfiltrujeme vliv nominálního kurzu a celkového růstu cen.

2. K této problematice v České republice nyní také přispěl svým příspěvkem ekonom Šestořád (2023), který uvádí, že efekt depreciace koruny se do cenové hladiny ČR propisuje jen velmi málo.

Empirická literatura zdůrazňuje, že ne země, ale firmy obchodují, exportují typicky produktivnější a větší firmy schopné nést fixní náklady vstupu na zahraniční trh. Export je tak citlivý na změny fixních a variabilních nákladů. Pro malé otevřené ekonomiky je tak zvláště relevantní napojení do globálních hodnotových řetězců a role dodavatelsko-odběratelských vazeb (srov. Helpman et al., 2008 či Lodefalk, 2014)

Můžeme jmenovat další významné determinanty zahraničního obchodu jakými jsou **tarifní a netarifní překážky, infrastruktura** a další.

Výše uvedené determinanty se snaží být na sobě nezávislé, ale vzájemně se překrývají a interagují spolu. Například silnější zahraniční poptávka může umožnit exportérům snížit ceny a tím zmírnit negativní dopad relativně vysokých jednotkových nákladů práce. Z metodologického hlediska literatura doporučuje: dobře měřit reálný směnný kurz, oddělit cenové a necenové faktory a často pracovat na „mikro“ úrovni, kvůli heterogenitě firem (Bolatto et al., 2019).

1.2 Modelování zahraničního obchodu

Za první „model“ zahraničního obchodu můžeme považovat princip absolutních výhod popsanych v díle Adama Smith (1776). V tomto „modelu“ je zahraniční obchod považován za motor ekonomického rozvoje. Tento přístup položil základy liberálního pojetí obchodu, který byl empiricky testován v moderních studiích (srov. Jones, 1961). Tento přístup byl nadále rozvíjen a testován.

Ve 20. století přišel Heckscher-Ohlin model, který integruje faktory produkce jako práce a kapitál do analýzy obchodu. Podle tohoto modelu země exportují zboží intenzivní na faktory, kterými disponují v nadbytku, což vede k vyrovnání faktorů cen³ a distribučním efektům obchodu.

Průlom v modelování zahraničního obchodu přišel v 60. letech, kdy byl představen tzv. gravity model, který modeluje obchodní toky jako funkci HDP, vzdálenosti obchodních partnerů a faktory rezistence (např. cla, netarifní překážky, kulturní rozdíly apod.). Jeho základní podoba je následující:

$$F_{ij} = G \frac{M_i M_j}{D_{ij}}, \quad (1.1)$$

kde G je konstanta, F_{ij} je obchodní tok, D_{ij} představuje vzdálenost mezi zemí i a j a M představuje ekonomickou dimenzi obou zemí. Model (1.1) je odvozen z Newtonova zákona gravitace. Gravity model se stal standardem pro analýzu zahraničních integrací (Baier et al., 2007).

V 90. letech se začali prosazovat dynamické stochastické modely všeobecné rovnováhy (dále jen DSGE) pro analýzu obchodních toků v kontextu makroekonomických cyklů.

3. Stolper-Sauleson teorém

Ghironi et al. (2005) integrují heterogenitu firem⁴ do DSGE modelu, vysvětlují cyklické fluktuace obchodu a elasticitu exportu na měnové šoky. Rivera-Batiz et al. (2020) shrnují, že DSGE modely zlepšují predikce elasticity měnové a fiskální politiky. Sen (2010) zdůrazňuje posun k endogennímu růstu obchodu, kde export stimuluje inovace a produktivitu.

Ekonometrické metody používané k odhadu exportních modelů prošly výraznou transformací. Jak tvrdí Santos Silva et al. (2006), zatímco dřívější studie stavěly především na metodě nejmenších čtverců (OLS), v posledních dekadách se využívají robustnější estimátory, zejména metoda maximální věrohodnosti (MLE).

Literatura posledních let je silně ovlivněna geopolitickými otřesy a technologickou transformací. Pandemie COVID-19, obchodní válka mezi USA a Čínou a válka na Ukrajině zobrazuje křehkost globálních řetězců (Antràs et al., 2021). Současně dochází k růstu významu digitálních obchodů a e-commerce. United Nations (2025) uvádí, že digitální služby tvoří více než 60 % celosvětového exportu služeb, což vyžaduje nové metodologické přístupy.⁵

V posledních dekadách se také hojně využívají pro modelování vektorové autoregresní modely (dále jen „VAR“) jako základní empirický nástroj pro makroekonomickou analýzu. Sims (1980) či Christiano (2012) odmítají identifikaci velkých strukturálních modelů a prosazují *data-driven* přístup, který umí lépe zachytit endogenitu proměnných. Současná praxe stojí na nejrůznějších „derivátech“ VAR modelů. Od VAR modelů s exogenním blokem, přes strukturální VAR modely, které zachycují dynamiku skrze identifikační omezení až po VAR modely s v čase proměnnými parametry a mnoho dalších (Lütkepohl, 2005).

Zahraniční obchod je samozřejmě také modelován i v České republice. Česká národní banka (ČNB) dlouhodobě využívá strukturální modely typu DSGE, které umožňují integrovat zahraniční obchod do širšího rámce makroekonomické analýzy. Ve svém jádrovém modelu DSGE g3+ ČNB explicitně zahrnuje exportní a importní funkce přičemž export je modelován jako funkce zahraniční poptávky a reálného efektivního kurzu (srov. Andriele et al., 2009; Franta et al., 2014). V g3+ modelu je exportní funkce modelována jako odvození poptávkové funkce pomocí agregátoru s CES⁶, log linearizovaná rovnice má tvar

$$\hat{x}_t = \hat{y}_t^* - \eta(\hat{p}_{x,t} - \hat{p}_t^*), \quad (1.2)$$

kde $\hat{x}_t$ značí odchylku reálného českého exportu od svého ustáleného stavu, $\hat{y}_t^*$ je odchylka reálné zahraniční poptávky od ustáleného stavu, η je elasticita substituce, a výraz $(\hat{p}_{x,t} - \hat{p}_t^*)$ označuje relativní cenu exportu, resp. opět odchylku od svého ustáleného stavu.

4. Heterogenitou firem v tomto kontextu se myslí to, že všechny firmy nejsou identické, ale liší se v produktivitě, velikosti, nákladech, rozhodování apod.

5. Z pohledu menších ekonomik je tak klíčové sledovat, jak tyto trendy ovlivňují jejich exportní specializaci a zahraniční poptávku.

6. CES = konstatní elasticita substituce

Vedle DSGE modelů ČNB také využívá VAR modely k hodnocení krátkodobých dynamik vztahů. Franta et al. (2014) ukazují, že v období po zavedení kurzového závazku⁷ se elasticita exportu vůči kurzovým změnám dočasně zvýšila, což potvrzuje, že reakce obchodních toků není stabilní v čase. Tento závěr se shoduje s mezinárodní literaturou (Koop et al., 2010).

Významnou roli v modelování zahraničního obchodu ČR hraje také Ministerstvo financí ČR, které při tvorbě predikcí používá kombinaci strukturálních modelů a ekonometrických přístupů založených na panelových datech (Ministerstvo financí ČR, 2023), ovšem i ministerstvo financí vyvíjelo vlastní DSGE model s názvem *HUBERT*. Studie Havrlant (2011) či Semerák (2021) potvrzují, že hlavními determinanty českého exportu jsou mimo jiné růst zahraniční poptávky, reálný směnný kurz a náklady práce.

Novější trendy v českém kontextu reflektují zapojení do globálních hodnotových řetězců (Timmer et al., 2016). Český export je z velké části tvořen meziprodukty, které vstupují do německého průmyslu. To znamená, že u predikce exportu nelze spoléhat pouze na zahraniční poptávku po konečném zboží, ale je nutné zohlednit šoky v dodavatelských řetězcích. Pandemie COVID-19 ukázala, že tyto šoky mohou mít výrazně větší dopady, než klasické cenové či měnové faktory (Česká národní banka, 2021).

Do budoucna lze očekávat, že modelování zahraničního obchodu v ČR bude stále více integrovat nové determinanty: digitalizaci, environmentální regulace (např. CBAM⁸) a strukturální změny v automobilovém průmyslu.

1.3 Zahraniční obchod a Česká republika

Česká republika je typickým příkladem malé otevřené ekonomiky s vysokým podílem exportu ku HDP a silnou sektorovou specializací (dopravní prostředky, strojírenství) a hlubokým napojením na německé výrobní řetězce. Pro postsocialistické ekonomiky se ukázalo, že slabé instituce byly významnou bariérou obchodu. Zlepšování kvality regulace, tarifních a netarifních překážek v konvergenčním období hrálo významnou roli v růstu českého vývozu (Janda et al., 2012).

Zahraniční poptávka patří k nejvíce konzistentně identifikovaným determinantům exportu i v případě České republiky. Havrlant (2011) uvádí, že zahraniční poptávka (vyjádřená cyklem ekonomiky zahraničních partnerů) má významný vliv na české exporty. Práce od Benáček et al. (2003) poukazuje na to, že růst agregátní poptávky v zahraničí je jedním z hlavních determinantů střednědobého horizontu vývozu ČR. Z literatury tak můžeme usoudit, že pro český export je velmi důležitý růst ekonomik obchodních partnerů.

Diskuse o kurzu a exportní výkonnosti je v českém prostředí velmi orientována na období tzv. kurzového závazku (listopad 2023 - duben 2017). Hodnocení této epizody

7. 2013 – 2017

8. *Carbon Border Adjustment Mechanism* = nástroj EU, který zavádí clo na uhlíkově náročné zboží.

(DSGE simulace i kvaziexperimentální metody) ukazuje, že oslabení koruny pomohlo zabránit deflaci a pravděpodobně podpořilo reálnou aktivitu českého exportu. Odhady ukazují mírně pozitivní dopad tohoto období na exportní výkonnost ČR i celkovou ekonomickou situaci země (srov. Brůha et al., 2017; Caselli, 2017; Skořepa et al., 2016 či Frait et al., 2021)

Jednotkové mzdové náklady představují měřítko cenové či nákladové konkurenceschopnosti. Vlach et al. (2011) upozorňují, že v období 2000-2008 jednotkové náklady práce začali konvergovat k úrovni EU, což znamenalo vyčerpání relativně levné pracovní síly jako konkurenční výhody. Wziątek-Kubiak et al. (2006) uvádí, že pokles relativní jednotkových nákladů byl významným faktorem zlepšení exportní pozice ČR, přičemž klíčový vliv měla samotná produktivita práce. Z toho vyplývá, že česká ekonomika musí brát v potaz, že snižování jednotkových nákladů práce není možné skrze zlevňování pracovní síly, ale skrze růst produktivity, technologickém zlepšování a růstu kvality produkce.

Ceny importovaných vstupů a komponent mohou velmi ovlivnit exportní výkon, a to zejména v otevřených ekonomikách s vysokým podílem importních vstupů na produkci. Békés (2013) uvádí, že rozdíly v exportních cenách jsou částečně vysvětlitelné rozdíly v importních cenách vstupů. V českém kontextu Benáček et al. (2003) identifikovali, že růst dovozních cen (či deprecie koruny) může pro exportéry znamenat vyšší náklady, pokud používají komponenty z dovozu. Pro ČR je tak zásadním faktorem růst či pokles relativních světových cen, resp. relativních cen českých dovozů.

Použitá data a metody

Cílem této kapitoly je formálně představit použitý modelový aparát a zdůvodnit jednotlivé volby tak, aby bylo zřejmé, jakým způsobem z něj následně získávám odhadované elasticity determinantů. V první části kapitoly (2.1.1) vycházím z klasického vektorového autoregresního (VAR) rámce a ukazuji základní vlastnosti tohoto typu modelů. Následně rozšiřuji základní VAR o blok exogenních proměnných a formuluji VAR-X model (2.1.2), který umožňuje explicitně pracovat s vnějšími šoky. Další část kapitoly (2.1.3) se zaměřuje na bayesovský přístup k odhadu parametrů, který řeší problém vysokého počtu parametrů vůči délce vzorku. Následně představuji použití Choleského dekompozice pro identifikaci strukturálních šoků (2.1.4). V další části kapitoly (2.4) se věnuji odhadu cyklických složek vybraných proměnných a v poslední části (2.5) představuji fungování bayesiánské analýzy a jakým způsobem probíhá odhad bayesiánských modelů.

2.1 Představení modelu

Pro odhad elasticity determinantů českého exportu jsem se rozhodl využít **rekurzivně odhadovaný BVAR-X model s Choleského identifikací** v gapové podobě, který je dle mého názoru vhodnou kombinací robustního přístupu, ale zároveň **nevyužívá až příliš složitý matematický aparát**. Následující podkapitoly 2.1.1 až 2.1.5 se postupně věnují jednotlivým aspektům a modifikacím modelu. V další části (2.3) se věnuji představení použitých proměnných, případně jejich úpravám.

2.1.1 Vektorový autoregresní model

Vektorové autoregresní (VAR) modely představují zobecněné rozšíření autoregresních modelů (AR), rozšíření se týká systému více vzájemně endogenních proměnných. Zatímco v AR modelu se daná proměnná vysvětluje vlastní zpožděnou proměnnou, tedy

$$y_t = \rho y_{t-1} + \epsilon_t,$$

kde současná hodnota (y_t) závisí na své zpožděné proměnné (y_{t-1}) a náhodné složce (ϵ_t). Ve VAR je každá proměnná vysvětlována jak vlastními, tak i zpožděnými hodno-

tami všech ostatních proměnných v systému. Tímto způsobem VAR model zachycuje vzájemnou dynamiku mezi veličinami, bez stanovení směru kauzality. Koncept VAR modelů byl formalizován např. práci dle Sims (1980).

Nechť y_t je $n \times 1$ vektor endogenních proměnných, pozorovaných v řadě $t = 1, 2, \dots, T$. Potom VAR(p) model lze zapsat jako:

$$y_t = c + A_1 y_{t-1} + \dots + A_p y_{t-p} + u_t, \quad u_t \sim N(0, \Sigma), \quad (2.1)$$

kde c je $(n \times 1)$ vektor konstant, A_i je $(n \times n)$ matice koeficientů, u_t je vektor náhodných složek s nulovou střední hodnotou a Σ je symetrická pozitivně definitní kovarianční matice⁹ reziduí u_t , platí, že $\Sigma = E(u_t u_t')$. Model tedy umožňuje, aby každá proměnná byla vysvětlována všemi ostatními proměnnými z minulosti až do zpoždění p . Pro odhad je vhodné využít maticového zápisu. Model lze definovat jako

$$Y = ZB + U,$$

kde

$$Y \equiv \begin{bmatrix} y'_{p+1} \\ \vdots \\ y'_T \end{bmatrix}, \quad Z \equiv \begin{bmatrix} 1 & y'_p & \dots & y'_1 \\ \vdots & \vdots & & \vdots \\ 1 & y'_{T-1} & \dots & y'_{T-p} \end{bmatrix}, \quad B \equiv \begin{bmatrix} c \\ A_1 \\ \vdots \\ A_p \end{bmatrix}$$

a U je matice náhodných složek. Tímto způsobem lze celý systém chápat jako vícerovnícovou regresi, kterou lze řešit pomocí OLS nebo SUR, přičemž oba přístupy poskytují shodné odhady (Lütkepohl, 2005).

Základním předpokladem použitelnosti modelu je jeho stabilita, která zaručuje, že proces y_t je stacionární¹¹ a že šoky mají konečný, postupně slábnoucí dopad. Stabilitu lze zkoumat pomocí kořenů charakteristického polynomu

$$\det(I_n - A_1 z - A_2 z^2 - \dots - A_p z^p) = 0.$$

Pokud všechny kořeny leží mimo jednotkový kruh ($|z| > 1$), je systém stabilní. V opačném případě se VAR model může chovat nestacionárně (Koop et al., 2009).

VAR modely nabízí řadu výhod, zejména se jedná o jeho flexibilitu. VAR model bere všechny proměnné jako endogenní a je na autorovi, popř. ekonomické teorii vysvětlit a dokázat kauzality. Dále nám také pohodlně ukazuje, které proměnné a jak reagují na zpoždění jiných proměnných. VAR modely se i v současné době často využívají pro účely krátkodobých predikcí a to zejména pro svoji jednoduchost a možnou „modifikovatelnost“, kdy klasický VAR model lze rozšířit např. o exogenní blok proměnných (VAR-X) či strukturální omezení (SVAR) apod. VAR model má však i své slabiny, tou nejpalčivější je počet parametrů. Pro n proměnných a p zpoždění model obsahuje $n(1 + np)$ parametrů. Například již VAR(4) model se 4 proměnnými vyžaduje odhad 68 parametrů,

9. ¹⁰

11. *Stacionarita* znamená, že daná časová řada má, konstantní rozptyl ($\text{var}(y_t) = \text{var}(y_{t-s}) = \sigma_y^2$), konstantní střední hodnotu ($E(y_t) = E(y_{t-s}) = \mu$) a konstantní kovarianci ($\text{cov}(y_t, y_{t-s}) = \text{cov}(y_{t-j}, y_{t-j-s}) = \gamma_s$).

což klase vysoké nároky na délku časové řady. VAR modely jsou také čistě empirické ekonometrické modely, nejsou založeny na žádné makroekonomické teorii (jako např. DSGE modely), záleží tedy na autorovi modelu, jak vyargumentuje jeho podobu.

2.1.2 Exogenní blok proměnných

Základní VAR model předpokládá, že všechny proměnné v systému jsou endogenní, tedy proměnné jsou na sobě závislé a ovlivňují se navzájem. V praxi se však setkáváme s řadou ekonomických jevů, které nejsou endogenní, ale exogenní. Právě rozšířením klasického VAR modelu o blok exogenních proměnných vzniká VAR-X(p, q) model. Formálně lze VAR-X model (p, q) řádu zapsat jako

$$y_t = c + A_1 y_{t-1} + A_2 y_{t-2} + \dots + A_p y_{t-p} + B_0 x_t + b_1 x_{t-1} + \dots + B_q x_{t-q} + u_t,$$

kde B_j je matice koeficientů exogenních proměnných a x_j je vektor exogenních proměnných. Rozšiřujeme tedy základní VAR model. V předchozí části (2.1.1) jsme si definovali VAR model jako

$$Y = ZB + U$$

v tomto případě rozšíříme matici Z o exogenní zpožděné proměnné a matici B o koeficienty exogenních proměnných. Výsledný systém rovnic lze opět řešit buď pomocí OLS či jiných technik.

Rozšířením o exogenní blok umožňuje VAR-X zachycovat jak vnitřní endogenní dynamiku systému, tak působení vnějších šoků. Přítomnost x_t a jeho zpoždění umožňuje oddělit efekty, které jsou „importovány“ z vnějšího prostředí, od těch, které vznikají v rámci samotného systému y_t (Lütkepohl, 2005).

Hlavní výhodou VAR-X modelu je již zmiňovaná možnost analyzování dopadů exogenních proměnných na náš model, aniž by bylo nutné modelovat celou ekonomiku (nebo celou světovou ekonomiku) endogenně, což je pro nás užitečné. Exogenní blok zvyšuje empirickou realističnost modelu, zahrnuje relevantní vnitrostátní či mezinárodní faktory, zmírňuje riziko opomenutí důležité vysvětlující proměnné, které by jinak mohlo odhady vztahů uvnitř endogenního modelu deformovat (Koop et al., 2009).

2.1.3 Bayesiánský odhad

Klasický (frekventistický) odhad VAR modelů se obvykle provádí pomocí OLS metody, která je efektivní za předpokladu dostatečně dlouhého vzorku. Jak jsem již zmiňoval v kapitole 2.1.1 u VAR modelů velmi rychle narůstá počet koeficientů. Připomenu, že pro odhad VAR(p) modelu s n proměnnými je potřeba $n(1 + np)$ parametrů. Tedy potřebujeme buď relativně dlouhé časové řady nebo redukovat počet regresorů či zpoždění. Bayesiánský přístup nabízí přirozené řešení tohoto problému. Bayesiánský přístup je

založený na tzv. apriorních informacích, které jsou upravovány podle našich dat a získáme tzv. posteriorní distribuci koeficientů. Tento přístup pomáhá stabilizovat odhady v malých vzorcích (Doan et al., 1983; Karlsson, 2012). Bayesovský VAR model (BVAR) vychází ze stejné struktury jako klasický VAR model (viz rovnice 2.1). Bayesiánský přístup však předpokládá, že neznáme parametry B a kovarianční matice Σ jsou náhodné veličiny s předem specifickým apriorním rozdělením $p(B, \Sigma)$.

O specifikách Bayesiánské analýzy píšou v pozdější kapitole 2.5. Je však zřejmé, že bayesovský přístup má výhody oproti „klasickým“ odhadům. Apriorní distribuce tlumí extrémní hodnoty parametrů a snižuje rozptyl odhadů, což zvyšuje robustnost modelu. Na rozdíl od bodových odhadů pomocí OLS poskytuje BVAR plné rozdělení parametrů, z něj lze poté odvodit také intervaly spolehlivosti. Bańbura et al. (2008) uvádějí, že BVAR modely (či jejich deriváty) dosahují lepší predikční výkonnosti, zejména v podmínkách omezené délky časových řad, což je pro kontext České republiky relevantní.

2.1.4 Choleského dekompozice

VAR modely jsou formulovány ve zredukované formě, kde všechny proměnné mohou reagovat na zpožděné hodnoty ostatních proměnných, avšak současné vztahy mezi nimi zůstávají neidentifikované. Náhodné složky modelu u_t mohou být navzájem korelované, a tudíž nelze bez dalších předpokladů určit, jaký podíl změny v jedné proměnné je důsledkem „vlastního“ šoku a jaký pochází z reakcí na jiné veličiny. Aby bylo možné analyzovat krátkodobé reakce a oddělit ortogonální (vzájemně nezávislé) šoky, je nutné provést jejich identifikaci.

Nejjednodušší a nejčastěji používanou metodou identifikace v empirické makroekonomii je Choleského dekompozice kovarianční matice reziduí. Tato metoda nevyžaduje dodatečné teoretické restrikce, poskytuje jednoznačné řešení a je výpočetně efektivní. Sims (1980) tuto metodu důkladně popsal a považuje se za průkopníka této metody. Z zredukované formy VAR modelu (rovnice 2.1) získáme matici Σ , kde $\Sigma = E(u_t u_t')$ je pozitivně definitní symetrická kovarianční matice inovací. Cílem je nalézt ortogonální šoky (ϵ_t), které jsou nekorelované a mají jednotkový rozptyl, tedy

$$E(\epsilon_t \epsilon_t') = I_n.$$

Pokud existuje regulární matice¹² P , tak že $u_t = P\epsilon_t$, pak platí, že

$$\Sigma = E(u_t u_t') = PE(\epsilon_t \epsilon_t')P' = PP'.$$

Hledáme tedy matici P , pro kterou platí, že $PP' = \Sigma$. Protože Σ je symetrická a pozitivně definitní, existuje jednoznačný Choleského rozklad, při němž $\Sigma = PP'$, kde P je dolní trojúhelníková matice s kladnými diagonálními prvky.

12. *Regulární matice* je taková matice, ke které lze vytvořit inverzní matici, tedy pokud pro matici M můžeme vytvořit matici M^{-1} , pak je matice M regulární.

Tento rozklad je ekvivalentní aplikaci ortogonální transformace, která „očistí“ rezidua od vzájemné korelace. Transformací $u_t = P\epsilon_t$ dostáváme vektor ortogonálních strukturálních inovací ϵ_t , které lze interpretovat jako vzájemně nezávislé šoky v jednotlivých proměnných systému. Pro lepší pochopení můžeme výraz $u_t = P\epsilon_t$ přepsat maticově

$$\begin{bmatrix} u_{1t} \\ u_{2t} \\ \vdots \\ u_{nt} \end{bmatrix} = \begin{bmatrix} p_{11} & 0 & 0 & \cdots & 0 \\ p_{21} & p_{22} & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{n,n-1} & p_{nn} \end{bmatrix} \begin{bmatrix} \epsilon_{1t} \\ \epsilon_{2t} \\ \vdots \\ \epsilon_{nt} \end{bmatrix}.$$

Z tohoto zápisu je lépe patrné, že první proměnná v systému reaguje v čase t pouze na vlastní šok ϵ_{1t} , druhá proměnná může reagovat jak na svůj vlastní šok ϵ_{2t} , tak na současný šok první proměnné ϵ_{1t} , třetí proměnná reaguje na šoky první, druhé a třetí proměnné, a tak dále. Pořadí proměnných ve vektoru y_t tedy určuje kauzální hierarchii v rámci jednoho časového období. Autor modelu tak musí určit pořadí proměnných podle předpokládané rychlosti jejich reakce. Autoři Lütkepohl (2005) či Enders (2014) ukazují, že se jedná o běžný přístup s minimální a transparentní sadou restrikcí, která umožňuje ekonomicky interpretovatelné výsledky.

2.1.5 Rekurzivní odhad

V ekonomikách často dochází ke strukturálním změnám (zlomům), které mohou ovlivnit vztahy mezi proměnnými. Předpoklad konstantních parametrů, který je základem „klasických“ VAR modelů, proto nemusí být realistický, zejména u časových řad pokrývajících delší časové období nebo časových řad u zemí s transformující se ekonomikou. V případě, že odhadujeme náš model i přes období strukturálního zlomu nemusí být naše výsledky korektní. Jedním z nejjednodušších způsobů, jak zohlednit dynamiku parametrů je využít rekurzivní odhad modelu. Tento přístup umožňuje, jak analyzovat samotné parametry, tak i jejich vývoj v čase.

Rekurzivní odhad spočívá v postupném rozšiřování vzorku dat (*expanding window*) a opakovaném odhadu modelu na stále větším množství dat. V praxi tedy máme celkový vzorek $\{y_t\}_{t=1}^T$. Zvolíme počáteční délku T_0 , na níž odhadneme první model. Poté přidáme jedno pozorování a model odhadneme na vzorku $T_0 + 1$. Tento odhad opakujeme, až nedojdeme do bodu, kdy odhadujeme model na celkovém počtu pozorování T . Formálně lze tento postup zapsat jako

$$\hat{\theta}_t = \arg \max_{\theta} \mathcal{L}(y_1, y_2, \dots, y_t | \theta), \quad t = T_0, T_{0+1}, T_{0+2}, \dots, T,$$

kde θ je vektor parametrů modelu a $\mathcal{L}(\cdot)$ je posteriorní hustota parametrů. Vznikne nám tak množina $\{\hat{\theta}_{T_0}, \hat{\theta}_{T_0+1}, \dots, \hat{\theta}_T\}$, což je množina všech odhadnutých posteriorních distribucí našich parametrů v čase. Takto lze odhalit případné strukturální změny, nestability modelu nebo změny ve velikosti parametrů (Hansen, 2001; Stock et al., 2001).

V byesovské ekonometrii má rekurzivní odhad přirozenou interpretaci jde o tzv. *sekvenciální aktualizaci posteriorní distribuce*. Jak ukazují Koop et al. (2009) či Karlsson (2012),

posteriorní rozdělení získané na základě dat do okamžiku T_0 se stává apriorním rozdělením pro následující krok odhadu. Tento princip lze formálně definovat následovně:

$$p(\theta|Y_{1:T_0+1}) \propto p(y_{T_0+1}|\theta)p(\theta|Y_{1:T_0}),$$

kde $p(\theta|Y_{1:T_0})$ představuje apriorní informace a $p(y_{T_0+1}|\theta)$ je podmíněná pravděpodobnost nově pozorovaných dat. Rekurzivní odhad tak umožňuje přirozeně integrovat nové informace bez ztráty historických dat a zároveň sledovat, jak se s novými daty mění distribuce parametrů (Koop et al., 2009).

2.2 Teoretická východiska volby modelu

Volba rekurzivně odhadovaného BVAR-X modelu v gapové formě s Choleského identifikací vychází z aktuální dostupné literatury a empirické praxe v modelování exportu malých otevřených ekonomik. Domnívám se, že kombinace bayesovského přístupu, exogenního bloku proměnných a rekurzivního odhadu představuje řešení, které se v současné empirické literatuře ukazuje jako efektivní kompromis mezi robustností a interpretační jednoduchostí a jedná se tak o vhodný modelový aparát pro účely této práce.

V posledních letech se BVAR modely staly standardem v aplikacích na exportní a obchodní dynamiky. Nguyen et al. (2024) odhadují růst exportu Vietnamu pomocí modelů BVAR a *mixed-frequency* VAR a zjišťují, že zapojení exogenních proměnných (globální poptávka, kurz, ceny komodit) významně zlepšují krátkodobé predikce. Podobně panelová analýza zemí ASEAN+3 (Rosorio et al., 2024) kombinuje VAR-X rámec s externími indikátory a potvrzuje, že vnější proměnné dominují při vysvětlování exportní dynamiky regionu. Tyto výsledky přímo podporují použití exogenního bloku při modelování exportu otevřených ekonomik.

Empirické aplikace na malé otevřené ekonomiky dále potvrzují, že bayesovské postupy přinášejí stabilnější a ekonomicky smysluplnější výsledky než klasické VAR modely. Onipede et al. (2022) rozšiřují tento přístup do rámce BGVAR s časově proměnnými parametry a dokumentují, že vnější šoky¹³ se do malých otevřených ekonomik promítají systematicky prostřednictvím exportních kanálů. Na podobný závěr dochází Corbo (2022) při analýze Švédska a Kanady, kde vývoj směnných kurzů a cenových šoků prokazatelně ovlivňuje exportní výkonnost. Výzkum tím potvrzuje, že modely s exogenním blokem jsou pro malé otevřené ekonomiky vhodným nástrojem zachycení vnějších vlivů.

Ani v evropském prostředí není tento přístup výjimkou. Ministerstvo financí ČR (2020) používá ve svém oficiálním prognostickém rámci VAR komponentu s externími proměnnými, což dokládá, že podobné modely jsou použitelné i pro českou ekonomiku. Nový dokument Evropské centrální banky (Linzenich et al., 2024) výslovně uvádí velké

13. Změny globální poptávky, světových úrokových sazeb a cen komodit

BVAR modely jako standardní nástroj pro krátkodobé predikce, a tedy i pro odhad krátkodobých elasticit exportu vůči zahraničním determinantům.

Také použití Choleského identifikace se opírá o běžnou empirickou praxi v současné makroekonomii. Aligishiev et al. (2025) i další metodologické studie (Wiesen, 2024) ji nadále používají jako výchozí schéma, ke kterému se porovnávají novější alternativy. Dle těchto studií v každém období nejprve reagují externí šoky (zahraniční poptávka, směnný kurz apod.), následně měnové a reálné veličiny domácích ekonomik a nakonec samotný export.

Rekurzivní odhad je pak vhodnou reakcí na nestabilitu parametrů v čase. V českých datech 2000–2023 dochází ke strukturálním zlomům (vstup do EU, *Great Recession* 2008, kurzové intervence ČNB, COVID-19 či energetický šok 2022), které pravděpodobně mění vztahy mezi exportem a jeho determinanty. Rekursivní přístup umožňuje průběžně sledovat vývoj parametrů a testovat stabilitu modelu bez nutnosti plné časové proměnlivosti parametrů.¹⁴ Tento přístup je doporučován i v novější makroekonomické literatuře (Lubik et al., 2015) jako realistický kompromis mezi flexibilitou a výpočetní jednoduchostí.

Celkově lze říci, že volba rekurzivně odhadovaného BVAR-X v gapové formě s Choleského identifikací je plně v souladu s moderní ekonometrickou praxí. Jde o model, který zvládá omezený počet pozorování, reflektuje vliv vnějších faktorů na export malé otevřené ekonomiky, umožňuje sledovat časovou proměnlivost vztahů a poskytuje velmi dobré výsledky v odhadu reálného datagenerujícího procesu.

2.3 Proměnné v modelu

Tato část se zaměřuje na představení proměnných použitých v mém modelu, případně jejich transformaci. Na úvod je třeba říci, že všechny proměnné, které vystupují v modelu jsou ve své gapové podobě, resp.

$$\hat{x}_t = 100[\log(x_t) - \log(\bar{x}_t)],$$

kde $\bar{x}_t$ je steady-state proměnné a x_t je pozorovaná proměnné. $\hat{x}_t$ tak při této transformaci odpovídá procentní odchylce od steady-state, což velmi usnadňuje interpretovatelnost výsledných koeficientů. Ve svém modelu používám následující proměnné: **reálný český export, zahraniční poptávku, nominální směnný kurz, inflační diferenciál, jednotkové nabídky práce a index importních cen**. Všechny originální časové řady byly již sezónně očištěny, v opačném případě byly očištěny za pomoci R skriptu, konkrétně jsem využil funkci `seas()` takto očištěné časové řady byli dále testovány a transformovány. Také je třeba


14. Tímto je myšleno použití VAR modelu s v čase proměnlivými koeficienty (TVP-VAR), jejímž průkopníkem se stal Primiceri (2005), který tento model použil na zkoumání měnové politiky USA. Odhad TVP-VAR modelu je však výpočetně mnohem náročnější, než odhad „obyčejného“ BVAR modelu. Pro tento odhad jsou délky časových řad českých proměnných nedostačující.

2. POUŽITÁ DATA A METODY

doplnit, že všechny časové řady jsou čtvrtletní a to od Q1 2000 do Q3 2023. Originální časové řady ilustruje obrázek 1.

První zvolenou proměnnou je **reálný český export**, který je zároveň vysvětlovanou proměnnou našeho modelu. Reálný export je vyjádřen v korunách ve stálých cenách, aby bylo abstrahováno od vlivu cenové hladiny. Časová řada byla získána z FRED (2024). Použití reálné exportu namísto nominální je v souladu s moderními empirickými přístupy, které zdůrazňují význam reálných veličin pro odhad elasticit a dopadů strukturálních šoků (Wiesen, 2024; Corbo, 2022; United Nations, 2025; Keil, 2024).

Obrázek 1: Originální časové řady proměnných



Zdroj: vlastní zpracování

Dalším použitým determinantem je **zahraniční poptávka**, ta představuje jeden z nejvýznamnějších faktorů vysvětlující vývoj exportu v malé otevřené ekonomice. Literatura potvrzuje, že růst poptávky v zahraničí má statisticky významný vliv na exportní výkon, a to zejména u ekonomik s vysokou mírou integrace na evropský trh (Antràs et al., 2021). Poptávka je chápána jako agregovaný ukazatel ekonomické aktivity obchodních

partnerů. V mém případě jako proxy proměnnou pro zahraniční poptávku používám vážený průměr reálného HDP největších exportních partnerů ČR a to podle objemu exportu dle dat dostupných z Observatory of Economic Complexity (2025). V tabulce 1 uvádím seznam exportních partnerů i s váhou¹⁵ a zdrojem dat. Využívám zahraniční poptávku jako exogenní proměnnou ve svém modelu, což odpovídá běžné praxi (srov. Corbo, 2022). Zvyšující se zahraniční poptávka se pozitivně promítá do růstu exportu, zatímco zpomalení ekonomického cyklu u hlavní partnerů má za následek ochlazení českého exportu.

Tabulka 1: Váhy reálného HDP 6 největších exportních partnerů

Země	Váha HDP	Zdroj dat
Německo	0,518	(FRED, 2025c)
Slovensko	0,128	(FRED, 2020)
Polsko	0,111	(FRED, 2025e)
Francie	0,087	(FRED, 2025b)
Itálie	0,081	(FRED, 2025d)
Rakousko	0,076	(FRED, 2025a)

Zdroj: vlastní zpracování

Jako další determinant používám **inflační diferenciál** mezi Českou republikou a zahraničím. Opět využívám stejné zahraniční partnery a stejné vážené průměry jako v případě zahraniční poptávky, viz tabulka 1. Inflační diferenciál je klíčovým ukazatelem cenové konkurenceschopnosti. Relativně rychlejší růst cenové hladiny doma vůči zahraničí vede k reálnému zhodnocení měny, a tím ke zhoršení konkurenceschopnosti dané ekonomiky na zahraničních trzích (Corbo, 2022; Keil, 2024).

Vysoký inflační diferenciál může indikovat přehřátí domácí ekonomiky nebo rostoucí výrobní náklady, které se následně promítají do exportních cen. Naopak nižší domácí inflace podporuje cenovou konkurenceschopnost českého exportu. Ve své práci jsem inflační diferenciál vypočítal jako

$$\hat{\pi}_t^{CZ} - \hat{\pi}_t^{FOR},$$

kde $\hat{\pi}_t^{CZ}$ je gap v domácí inflaci a $\hat{\pi}_t^{FOR}$ je gap v zahraniční inflaci. Jedná se tedy o rozdíl v gapu inflací. Kladné hodnoty proměnné znamenají, že inflační gap v České republice byl vyšší, než v zahraničí, tedy, že cenová hladina České republiky roste relativně rychleji vůči exportním partnerům a český export se tak stává relativně méně konkurenceschopným. Pro výpočet inflace jsem použil Harmonizovaný index spotřebitelských cen (HICP) dostupný z Eurostat (2025). Jelikož jsem danou časovou řadu (resp. časovou řadu pro HICP České republiky a HICP pro zahraničí) zlogaritmoval a provedl první diferenci získal jsem odhad inflace. Tedy

$$\pi_t = \Delta \log(HICP)_t = \log(HICP)_t - \log(HICP)_{t-1}.$$

15. Součet vah je roven jedné.

2. POUŽITÁ DATA A METODY

Pro úplnost ještě uvedu, že tento index je pro všechny položky obsažené v HICP (beru tedy celkovou inflaci) a index nabývá hodnoty 100 v roce 2005. Jelikož jsou na stránkách Eurostatu dostupná pouze měsíční data vzal jsem vždy průměr tří měsíčních hodnot spadajících do daného čtvrtletí.

Nominální **směnný kurz** koruny vůči euru představuje jeden z hlavních determinantů Českého exportu a také další proměnnou v mém modelu. Vzhledem k tomu, že většina českého exportu směřuje do eurozóny, je tento kurz zásadním faktorem ovlivňujícím exportní výkonnost české ekonomiky. Studie Caselli (2017); Corbo (2022) či Keil (2024) potvrzují, že apreciacie domácí měny snižuje exportní výkony, zatímco její depreciace export podporuje.

Časovou řadu pro nominální směnný kurz jsem získal ze systému ARAD (ČNB, 2025). Kurz je uváděn v přímé kotaci, která je pro Českou republiku běžnější, tedy kolik domácí měny (CZK) je potřeba na nákup jedné jednotky zahraniční měny (EUR). Tedy, pokud vidíme na obrázku 1 klesající trend znamená to dlouhodobou apreciaci koruny vůči euru.

Dalším zvoleným determinantem jsou **jednotkové náklady práce**, které slouží jako klíčový ukazatel konkurenceschopnosti skrze produktivitu práce. Nárůst jednotkových nákladů práce znamená, že růst mezd převyšuje růst produktivity, což může vést ke ztrátě konkurenceschopnosti. Literatura tento vztah potvrzuje (srov. De Broeck, 2012; Herrero, 2022). V případě České republiky, jejíž exportní sektor je silně navázán na průmyslovou výrobu, je vývoj této proměnné obzvláště relevantní. Proměnnou zastupující jednotkové náklady práce je *Productivity and unit labour cost (employment based) index*, který vydává OECD (2025). Index nabývá hodnoty 100 v roce 2015.

Poslední proměnnou použitou v mém modelu je **index reálných importních cen**, který vyjadřuje vývoj cen dovážených vstupů po očištění o domácí cenovou hladinu. Tato proměnná má zásadní význam pro hodnocení nákladových tlaků v exportních odvětvích, která jsou silně závislá na dovozech meziproductů a energií. Růst reálných importních cen snižuje konkurenceschopnost vývozců a může negativně ovlivnit objem exportu (Keil, 2024). Očekávám, že význam této proměnné se projeví zejména v období energetické krize (cca 2021-2023), kdy prudký růst cen energií významně ovlivnil českou ekonomiku. Časové řady pro tuto proměnnou získávám ze stránek Eulerpool (2025).

Domnívám se, že zvolený soubor proměnných reflektuje klíčové determinanty vývoje českého exportu. Proměnné umožňují zachytit všechny očekávané vlivy na export a to jak na nabídkové, tak na poptávkové straně. Pro přehlednost přikládám tabulku 2, která souhrnně udává všechny použité proměnné, jejich notaci v této práci a notaci v příloženém R skriptu (viz příloha A). Přidávám také očekávané znaménko parametru daného determinantu. Kladné znaménko (+) znamená, že 1% růst nad steady-state dané proměnné ovlivňuje export kladně a záporné znaménko (-) potom naopak, že růst ovlivňuje proměnnou negativně.

Tabulka 2: Proměnné použité v modelu

Proměnná	Notace v textu	Notace ve skriptu	Očekávaná hodnota
Export	$\hat{x}_t$	l_x_gap	
Zahraniční poptávka	$\hat{y}_t$	l_y_gap	+
Směnný kurz	$\hat{e}_t$	l_e_gap	+
Inflační diferenciál	$\hat{\pi}_t^{CZ} - \hat{\pi}_t^{FOR}$	l_p_gap	-
Jednotkové náklady práce	$\hat{ulc}_t$	l_ulc_gap	-
Index importních cen	$\hat{m}_t$	l_m_gap	-

Zdroj: vlastní zpracování

Pro úplnost také uvádím, které proměnné беру jako exogenní a které jako endogenní¹⁶. Mezi exogenní proměnné řadím: zahraniční poptávku a index importních cen neb ty nemůže vývoj českého exportu nijak ovlivnit. Ostatní proměnné jsou brány jako endogenní a to v tomto pořadí:

1. inflační diferenciál,
2. nominální směnný kurz,
3. jednotkové náklady práce a
4. export.

Toto pořadí je od „nejméně“ endogenní proměnné po tu „nejvíce“ endogenní proměnou.

2.4 Odhad cyklických složek proměnných

Cílem této části je oddělit krátkodobé výkyvy od dlouhodobého trendu, a získat tak časové řady, které odpovídají definici odchylek od ustáleného stavu. Právě práce s cyklickými komponentami umožňuje lépe zachytit dynamické vazby mezi makroekonomickými proměnnými. V první části kapitoly proto diskutují volbu filtrační metody (2.4.1) a její vlastnosti, následně představují odhadnuté cyklické složky a jejich základní statistické charakteristiky (2.4.3), které slouží jako vstup do modelu v další části práce.

2.4.1 Volba filtrační metody pro odhad cyklické a trendové složky

Rozklad časové řady na její cyklickou, sezónní a trendovou složku je dlouhodobě diskutovaná problematika. Dlouhodobě se vede diskuse nad správným odhadem trendové

16. U endogenní proměnných uvádím také pořadí ve vektoru kvůli Choleského dekompozici, viz kapitola 2.1.4.

a cyklické složky ekonomických veličin. Nejčastěji využívaným nástrojem pro tuto dekompozici je *Hodrick-Prescottův* (HP) filtr, který představili tito ekonomové ve své práci (Hodrick et al., 1997).¹⁷

Standardní podoba HP filtru je dvoustranná, což znamená, že pro výpočet trendu v čase t využíváme nejen minulá, ale i budoucí pozorování. Tento přístup má své nesporné výhody, výsledný trend je hladší a lépe vystihuje dlouhodobý vývoj. Nicméně v reálném čase, kdy jsou data dostupná pouze do období t , je tato varianta problematická. Výsledkem je tzv. *end-point bias*, zkreslení na konci časové řady (Mise et al., 2003). Tento problém vedl k vývoji jednostranného HP filtru, který se snaží zachovat základní logiku filtru, ale je více robustní.

2.4.2 Fungování Hodrick-Prescottova filtru

V podstatě jde o řešení optimalizačního problému, ve kterém hledáme hladkou trendovou složku (τ_t) minimalizující následující funkci:

$$\min_{\{\tau_t\}} \left[\sum_{t=1}^T (y_t - \tau_t)^2 + \lambda \sum_{t=2}^{T-1} [(\tau_{t+1} - \tau_t) - (\tau_t - \tau_{t-1})]^2 \right], \quad (2.2)$$

kde y_t je původní časová řada, τ_t trend a λ vyhlazovací parametr.¹⁸ První člen penalizuje odchylku od původních dat, druhý pak „křivost“ trendu. Hodnota λ určuje relativní váhu obou kritérií (vyšší λ vede k hladšímu trendu). Výsledkem je dekompozice časové řady na trend (τ_t) a cyklickou složku

$$\hat{y}_t = y_t - \bar{y}_t,$$

kde $\hat{y}_t$ je cyklická složka, ta je interpretovaná jako odchylka proměnné od jejího ustáleného stavu a $\bar{y}_t \equiv \tau_t$.

Základní nedostatkem klasického HP filtru je již zmiňované v předhledění u výpočtu trendové složky. Tedy trendu v čase t nezáleží pouze na hodnotách $y_{t-1}, y_{t-2}, \dots$, ale také na budoucích hodnotách $y_{t+1}, y_{t+2}, \dots$. To vede ke zkreslení výsledků na konci řady. Toto zkreslení je zdokumentováno v literatuře, např. Cogley et al. (1995) či Orphanides et al. (2002).

Jako alternativu ke klasickému HP filtru a odpověď na jeho nedostatky byl navrhnut tzv. jednostranný HP filtr, který představuje modifikace klasického procesu, kdy se trend v každém čase odhaduje pouze na základě informací z minulých pozorování. Filtr je aplikován rekurzivně a při přidání nového pozorování se přepočítá jeho trend, nikoli celá řada. Formálně lze jednostranný HP filtr chápat jako aproximaci řešení, které by

17. Původní verze HP filtru byla používána v nepublikovaných studiích již v 80. letech, ale širší známost získala až po vydání článku *Postwar U.S. business cycle: An empirical investigation*.

18. Pro čtvrtletní data se parametr λ většinou kalibruje na hodnotu 1600, tuto hodnotu jsem použil pro odhad trendu proměnných.

minimalizovalo funkci, uvedenou v rovnici 2.2, pro každý časový okamžik zvlášť a to jen s využitím aktuálně dostupných dat. V důsledku toho je výsledný trend méně hladký, než u klasického HP filtru. Cyklus je více volatilnější a obsahuje více bílého šumu.

Literatura ukazuje, že real-time odhadu cyklické složky jsou extrémně nestabilní a silně závislé na metodě (Orphanides et al., 2002). Jednostranný HP filtr, tak představuje pragmatické řešení protože poskytuje konzistentní časovou řadu odhadů. Mise et al. (2003) ukazují, že i když jednostranný HP filtr vede k méně hladkým výsledkům, jeho predikční schopnost pro makroekonomické veličiny může být lepší, než u klasické verze.

2.4.3 Cyklické složky proměnných

Pro odhad cyklických složek byl využit jednostranný HP filtr, důvod jeho výběru a jeho fungování je shrnut v kapitolách 2.4.1 a 2.4.2. Všechny odhadnuté cyklické složky jsou zobrazeny na obrázku 2. Z obrázku je patrné, že export je nejvíce volatilní proměnnou, naopak nejméně volatilní proměnnou je inflační diferenciál.

U všech proměnných byl proveden ADF (*Augmented Dickey-Fuller*) test, z výsledků testů, které jsou shrnuty v příloze B je patrné, že všechny časové řady jsou stacionární, tedy již je nemusíme dále upravovat a můžeme je v této podobě korektně použít pro odhad našeho modelu. V tabulce 3 uvádím popisné statistiky zvolených časových řad (první a druhý moment). Všechny proměnné mají po aplikaci HP filtru střední hodnotu blízkou nule.

Tabulka 3: Popisné statistiky cyklických složek proměnných


Proměnná	Střední hodnota	Rozptyl	Směrodatná odchylka
l_x_gap	-0,4966	34,7367	5,8938
l_y_gap	-0,0037	3,1579	1,7770
l_e_gap	0,2217	8,1383	2,8528
l_p_gap	0,2267	0,9614	0,9805
l_ulc_gap	0,0543	2,5670	1,6022
l_m_gap	0,6339	10,5474	3,2477

Zdroj: vlastní zpracování

2.5 Bayesiánská analýza

Bayesiánská analýza představuje statistický přístup, který se zakládá na Bayesově teorému (viz rovnice 2.3) a umožňuje spojení předchozích znalostí s daty prostřednictvím distribuce pravděpodobnosti. V praxi nám tyto metody umožňují formálně začlenit do modelu naše předchozí znalosti (teorii) a empirická pozorování. Bayesiánské techniky

Obrázek 2: Odchylyky proměnných od ustáleného stavu



Zdroj: vlastní zpracování

jsou také vhodné při malém vzorku dat či strukturálními zlomy v datech, což je náš případ.

Na rozdíl od klasické ekonometrie, která se zaměřuje na odhady parametrů jako fixních hodnot a jejich testování na základě dlouhodobých vztahů mezi proměnnými, bayesiánská ekonometrie považuje parametry za náhodné veličiny s vlastními distribucemi pravděpodobnosti (Bernardi, 2021). Němec (2011) podotýká, že v kontextu ekonometrie bayesiánský přístup umožňuje estimaci parametrů s ohledem na ekonomickou teorii (využijeme jako priory), což zlepšuje robustnost v malých vzorcích.

Princip fungování bayesiánských metod lze shrnout do tří základních komponent: *prior*, *likelihood*¹⁹ a *posterior*. Prior reprezentuje naše předchozí znalosti o parametrech, které mohou být informativní – na základě expertních odhadů nebo neinformativní, aby minimalizovali vliv na výsledek. Likelihood je funkce, které popisuje, jak probíhá datagenerující proces dle dostupných dat. Posterior se pak získá kombinací těchto dvou veličin, což umožňuje formalizovat nejistotu spojenou s odhadem parametrů (Němec, 2011).

19. *Likelihood* je věrohodnostní funkce.

Centrálním nástrojem je tzv. *Bayesův teorém*, který je definován jako:

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)}, \quad (2.3)$$

kde $p(\theta|y)$ je posteriorní distribuce parametrů θ za podmínky dat y , $p(y|\theta)$ je likelihood, $p(\theta)$ je prior a $p(y)$ je marginální pravděpodobnost²⁰ dat. Jinými slovy rovnice říká, že podmíněná pravděpodobnost, že nastane jev θ za podmínky y je rovna poměru pravděpodobnosti nastání jevu y za podmínky θ a pravděpodobnosti nastání jevu θ ku pravděpodobnosti nastání jevu y . Tato rovnice ukazuje, jak nová data modifikují předchozí přesvědčení o parametrech (Bernardi, 2021).

V praxi si to můžeme představit následovně. Předpokládáme určitý vliv růstu agregátní poptávky (AD) na inflaci na základě ekonomické teorie, tuto informaci použijeme jako prior ($p(\theta)$). Poté můžeme do modelu přidat reálná pozorovaná data ($p(y)$). Kombinací těchto veličin získáme posterior ($p(\theta|y)$), tedy hodnotu našeho vlivu AD na inflaci, který vychází jak z teorie, tak z pozorovaných dat (srov. Němec, 2011).

Pro estimaci posteriorní distribuce se v praxi využívají numerické metody, jako *Markov chain Monte Carlo* (MCMC), které generalizují vzorky z posterioru. Mezi nejpoužívanější algoritmy patří např. Gibbsonův vzorkovač, Metropolis-Hastings algoritmus nebo Hamiltonian Monte Carlo, který jsem použil pro svoji práci (viz 2.5.1).

Práci s bayesiánskými metodami v dnešní době zvládá většina ekonometrických a statistických softwarů, jako např. MatLab, R, Python či Stata. Pro svoji práci jsem využil programovací jazyk R (a to v prostředí R Studio).

2.5.1 Hamiltonian Monte Carlo

Pro generování posteriorního rozdělení parametrů Bayesiánského modelu je využita metoda *Hamiltonian Monte Carlo* (HMC), která představuje rozšíření klasického algoritmu Metropolis-Hastings. Oproti standardním MCMC metodám HMC neprovádí náhodné návrhy parametrů, ale využívá informaci o gradientu²¹ log-posterioru, což umožňuje efektivnější prozkoumání prostoru parametrů (Korobilis, 2020; Bernardi, 2021).

Cílem algoritmu je získat posloupnost náhodných vektorů parametrů

$$\theta_1, \theta_2, \dots, \theta_N,$$

jejíž rozdělení odpovídá posterioru $p(\theta|y)$, kde y je vektor (resp. matice) pozorovaných dat, θ je vektor všech parametrů modelu, $p(\theta|y)$ je posteriorní hustota, $L(y|\theta)$ je věrohodnost (likelihood) a $\pi(\theta)$ je apriorní rozdělení parametrů. Podle Bayesovy věty (rovnice

20. Marginální pravděpodobnost je pravděpodobnost, že nastane daný jev, bez podmínky toho, že nastane jiný jev.

21. *Gradient* (∇) je vektor všech parciálních derivací funkce podle jejích proměnných, který udává směr největšího růstu hodnoty funkce.

2.3) platí:

$$p(\theta | y) \propto L(y | \theta) \pi(\theta).$$

Metoda HMC rozšiřuje prostor parametrů zavedením pomocné proměnné p , která je náhodný vektor se střední hodnotou nulou a rozptylem definovaným pozitivně definitní maticí M :

$$p \sim \mathcal{N}(0, M).$$

Matice M^{22} určuje škálování jednotlivých dimenzí parametrů. HMC pracuje s tzv. *Hamiltoniánem*, který definuje společnou funkci dvou proměnných:

$$H(\theta, p) = U(\theta) + K(p).$$

Zde platí, že $U(\theta)$ je tzv. *potenciální energie*, definovaná jako záporný log-posterior:

$$U(\theta) = -\log p(\theta | y) = -\log L(y | \theta) - \log \pi(\theta)$$

a $K(p)$ je tzv. *kinetická energie*, definovaná kvadraticky pomocí pomocné proměnné p :

$$K(p) = \frac{1}{2} p' M^{-1} p.$$

Společná hustota pro dvojici (θ, p) je pak dána jako

$$p(\theta, p) \propto \exp[-H(\theta, p)] = \exp[-U(\theta)] \exp[-K(p)].$$

Algoritmus generuje návrhy nových hodnot θ' pomocí diskrétní simulace změn θ a p . Jejich vývoj je popsán následujícími diferenciálními rovnicemi

$$\frac{d\theta}{dt} = M^{-1}p, \quad \frac{dp}{dt} = -\nabla_{\theta} U(\theta),$$

kde t je pomocný (umělý) parametr simulace a $\nabla_{\theta} U(\theta)$ označuje gradient funkce $U(\theta)$ podle všech složek vektoru θ . V praxi se tyto rovnice řeší numericky²³ pomocí tzv. *leapfrog integrátoru*²⁴. Pro krok o délce ε lze schéma zapsat jako

$$\begin{aligned} p_{t+\frac{\varepsilon}{2}} &= p_t - \frac{\varepsilon}{2} \nabla_{\theta} U(\theta_t), \\ \theta_{t+\varepsilon} &= \theta_t + \varepsilon M^{-1} p_{t+\frac{\varepsilon}{2}}, \\ p_{t+\varepsilon} &= p_{t+\frac{\varepsilon}{2}} - \frac{\varepsilon}{2} \nabla_{\theta} U(\theta_{t+\varepsilon}). \end{aligned}$$

22. *Mass matrix* M je matice určující relativní škálování jednotlivých parametrů v HMC. Správná volba M umožňuje algoritmu efektivněji postupovat v různých směrech prostoru parametrů.

23. *Numerická integrace* je metoda, která nahrazuje soustavu spojitých diferenciálních rovnic jejich diskrétní aproximací po malých krocích délky ε .

24. *Leapfrog integrátor* je stabilní numerické schéma používané v HMC pro střídavou aktualizaci parametrů a pomocných proměnných, které kombinuje výpočet gradientu a lineární posun parametrů.

Tyto tři kroky tvoří jeden *leapfrog* krok a opakují se L -krát. Po L krocích dostaneme nový návrh (θ', p') .

Protože numerická integrace není přesná, provádí se po každém návrhu akceptační test ve stylu Metropolis-Hastings. Spočítá se změna Hamiltoniánu

$$\Delta H = [U(\theta') + K(p')] - [U(\theta) + K(p)],$$

a nový návrh je přijat s pravděpodobností

$$\alpha = \min\{1, e^{-\Delta H}\}.$$

Pokud je návrh přijat, nastaví se $\theta_{t+1} = \theta'$, v opačném případě se ponechá původní hodnota $\theta_{t+1} = \theta_t$. Po každé iteraci se pomocná proměnná p znovu generuje z rozdělení $\mathcal{N}(0, M)$, aby se zabránilo závislosti mezi jednotlivými vzorky.

Pro svoji práci jsem využil HMC algoritmus ve své modifikaci *No-U-Turn Sampler* (NUTS), který využívá adaptivní variantu algoritmu²⁵. Navíc je automaticky implementován v prostředí Stan. NUTS automaticky určuje délku trajektorie a velikost kroku ε , takže není nutné je volit ručně.

Oproti klasickým metodám náhodného skoku, jako je Metropolis-Hastings či Gibbsovův vzorkovač, dosahuje HMC nižší autokorelace mezi vzorky a rychlejší konvergence k posteriornímu rozdělení (Hoffman et al., 2014; Farkas et al., 2020).

25. *Adaptivní krok ε* je délka jednoho dílčího kroku v HMC. Menší ε zvyšuje přesnost integrace, ale snižuje efektivitu výpočtu. Ve Stan se hodnota ε adaptuje automaticky během zahřívací fáze (warm-up).

Empirická analýza

Text

Závěr

Text

Bibliografie

1. ALIGISHIEV, Zamid; GHIAIE, Hamed. *Cyclical Fiscal Multipliers: Policy Mix and Financial Friction Puzzle*. 2025. IMF Working Paper, WP/25/108. International Monetary Fund. Dostupné také z: <https://www.imf.org/en/Publications/WP/Issues/2025/05/30/Cyclical-Fiscal-Multipliers-Policy-Mix-and-Financial-Friction-Puzzle-567327>.
2. ANDERSON, James E.; WINCOOP, Eric van. Gravity with Gravitas: A Solution to the Border Puzzle. *American Economic Review*. 2003, roč. 93, č. 1, s. 170–192. Dostupné z doi: 10.1257/000282803321455214.
3. ANDRLE, M.; HLEDÍK, T.; KAMENÍK, O.; VLČEK, J. Implementing the New Structural Model of the Czech National Bank. *Czech National Bank Research and Policy Notes* [online]. 2009 [cit. 2025-12-01]. Dostupné z: https://www.cnb.cz/export/sites/cnb/en/economic-research/.galleries/research_publications/cnb_wp/cnbwp_2009_02.pdf.
4. ANTRÀS, Pol; CHOR, Davin. *Global Value Chains*. 2021. NBER Working Paper, 28549. National Bureau of Economic Research. Dostupné z doi: 10.3386/w28549.
5. BAIER, Scott L.; BERGSTRAND, Jeffrey H. Do Free Trade Agreements Actually Increase Members' International Trade? *Journal of International Economics*. 2007, roč. 71, č. 1, s. 72–95. Dostupné z doi: 10.1016/j.jinteco.2006.02.005.
6. BAÑBURA, Marta; GIANNONE, Domenico; REICHLIN, Lucrezia. *Large Bayesian VARs*. 2008. Working Paper Series, 966. European Central Bank. Dostupné také z: <https://www.ecb.europa.eu/pub/pdf/scpwps/ecbwp966.pdf>.
7. BÉKÉS, Gábor. Unit Values, Unit Labour Costs and Trade Performance in Four Central European Countries. *Working Paper*. 2013. Dostupné také z: <https://ideas.repec.org/p/has/discpr/1329.html>.
8. BENÁČEK, V.; PROKOP, L.; VÍŠEK, J. *Determining Factors of the Czech Foreign Trade Balance: Structural Issues in Trade Creation*. Prague, 2003. CNB Working Paper Series, 3/2003. Czech National Bank. Dostupné také z: https://www.cnb.cz/export/sites/cnb/en/economic-research/.galleries/research_publications/cnb_wp/wp3-2003.pdf.
9. BERGSTRAND, Jeffrey H. The Gravity Equation in International Trade. *The Review of Economics and Statistics*. 1985, roč. 67, č. 3, s. 474–481. Dostupné z doi: 10.2307/1925976.
10. BERNARDI, Mauro. *Bayesian Econometrics*. 2021. Dostupné také z: <https://www.econstor.eu/bitstream/10419/237798/1/Bayesian-Econometrics.pdf>.

BIBLIOGRAFIE

11. BOLATTO, Silvia; GRAZZI, Matteo; PIETROBELLI, Carlo; SASSO, Simone. Export Determinants at the Firm-Level: Evidence from Latin America. *Working Paper*. 2019. Dostupné také z: https://mgrazzi.github.io/bolatto_etal_2019-11.pdf.
12. BOTTEGA, Alberto. Innovation, Export Performance and Trade Elasticities. *Technological Forecasting and Social Change*. 2021, roč. 170, s. 120951. Dostupné z doi: 10.1016/j.techfore.2021.120951.
13. BRŮHA, Jan; TONNER, Jaromír. An Exchange Rate Floor as an Instrument of Monetary Policy: An Ex-Post Assessment of the Czech Experience. *CNB Working Paper Series*. 2017, č. 4. Dostupné také z: https://www.cnb.cz/export/sites/cnb/en/economic-research/.galleries/research_publications/cnb_wp/cnbwp_2017_04.pdf.
14. CAMPA, Jose Manuel; GOLDBERG, Linda S. Exchange Rate Pass-Through into Import Prices: A Macro or Micro Phenomenon? *NBER Working Paper*. 2002, č. 8934. Dostupné také z: <https://www.nber.org/papers/w8934>.
15. CASELLI, Francesca. Did the Exchange Rate Floor Prevent Deflation in the Czech Republic? *IMF Working Paper*. 2017, č. 17/206. Dostupné také z: <https://ideas.repec.org/p/imf/imfwpa/2017-206.html>.
16. COGLEY, Timothy; NASON, James M. Effects of the Hodrick-Prescott filter on trend and difference stationary time series Implications for business cycle research. *Journal of Economic Dynamics and Control*. 1995, roč. 19, č. 1, s. 253–278. ISSN 0165-1889. Dostupné z doi: [https://doi.org/10.1016/0165-1889\(93\)00781-X](https://doi.org/10.1016/0165-1889(93)00781-X).
17. CORBO, Vesna. *Drivers of Consumer Prices and Exchange Rates in Small Open Economies*. 2022. Working Paper, 407. Sveriges Riksbank. Dostupné také z: <https://www.riksbank.se/globalassets/media/rapporter/working-papers/2022/no.-407-drivers-of-consumer-prices-and-exchange-rates-in-small-open-economies.pdf>.
18. ČESKÁ NÁRODNÍ BANKA. *Zpráva o měnové politice* [online]. 2021. [cit. 2025-12-01]. Tech. zpr. Česká národní banka. Dostupné z: <https://www.cnb.cz/cs/menova-politika/zpravy-o-menove-politice/>.
19. ČNB. *Kurz koruny k euru (CZK/EUR), čtvrtletní, sezónně neočištěno, nominálně*. 2025. Dostupné také z: https://www.cnb.cz/arad/#/cs/display_link/single_MEXRHCZEUQNAJEXRVALNOMQ_.
20. DE BROECK, Mark. Assessing Competitiveness Using Industry Unit Labour Costs. *IMF Working Paper*. 2012, č. WP/12/107. Dostupné také z: <https://www.imf.org/external/pubs/ft/wp/2012/wp12107.pdf>.
21. DECRAMER, Stefaan; FUSS, Catherine; KONINGS, Jozef. How Do Exporters React to Changes in Cost Competitiveness? *ECB Working Paper*. 2014, č. 1752. Dostupné také z: https://www.comp-net.org/fileadmin/_compnet/user_upload/research/Trade_and_Competitiveness/ecbwp1752.en.pdf.
22. DOAN, Thomas; LITTERMAN, Robert; SIMS, Christopher A. *Forecasting and Conditional Projection Using Realistic Prior Distributions for VARs*. 1983. Working Paper, 1202. National Bureau of Economic Research. Dostupné z doi: 10.3386/w1202.
23. EATON, Jonathan; KORTUM, Samuel. Technology, Geography, and Trade. *Econometrica*. 2002, roč. 70, č. 5, s. 1741–1779. Dostupné z doi: 10.1111/1468-0262.00352.

24. ENDERS, Walter. *Applied Econometric Time Series*. 4th. Wiley, 2014. Dostupné také z: <https://www.wiley.com/en-us/Applied+Econometric+Time+Series%2C+4th+Edition-p-9781118808566>.
25. EULERPOOL. *Ceny dovozu – Česká republika*. 2025. Dostupné také z: <https://eulerpool.com/cs/macro/%C4%8Desk%C3%A1-republika/ceny-dovozu>.
26. EUROSTAT. *HICP – monthly data (index) [dataset]*. 2025. Dostupné z doi: 10.2908/PRC_HICP_MIDX. Dataset code: prc_hicp_midx.
27. FAGERBERG, Jan. International Competitiveness. *The Economic Journal*. 1988, roč. 98, č. 391, s. 355–374. Dostupné také z: <https://www.jstor.org/stable/2667846>.
28. FARKAS, Matyas; TATAR, Balazs. Bayesian Estimation of DSGE Models with Hamiltonian Monte Carlo. 2020. Dostupné také z: <https://www.matyafarkas.eu/publication/hmc/hmc.pdf>.
29. FRAIT, Jan; MORA, Marek. From Float to Currency Floor and Back to Float: The Czech National Bank's Temporary Exchange Rate Commitment. In: *BIS Papers No. 113: Monetary Policy Frameworks in the Post-COVID World*. Bank for International Settlements, 2021, s. 121–131. Dostupné také z: https://www.bis.org/publ/bppdf/bispap113_g.pdf.
30. FRANTA, Marek; HOLUB, Tomáš; KRÁL, Petr; ŠMÍDKOVÁ, Kateřina. *The Exchange Rate as an Instrument at Zero Interest Rates: The Case of the Czech Republic* [online]. 2014. [cit. 2025-12-01]. CNB Working Paper, 14/229. Česká národní banka. Dostupné z: https://www.cnb.cz/export/sites/cnb/cs/ekonomicky-vyzkum/.galleries/vyzkum_publikace/rpn/download/rpn_3_2014_cz.pdf.
31. FRED. *National Accounts: GDP by Expenditure: Constant Prices: Exports of Goods and Services for Czech Republic (Series NAEXKP06CZQ652S)* [FRED, Federal Reserve Bank of St. Louis]. 2024. Dostupné také z: <https://fred.stlouisfed.org/series/NAEXKP06CZQ652S>.
32. FRED. *Real Gross Domestic Product for Austria [Series ID: CLVMNACSCAB1GQAT]* [FRED, Federal Reserve Bank of St. Louis]. 2025. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQAT>.
33. FRED. *Real Gross Domestic Product for France [Series ID: CLVMNACSCAB1GQFR]* [FRED, Federal Reserve Bank of St. Louis]. 2025. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQFR>.
34. FRED. *Real Gross Domestic Product for Germany [Series ID: CLVMNACSCAB1GQDE]* [FRED, Federal Reserve Bank of St. Louis]. 2025. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQDE>.
35. FRED. *Real Gross Domestic Product for Italy [Series ID: CLVMNACSCAB1GQIT]* [FRED, Federal Reserve Bank of St. Louis]. 2025. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQIT>.
36. FRED. *Real Gross Domestic Product for Poland [Series ID: CLVMNACSCAB1GQPL]* [FRED, Federal Reserve Bank of St. Louis]. 2025. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQPL>.
37. FRED. *Real Gross Domestic Product for Slovakia [Series ID: CLVMNACSCAB1GQSK]* [FRED, Federal Reserve Bank of St. Louis]. 2020. Dostupné také z: <https://fred.stlouisfed.org/series/CLVMNACSCAB1GQSK>.

BIBLIOGRAFIE

38. FROMLET, Per. Exchange Rates, Wages, and Export Price Dynamics. *National Institute of Economic Research Working Paper*. 2013. Dostupné také z: <https://www.konj.se/media/f10bnp24/working-paper-132-exchange-rates-wages-and-export-price-dynamics.pdf>.
39. GHIRONI, Fabio; MELITZ, Marc J. International Trade and Macroeconomic Dynamics with Heterogeneous Firms. *The Quarterly Journal of Economics* [online]. 2005, vol. 120, no. 3, s. 865–915 [cit. 2025-12-01]. Dostupné z doi: 10.1093/qje/120.3.865.
40. HANSEN, Bruce E. The New Econometrics of Structural Change: Dating Breaks in U.S. Labor Productivity. *Journal of Economic Perspectives*. 2001, roč. 15, č. 4, s. 117–128. Dostupné také z: <https://pubs.aeaweb.org/doi/pdf/10.1257/jep.15.4.117>.
41. HAVRLANT, David. Models of Factors Driving the Czech Export. *Problems of Economic Transition*. 2011, roč. 3, s. 195–215. Dostupné také z: <https://ideas.repec.org/a/prg/jnlpep/v2011y2011i3id396p195-215.html>.
42. HEAD, Keith; MAYER, Thierry. Gravity Equations: Workhorse, Toolkit, and Cookbook. In: GOPINATH, Gita; HELPMAN, Elhanan; ROGOFF, Kenneth (ed.). *Handbook of International Economics, Vol. 4*. Elsevier, 2014, s. 131–195. Dostupné z doi: 10.1016/B978-0-444-54314-1.00003-3.
43. HELPMAN, Elhanan; MELITZ, Marc; RUBINSTEIN, Yona. Estimating Trade Flows: Trading Partners and Trading Volumes. *The Quarterly Journal of Economics*. 2008, roč. 123, č. 2, s. 441–487. Dostupné z doi: 10.1162/qjec.2008.123.2.441.
44. HERRERO, Diego. Labor Costs, KIBS, and Export Performance: A Comparative Study. *Hans Böckler Foundation Working Paper*. 2022. Dostupné také z: https://www.boeckler.de/pdf/v_2022_10_22_herrero.pdf.
45. HODRICK, Robert J.; PRESCOTT, Edward C. Postwar U.S. business cycles: An empirical investigation. *Journal of Money, Credit and Banking*. 1997, roč. 29, č. 1, s. 1–16. Dostupné také z: <https://doi.org/10.2307/2953682>.
46. HOFFMAN, Matthew D.; GELMAN, Andrew. The No-U-Turn Sampler: Adaptively Setting Path Lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*. 2014, roč. 15, s. 1593–1623. Dostupné také z: <https://arxiv.org/abs/1111.4246>.
47. CHOUDHRI, Ehsan U. The Exchange Rate Pass-Through to Import and Export Prices. *Journal of Policy Modeling*. 2015, roč. 37, č. 3, s. 510–529. Dostupné z doi: 10.1016/j.jpolmod.2015.03.001.
48. CHRISTIANO, L. Christopher A. Sims and Vector Autoregressions. *Scandinavian Journal of Economics*. 2012, roč. 114, č. 4, s. 1082–1104. Dostupné také z: <https://www.jstor.org/stable/23356950>.
49. JANDA, Karel; MICHALIKOVÁ, Eva; SKUHROVEC, Jiří. Credit Support for Export: Evidence from the Czech Republic. *CERGE-EI Working Paper Series*. 2012, č. 461. Dostupné také z: <https://ideas.repec.org/p/cer/papers/wp461.html>.
50. JONES, Ronald W. A Survey of the Theory of International Trade: Part I, The Classical Theory. *The Economic Journal*. 1961, roč. 71, č. 282, s. 1–16. Dostupné z doi: 10.2307/2228245.
51. KARLSSON, Sune. Forecasting with Bayesian VARs. In: ELLIOTT, Graham; TIMMERMAN, Allan (ed.). *Handbook of Economic Forecasting, Volume 2A*. Elsevier, 2012, s. 791–897. Dostupné z doi: 10.1016/B978-0-444-53683-9.00015-4.

52. KEIL, Sebastian. Assessing the Role of Non-Price Factors: Shedding New Light on Export Competitiveness. *International Economics*. 2024. Dostupné z dor: 10.1016/j.inteco.2024.03.001.
53. KOOP, Gary; KOROBILIS, Dimitris. *Bayesian Multivariate Time Series Methods for Empirical Macroeconomics*. 2009. Tech. zpr., 20125. Munich Personal RePEc Archive (MPRA). Dostupné také z: https://mpra.ub.uni-muenchen.de/20125/1/MPRA_paper_20125.pdf.
54. KOOP, Gary; KOROBILIS, Dimitris. Bayesian Multivariate Time Series Methods for Macroeconomic Forecasting. *Journal of Econometrics* [online]. 2010, roč. 160, č. 2, s. 210–223 [cit. 2025-12-01]. Dostupné z: <https://scispace.com/pdf/bayesian-multivariate-time-series-methods-for-empirical-3xq7f5uxcz.pdf>.
55. KOROBILIS, Dimitris. *Machine Learning Econometrics: Bayesian Algorithms and Applications*. 2020. Tech. zpr., 100165. Munich Personal RePEc Archive (MPRA). Dostupné také z: <https://mpra.ub.uni-muenchen.de/100165/>.
56. LINZENICH, Jan; MEUNIER, Baptiste. *Nowcasting Made Easier: A Toolbox for Economists*. 2024. Working Paper, 3004. European Central Bank. Dostupné také z: <https://www.ecb.europa.eu/pub/pdf/scpwps/ecb.wp3004~3ce9d0d8ca.en.pdf>.
57. LODEFALK, Magnus. The Role of Services for Manufacturing Firm Exports. *Review of World Economics*. 2014, roč. 150, s. 59–82. Dostupné z dor: 10.1007/s10290-013-0171-4.
58. LUBIK, Thomas A.; MATTHES, Christian. Time-Varying Parameter VARs: Specification, Estimation, and an Application. *Federal Reserve Bank of Richmond Economic Quarterly*. 2015, roč. 101, č. 4, s. 323–352. Dostupné také z: https://www.richmondfed.org/-/media/richmondfedorg/publications/research/economic_quarterly/2015/q4/pdf/lubik.pdf.
59. LÜTKEPOHL, Helmut. *New Introduction to Multiple Time Series Analysis*. Berlin: Springer, 2005. ISBN 978-3-540-40172-8. Dostupné také z: https://www.cur.ac.rw/mis/main/library/documents/book_file/2005_Book_NewIntroductionToMultipleTimeSeries.pdf.
60. MINISTERSTVO FINANČÍ ČR. *Forecasting Components: VAR Analysis in the Czech Republic*. 2020. Working Paper. Ministerstvo financí České republiky. Dostupné také z: <https://www.mfcr.cz/assets/attachments/20200402-Forecasting-VAR-analysis.pdf>.
61. MINISTERSTVO FINANČÍ ČR. *Makroekonomická predikce – duben 2023* [online]. 2023. [cit. 2025-12-01]. Tech. zpr. Ministerstvo financí ČR. Dostupné z: <https://www.mfcr.cz/cs/rozpocetova-politika/makroekonomika/makroekonomicka-predikce/2023/makroekonomicka-predikce-duben-2023-50912>.
62. MISE, Emi; NELSON, Charles R. Lag length selection and the construction of unit root tests with good size and power. *Econometrica*. 2003, roč. 71, č. 4, s. 1177–1210. Dostupné také z: <https://doi.org/10.1111/1468-0262.00441>.
63. NĚMEC, Daniel. *Bayesiánská analýza* [online]. 2011. [cit. 2025-12-01]. Dostupné z: <https://1url.cz/@Nemec-BAAN>.
64. NGUYEN, Thanh; PHAM, Minh; DO, Lan. Nowcasting Vietnam's Export Growth with Mixed-Frequency Data. *Review of Global Social and Applied Sciences*. 2024, roč. 5,

BIBLIOGRAFIE

- č. 2, s. 45–62. Dostupné také z: <https://rgsa.openaccesspublications.org/rgsa/article/view/6237>.
65. OBSERVATORY OF ECONOMIC COMPLEXITY. *Czechia (CZE) – Exports, Imports, and Trade Partners*. 2025. Dostupné také z: <https://oec.world/en/profile/country/cze>.
66. OECD. *Productivity Levels / Unit Labour Costs – Czechia (CZE) – Series: ULCE..IX...S*. 2025. Dostupné také z: [https://data-explorer.oecd.org/vis?lc=en&fs\[0\]=Topic%2C1%7CEconomy%23ECO%23%7CProductivity%23ECO_PRO%23&pg=0&fc=Topic&bp=true&snb=6&vw=tb&df\[ds\]=dsDisseminateFinalDMZ&df\[id\]=DSD_PDB%40DF_PDB_ULC_Q&df\[ag\]=OECD.SDD.TPS&df\[vs\]=1.0&dq=CZE.Q.ULCE..IX...S.&to\[TIME_PERIOD\]=false&pd=%2C&lb=bt](https://data-explorer.oecd.org/vis?lc=en&fs[0]=Topic%2C1%7CEconomy%23ECO%23%7CProductivity%23ECO_PRO%23&pg=0&fc=Topic&bp=true&snb=6&vw=tb&df[ds]=dsDisseminateFinalDMZ&df[id]=DSD_PDB%40DF_PDB_ULC_Q&df[ag]=OECD.SDD.TPS&df[vs]=1.0&dq=CZE.Q.ULCE..IX...S.&to[TIME_PERIOD]=false&pd=%2C&lb=bt).
67. ONIPEDE, Samuel F.; OMODERO, Cordelia O.; AYINDE, Kazeem. Small Open Economies and External Shocks: An Application of Bayesian Global VAR. *Economic Modelling*. 2022, roč. 114, s. 105–128. Dostupné také z: <https://pmc.ncbi.nlm.nih.gov/articles/PMC9174443/>.
68. ORPHANIDES, Athanasios; VAN NORDEN, Simon. The unreliability of output-gap estimates in real time. *The Review of Economics and Statistics*. 2002, roč. 84, č. 4, s. 569–583. Dostupné také z: <https://doi.org/10.1162/003465302760556422>.
69. PRATI, Alessandro. Import and Export Elasticities. In: *Trade Elasticities*. IMF, 2014. Dostupné také z: <https://www.elibrary.imf.org/display/book/9781616350536/ch06.xml>.
70. PRIMICERI, Giorgio E. Time-Varying Structural Vector Autoregressions and Monetary Policy. *Journal of Monetary Economics*. 2005, roč. 52, č. 7, s. 1187–1216. Dostupné také z: https://faculty.wcas.northwestern.edu/gep575/tvsvar_final_july_04.pdf. Použito kvůli definici rekurzivního TVP přístupu; stále základní zdroj.
71. REDDING, Stephen; VENABLES, Anthony J. Explaining Cross-Country Export Performance: International Linkages and Internal Geography. *CEP Discussion Paper 0549*. 2002. Dostupné také z: <https://eprints.lse.ac.uk/2173/8/DP0549.pdf>.
72. RIVERA-BATIZ, Francisco L.; ERBIL, Can; OPANASETS, Alexandra. International Trade Theory and Evidence: A Survey. In: *Encyclopedia of International Economics and Global Trade* [online]. 2020, vol. 3, s. 85–144 [cit. 2025-12-01]. Dostupné z: https://www.columbia.edu/~flr9/documents/Rivera-Batiz_Erbil_Opanasets_International_Trade_Theory_2020.pdf.
73. ROSORIO, Diana; QUÁCH, Tuan Long; WYNN, Machael. *Nowcasting Exports in ASEAN+3 Economies*. 2024. Working Paper. AMRO. Dostupné také z: https://amro-asia.org/wp-content/uploads/2024/06/AMRO-Working-Paper-2024_12June2024.pdf.
74. SANTOS SILVA, J. M. C.; TENREYRO, Silvana. The Log of Gravity. *The Review of Economics and Statistics*. 2006, roč. 88, č. 4, s. 641–658. Dostupné z doi: 10.1162/rest.88.4.641.
75. SEMERÁK, Vilém. Analysis of the Export and Import Function of the Czech Republic. *Journal of Competitiveness and Finance* [online]. 2021, roč. 21, č. 2, s. 5–26 [cit. 2025-12-01]. Dostupné z: <https://ideas.repec.org/a/prg/jnlcfu/v2021y2021i2id560p5-26.html>.

76. SEN, Sunanda. *International Trade Theory and Policy: A Review of the Literature* [online]. 2010. [cit. 2025-12-01]. Working Paper, 635. Levy Economics Institute of Bard College. Dostupné z: https://www.researchgate.net/publication/228240655_International_Trade_Theory_and_Policy_A_Review_of_the_Literature.
77. SIMS, Christopher A. Macroeconomics and Reality. *Econometrica*. 1980, roč. 48, č. 1, s. 1–48. Dostupné z doi: 10.2307/1912017.
78. SKOŘEPA, Michal; TOMŠÍK, Vladimír; VLČEK, Jan. Impact of the CNB's Exchange Rate Commitment: Pass-through to Inflation. In: *BIS Papers No. 89: Inflation Mechanism, Expectations and Monetary Policy*. Bank for International Settlements, 2016, s. 153–160. Dostupné také z: <https://www.bis.org/publ/bppdf/bispap89j.pdf>.
79. SMITH, Adam. *Pojednání o podstatě a původu bohatství národů*. Přel. HRUBÝ, Josef. Praha: Svoboda, 1776.
80. STOCK, James H.; WATSON, Mark W. Vector Autoregressions. *Journal of Economic Perspectives*. 2001, roč. 15, č. 4, s. 101–115. Dostupné také z: <https://pubs.aeaweb.org/doi/pdf/10.1257/jep.15.4.101>.
81. ŠESTOŘÁD, T. *Jak kurz koruny ovlivňuje českou ekonomiku?* ČNB Blog, 2023-11. Dostupné také z: https://www.cnb.cz/cs/o_cnb/cnblog/Jak-kurz-koruny-ovlivnuje-ceskou-ekonomiku/.
82. TAGLIONI, Daria. Exchange Rates and the Extensive Margin of Exports. *WTO Working Paper*. 2012. Dostupné také z: https://www.wto.org/english/res_e/reser_e/gtdw_e/wkshop12_e/taglioni.pdf.
83. TIMMER, Marcel P.; LOS, Bart; STEHRER, Robert; VRIES, Gaaitzen J. de. *An Anatomy of the Global Trade Slowdown Based on the WIOD 2016 Release* [online]. 2016. [cit. 2025-12-01]. Research Memorandum, 162. Groningen Growth a Development Centre. Dostupné z: https://www.rug.nl/ggdc/html_publications/memorandum/gd162.pdf.
84. UNITED NATIONS. *Key Statistics and Trends in International Trade 2024: Trade Growth amid Volatility and Ongoing Uncertainties*. Geneva, 2025. Technical and Statistical Report, UNCTAD/DITC/TAB/2025/2. United Nations. ISBN 978-92-1-003536-1. ISSN 2663-7960. Dostupné také z: https://unctad.org/system/files/official-document/ditctab2025d2_en.pdf.
85. VLACH, Jan; KOZELSKÝ, Tomáš. Labour Costs, Unit Labour Costs and the Labour's Share in Costs in the Czech Republic 2000 to 2008. *RILSA Study*. 2011. Dostupné také z: https://katalog.vupsv.cz/Fulltext/vz_328.pdf.
86. WIESEN, Tobias F. P. A Joint Impulse Response Function for Structural VARs. *Journal of Applied Econometrics*. 2024, roč. 39, č. 4, s. 512–535. Dostupné také z: <https://onlinelibrary.wiley.com/doi/full/10.1002/jae.3094>.
87. WZIĄTEK-KUBIAK, Alicja; MAGDA, Iwona. Changes in the Competitive Position of the Czech Republic and Poland. *Studies & Analyses No. 317*. 2006. Dostupné také z: <https://www.files.ethz.ch/isn/108876/317.pdf>.

R skript a dataset

R skript s odhadnutým modelem a použitými daty přikládám při elektronickém odevzdání diplomové práce ve formátu .zip. Pro větší přehlednost a snadnější dostupnost je materiál rovněž zveřejněn na mém GitHubu: https://github.com/PetrChaloupek/MacroeconomicModelling/tree/754a6ba8fcfe088af5c709a80a94f84df6a31418/R/Determinants_and_Elasticity_of_Czech_Export.

Test stacionarity

Tabulka 4: ADF test cyklických složek proměnných

Proměnná	Testová statistika	p-hodnota
l_x_gap	-3,414	0,00096***
l_y_gap	-3,874	0,00020***
l_e_gap	-4,058	0,00010***
l_p_gap	-2,498	0,01427**
l_ulc_gap	-2,440	0,01661**
l_m_gap	-4,154	0,000074***

Zdroj: vlastní zpracování